Fernando Mucomole

Universidade Eduardo Mondlane
Centro de Desenvolvimento Académico
Formação Avançada em Revisão Sistemática e Meta-Análises

Maputo – Moçambique, 2026

Enquadramento do módulo

A meta-análise é um conjunto de métodos estatísticos utilizados para combinar quantitativamente resultados de estudos que investigam uma questão de investigação comum.

Quando os estudos são suficientemente comparáveis em termos de:

- população;
- intervenção ou exposição;
- comparador;
- resultados;
- desenho metodológico.

A síntese quantitativa permite estimar efeitos globais, quantificar a incerteza e investigar a variabilidade dos resultados entre estudos.

O que envolve uma meta-análise?

A realização de uma meta-análise não consiste apenas em calcular uma média dos resultados publicados.

Exige:

1. Definição de uma medida de efeito apropriada;
2. Estimação da variância;
3. Escolha de um modelo estatístico;
4. Avaliação da heterogeneidade;
5. Interpretação crítica dos resultados;
6. Documentação dos procedimentos analíticos.

Ideia central

A meta-análise combina estimativas de efeitos e a respectiva incerteza. Os resultados devem ser interpretados à luz da qualidade dos estudos, da compatibilidade das medidas e da heterogeneidade.

Objectivos de aprendizagem

No final do módulo, o formando deverá ser capaz de:

1. Identificar medidas de efeito para resultados contínuos, binários e outros tipos de dados.
2. Calcular DM, DMP, OR, RR e diferenças de riscos.
3. Estimar variâncias, erros-padrão e intervalos de confiança.
4. Distinguir modelos de efeito fixo e efeitos aleatórios.
5. Quantificar e interpretar a heterogeneidade.
6. Explicar a estimação da variância entre estudos.
7. Calcular e interpretar intervalos de predição.
8. Compreender os fundamentos da meta-regressão.
9. Implementar meta-análises em R.
10. Produzir relatórios estatísticos reproduzíveis.

Estimativa do efeito e incerteza

Considere-se um conjunto de k estudos.
Cada estudo fornece:

- uma estimativa do efeito, y_i;
- uma variância amostral estimada, v_i.

O erro-padrão da estimativa é:

$$SE(y_i) = \sqrt{v_i}.$$

Sob uma aproximação normal, o intervalo de confiança de 95% é:

$$IC_{95\%}(y_i) = y_i \pm 1.96\sqrt{v_i}.$$

O valor 1,96 corresponde aproximadamente ao quantil de 97,5% da distribuição normal padrão.

Precisão e ponderação

Um estudo com menor variância fornece, em geral, uma estimativa mais precisa.
No modelo de efeito fixo, o peso inverso da variância é:

$$w_i = \frac{1}{v_i}.$$

No modelo de efeitos aleatórios:

$$w_i^* = \frac{1}{v_i + \tau^2}.$$

Em que τ^2 representa a variância entre os efeitos verdadeiros dos estudos.

Distinção importante

v_i representa a incerteza amostral da estimativa do estudo. τ^2 representa a dispersão dos efeitos verdadeiros entre estudos.

Medidas de efeito para resultados contínuos

Os resultados contínuos são variáveis numéricas, por exemplo:

- pressão arterial;
- concentração de uma substância;
- temperatura;
- rendimento;
- velocidade do vento;
- irradiância solar.

Duas medidas importantes:

1. Diferença média (DM);
2. Diferença média padronizada (DMP).

Diferença média

A diferença média é utilizada quando os estudos medem o mesmo resultado na mesma escala e com unidades comparáveis.

$$DM = \bar{X}_I - \bar{X}_C$$

Em que:

- $\bar{X}_I$: média do grupo de intervenção;
- $\bar{X}_C$: média do grupo de controlo.

A variância estimada é:

$$\text{Var}(DM) = \frac{s_I^2}{n_I} + \frac{s_C^2}{n_C}.$$

O erro-padrão é:

$$SE(DM) = \sqrt{\frac{s_I^2}{n_I} + \frac{s_C^2}{n_C}}.$$

Exemplo: diferença média

Um estudo compara a concentração média de um indicador:

$$\bar{X}_I = 24, \qquad \bar{X}_C = 20.$$

A diferença média é:

$$DM = 24 - 20 = 4.$$

Interpretação

O grupo de intervenção apresenta uma média 4 unidades superior à do grupo de controlo.

A conclusão sobre a incerteza exige também os desvios-padrão e as dimensões amostrais.

Diferença média padronizada

A diferença média padronizada é útil quando os estudos medem o mesmo conceito através de escalas diferentes.

Uma versão habitual é a estatística d de Cohen:

$$d = \frac{\bar{X}_I - \bar{X}_C}{s_p}.$$

O desvio-padrão combinado é:

$$s_p = \sqrt{\frac{(n_I - 1)s_I^2 + (n_C - 1)s_C^2}{n_I + n_C - 2}}.$$

A DMP é expressa em unidades de desvio-padrão.

Correcção de Hedges

Para reduzir o enviesamento em amostras pequenas, pode utilizar-se a correcção de Hedges:

$$g = Jd$$

com a aproximação:

$$J \approx 1 - \frac{3}{4(n_I + n_C) - 9}.$$

Limitação da padronização

A DMP não deve ser utilizada automaticamente apenas porque os estudos usam escalas distintas. É necessário verificar se as escalas medem o mesmo constructo e se os desvios-padrão são comparáveis.

Medidas de efeito para resultados binários

Os resultados binários apresentam duas categorias:

- evento / não evento;
- sucesso / insucesso;
- presença / ausência.

	Evento	Sem evento
Intervenção	a	b
Controlo	c	d

As dimensões dos grupos são:

$$n_I = a + b, \qquad n_C = c + d.$$

Risco relativo

O risco relativo compara a probabilidade do evento nos dois grupos:

$$RR = \frac{a/(a+b)}{c/(c+d)}.$$

Interpretação:

- $RR = 1$: riscos iguais;
- $RR > 1$: risco superior no grupo de intervenção;
- $RR < 1$: risco inferior no grupo de intervenção.

A variância aproximada do logaritmo do RR é:

$$\text{Var}(\log RR) = \frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}.$$

Intervalo de confiança do risco relativo

O erro-padrão é:

$$SE(\log RR) = \sqrt{\text{Var}(\log RR)}.$$

O intervalo de confiança é calculado na escala logarítmica e depois transformado:

$$IC_{95\%}(RR) = \exp\left[\log(RR) \pm 1.96 SE(\log RR)\right].$$

Esta transformação assegura que os limites do intervalo do RR permanecem positivos.

Razão de possibilidades (OR)

A razão de possibilidades é:

$$OR = \frac{a/b}{c/d} = \frac{ad}{bc}.$$

A variância aproximada do logaritmo da OR é:

$$\text{Var}(\log OR) = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}.$$

O intervalo de confiança é:

$$IC_{95\%}(OR) = \exp\left[\log(OR) \pm 1.96 SE(\log OR)\right].$$

OR e RR: interpretação

A OR e o RR não são, em geral, numericamente iguais.

Quando o evento é frequente, a OR pode afastar-se substancialmente do RR.

Cuidados

- Definir claramente o evento;
- Definir a direcção da comparação;
- Verificar a presença de células nulas;
- Não confundir risco com possibilidade.

Diferença de riscos

A diferença de riscos é:

$$DR = \frac{a}{a+b} - \frac{c}{c+d}.$$

Uma diferença de riscos igual a -0.08 corresponde a uma redução absoluta de 8 pontos percentuais.

A variância aproximada é:

$$\text{Var}(DR) = \frac{p_I(1-p_I)}{n_I} + \frac{p_C(1-p_C)}{n_C}.$$

Em que:

$$p_I = \frac{a}{n_I}, \qquad p_C = \frac{c}{n_C}.$$

Intervalo de confiança da diferença de riscos

O intervalo normal aproximado é:

$$DR \pm 1.96\sqrt{\text{Var}(DR)}.$$

Limitação

Quando as proporções estão próximas de zero ou um, ou as amostras são pequenas, este intervalo pode ter propriedades inadequadas.
Devem considerar-se métodos alternativos apropriados à situação.

Exemplo numérico: dados binários

Grupo	Eventos	Sem evento	Total
Intervenção	20	80	100
Controlo	30	70	100

$$p_I = 0.20, \qquad p_C = 0.30.$$

$$RR = \frac{0.20}{0.30} \approx 0.667.$$

$$OR = \frac{20 \times 70}{80 \times 30} \approx 0.583.$$

$$DR = 0.20 - 0.30 = -0.10.$$

Interpretação do exemplo binário

Neste exemplo:

- O risco observado no grupo de intervenção é cerca de 33,3% inferior ao do grupo de controlo em termos relativos.
- A diferença absoluta observada é de menos 10 pontos percentuais.

Nota metodológica

Estes cálculos, isoladamente, não estabelecem causalidade nem substituem a avaliação da incerteza e do desenho do estudo.

Outros tipos de dados e medidas de efeito

Tipo de resultado	Medidas possíveis	Observações
Contínuo	DM, DMP, diferenças ajustadas	Verificar unidades, escalas, desvios-padrão e desenho.
Binário	RR, OR, DR	Definir o evento e a direcção da comparação.
Contagens	Razão de taxas, diferença de taxas	Considerar tempo de exposição e modelo de contagem.
Tempo até ao evento	Hazard ratio (HR)	Verificar definição do evento e pressupostos de sobrevivência.
Correlação	Coeficiente r, transformação z de Fisher	A transformação pode facilitar a síntese e a aproximação normal.
Diagnóstico	Sensibilidade, especificidade e modelos conjuntos	Considerar a dependência entre sensibilidade e especificidade.

Não se devem combinar directamente medidas em escalas incompatíveis. As transformações devem ter justificação metodológica explícita.

Modelos estatísticos: efeito fixo

No modelo de efeito fixo, considera-se que todos os estudos estimam um único efeito subjacente comum.

As diferenças observadas são atribuídas à variabilidade amostral.

O estimador combinado é:

$$\hat{\mu}_F = \frac{\sum_{i=1}^{k} w_i y_i}{\sum_{i=1}^{k} w_i}, \qquad w_i = \frac{1}{v_i}.$$

Variância e intervalo no modelo fixo

A variância estimada é:

$$\text{Var}(\hat{\mu}_F) = \frac{1}{\sum_{i=1}^{k} w_i}.$$

O erro-padrão:

$$SE(\hat{\mu}_F) = \sqrt{\frac{1}{\sum_{i=1}^{k} w_i}}.$$

O intervalo de confiança aproximado é:

$$IC_{95\%}(\hat{\mu}_F) = \hat{\mu}_F \pm 1.96 SE(\hat{\mu}_F).$$

Interpretação do modelo de efeito fixo

Este modelo pode ser adequado quando a hipótese de um efeito comum é defensável e a população de estudos permite essa interpretação.

Cuidado

A ausência de heterogeneidade estatisticamente significativa não demonstra, por si só, que o efeito seja idêntico em todos os estudos.

Modelo de efeitos aleatórios

O modelo de efeitos aleatórios admite que os efeitos verdadeiros variam entre os estudos. Uma formulação habitual é:

$$y_i = \theta_i + \varepsilon_i$$

$$\theta_i = \mu + u_i.$$

Em que:

- y_i: estimativa observada;
- θ_i: efeito verdadeiro do estudo;
- ε_i: erro amostral;
- u_i: desvio do efeito verdadeiro;
- μ: média dos efeitos verdadeiros.

Pressupostos do modelo aleatório

Uma hipótese clássica é:

$$u_i \sim N(0, \tau^2)$$

$$\varepsilon_i \sim N(0, v_i).$$

Assim:

$$\text{Var}(y_i) = v_i + \tau^2.$$

A variância total incorpora:

- incerteza amostral;
- variabilidade entre efeitos verdadeiros.

Estimador de efeitos aleatórios

O estimador combinado é:

$$\hat{\mu}_R = \frac{\sum_{i=1}^{k} w_i^* y_i}{\sum_{i=1}^{k} w_i^*}.$$

Os pesos são:

$$w_i^* = \frac{1}{v_i + \tau^2}.$$

A variância condicional estimada é:

$$\widehat{\mathrm{Var}}(\hat{\mu}_R) = \frac{1}{\sum_{i=1}^{k} w_i^*}.$$

Inferência nos efeitos aleatórios

A incerteza na estimação de τ^2 e o número de estudos podem exigir métodos de inferência mais robustos.

Um método possível é o ajuste de Hartung–Knapp.

Interpretação

O modelo estima a média dos efeitos verdadeiros na população de estudos definida pelo modelo, admitindo variação entre estudos.

Comparação dos modelos

Aspecto	**Efeito fixo**	**Efeitos aleatórios**
Hipótese central	Efeito comum	Distribuição de efeitos verdadeiros
Variância	v_i	$v_i + \tau^2$
Peso	$1/v_i$	$1/(v_i + \tau^2)$
Interpretação	Efeito comum assumido	Média dos efeitos na população de estudos
Heterogeneidade	Não modelada como dispersão de efeitos verdadeiros	Modelada através de τ^2
Limitação	Pode ser inadequado se houver variação real	Exige estimar a variância entre estudos

Como escolher o modelo?

Não escolher apenas pelo teste de heterogeneidade

A escolha entre modelos deve ser fundamentada:

- na pergunta de investigação;
- no desenho dos estudos;
- na plausibilidade de um efeito comum;
- na população de estudos de interesse.

Não se deve escolher automaticamente o modelo de efeito fixo quando o teste de heterogeneidade apresenta $p > 0.05$.

Heterogeneidade entre estudos

A heterogeneidade corresponde à variabilidade dos resultados que não é explicada exclusivamente pelo erro amostral.

Pode estar associada a diferenças de:

- população;
- contexto;
- intervenção ou exposição;
- medição;
- desenho metodológico;
- qualidade dos estudos.

Estatística Q de Cochran

A estatística Q é definida por:

$$Q = \sum_{i=1}^{k} w_i (y_i - \hat{\mu}_F)^2.$$

Sob determinadas hipóteses, Q é comparada com uma distribuição qui-quadrado com:

$$gl = k - 1.$$

Limitações

O teste pode ter baixa potência quando existem poucos estudos e detectar diferenças pequenas quando há muitos estudos.

Estatística I^2

Uma medida frequentemente utilizada é:

$$I^2 = \max\left\{0, \frac{Q-(k-1)}{Q}\right\} \times 100\%.$$

O I^2 descreve a proporção da variabilidade observada atribuível à heterogeneidade, segundo esta formulação.

Não representa directamente a magnitude absoluta das diferenças entre efeitos.

Interpretação de I^2

Como referências heurísticas, encontram-se frequentemente:

Valor aproximado	**Interpretação**
25%	Baixa heterogeneidade
50%	Heterogeneidade moderada
75%	Heterogeneidade elevada

Nota

Estas categorias não são regras universais. A interpretação depende do contexto, da precisão e das medidas de efeito utilizadas.

Variância entre estudos: τ^2

A variância entre estudos quantifica a dispersão dos efeitos verdadeiros na escala de efeito utilizada. Uma estimativa clássica é o método de DerSimonian–Laird:

$$\hat{\tau}^2_{\mathrm{DL}} = \max\left\{0, \frac{Q-(k-1)}{C}\right\}.$$

Em que:

$$C = \sum_{i=1}^{k} w_i - \frac{\sum_{i=1}^{k} w_i^2}{\sum_{i=1}^{k} w_i}.$$

Outros estimadores de τ^2

Existem outros estimadores, incluindo:

- Máxima verosimilhança (ML);
- Máxima verosimilhança restrita (REML);
- Paule–Mandel.

Os métodos podem produzir resultados diferentes, sobretudo quando há poucos estudos ou heterogeneidade limitada.

A escolha deve ser justificada e, quando relevante, acompanhada por análises de sensibilidade.

Interpretação conjunta da heterogeneidade

Três medidas complementares

- I^2: descreve a heterogeneidade relativa;
- τ^2: representa a variância entre efeitos verdadeiros;
- Intervalo de predição: descreve a distribuição plausível do efeito verdadeiro num novo contexto comparável.

Intervalos de predição

O intervalo de confiança da média combinada descreve a incerteza sobre a média dos efeitos.

O intervalo de predição procura representar a incerteza sobre o efeito verdadeiro de um novo estudo pertencente à população de estudos definida pelo modelo.

Fórmula aproximada do intervalo de predição

Uma aproximação habitual é:

$$\hat{\mu}_R \pm t_{k-2,\,0.975}\sqrt{\hat{\tau}^2 + \widehat{\mathrm{Var}}(\hat{\mu}_R)}.$$

Em que $t_{k-2,\,0.975}$ é um quantil da distribuição t de Student.

A fórmula corresponde a uma aproximação utilizada em certas implementações e não é universal para todos os modelos.

Interpretação dos intervalos de predição

Um intervalo de confiança relativamente estreito para a média pode coexistir com um intervalo de predição amplo.

Esta situação indica que:

- a média global pode ser estimada com precisão;
- o efeito verdadeiro pode variar substancialmente entre contextos.

Cautela

Com poucos estudos, o intervalo de predição pode ser muito impreciso. Não deve ser interpretado como um intervalo que contém 95% dos resultados observados de todos os estudos.

Introdução à meta-regressão

A meta-regressão é uma extensão da meta-análise que investiga se características dos estudos estão associadas à magnitude dos efeitos.

Considere-se uma variável moderadora x_i.

Um modelo simples é:

$$y_i = \beta_0 + \beta_1 x_i + u_i + \varepsilon_i.$$

Componentes da meta-regressão

- β_0: intercepto;
- β_1: associação entre o moderador e o efeito;
- u_i: variação residual entre estudos;
- ε_i: erro amostral.

Com vários moderadores:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + u_i + \varepsilon_i.$$

Exemplos de moderadores

Em estudos de recurso eólico:

- altura de medição;
- período de observação;
- região geográfica.

Em estudos de irradiância solar:

- tipo de instrumento;
- estação do ano;
- categoria climática.

Os moderadores devem estar disponíveis de forma comparável nos estudos.

Interpretação dos coeficientes

O coeficiente β_1 estima a mudança média na medida de efeito associada a uma unidade adicional de x_i, mantendo os restantes moderadores constantes no modelo especificado.

Se a medida de efeito for o logaritmo do risco relativo, o coeficiente está na escala logarítmica.

A exponenciação permite obter uma razão multiplicativa na escala do RR.

Limitações da meta-regressão

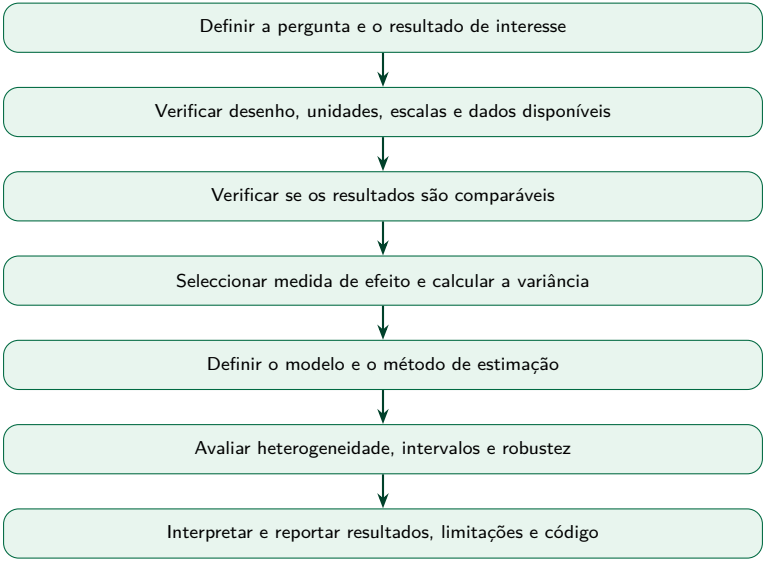
- O número de estudos limita o número de moderadores.
- Associações entre características dos estudos não demonstram relações causais.
- A análise de características médias pode sofrer de falácia ecológica.
- A colinearidade dificulta a interpretação.
- Muitos moderadores exploratórios aumentam o risco de resultados espúrios.
- A ausência de dados dos moderadores pode introduzir enviesamento.

Princípio metodológico da meta-regressão

Planeamento

Os moderadores principais devem, sempre que possível, ser definidos no protocolo.
As análises exploratórias devem ser identificadas como tal e interpretadas com prudência.

Fluxo de decisão estatística



Quando os resultados não são comparáveis

Se os resultados não forem suficientemente comparáveis:

- rever a pergunta e a estrutura da síntese;
- verificar as definições dos resultados;
- verificar as unidades e escalas;
- considerar síntese narrativa;
- considerar métodos estatísticos específicos.

A comparabilidade deve ser avaliada antes de combinar quantitativamente os resultados.

Implementação prática com R

Objectivo da actividade

Realizar uma meta-análise de resultados contínuos a partir de dados ilustrativos de cinco estudos.

A actividade inclui:

- cálculo de diferenças médias;
- ajuste de modelos de efeito fixo e aleatórios;
- avaliação da heterogeneidade;
- intervalo de predição;
- gráfico de floresta.

Nota

Os dados são exclusivamente didácticos e não representam resultados de uma investigação publicada.

Instalação dos pacotes R

O pacote `metafor` disponibiliza funções para análise de efeitos, modelos, heterogeneidade, meta-regressão e gráficos.

O pacote `meta` disponibiliza funções adicionais para sínteses estatísticas e visualização.

```r
install.packages(c("metafor", "meta"))
```

A instalação só é necessária uma vez em cada ambiente R. Em sessões posteriores, basta carregar os pacotes.

Conjunto de dados ilustrativo

Estudo	n_I	Média I	DP I	n_C	Média C	DP C
A	40	15.2	3.1	38	13.8	3.0
B	52	14.1	2.8	50	13.5	2.9
C	35	16.0	3.4	36	14.2	3.2
D	60	13.8	2.7	58	13.9	2.8
E	45	15.0	3.0	47	14.1	3.1

A variável de resultado está na mesma unidade nos cinco estudos.

Por isso, a diferença média é uma medida de efeito plausível para esta demonstração.

Script R: criação dos dados

```r
# MODULO 12: META-ANALISE
# Dados exclusivamente didacticos

library(metafor)

dados <- data.frame(
 estudo = c("Estudo A", "Estudo B", "Estudo C",
            "Estudo D", "Estudo E"),
 nI = c(40, 52, 35, 60, 45),
 mediaI = c(15.2, 14.1, 16.0, 13.8, 15.0),
 dpI = c(3.1, 2.8, 3.4, 2.7, 3.0),
 nC = c(38, 50, 36, 58, 47),
 mediaC = c(13.8, 13.5, 14.2, 13.9, 14.1),
 dpC = c(3.0, 2.9, 3.2, 2.8, 3.1)
)

print(dados)
```

Script R: cálculo dos efeitos

```r
efeitos <- escalc(
 measure = "MD",
 m1i = mediaI,
 sd1i = dpI,
 n1i = nI,
 m2i = mediaC,
 sd2i = dpC,
 n2i = nC,
 data = dados
)

print(efeitos[, c("estudo", "yi", "vi")])
```

A função `escalc()` calcula as estimativas dos efeitos e as respectivas variâncias.

Script R: modelo de efeito fixo

```r
modelo_fixo <- rma(
  yi = yi,
  vi = vi,
  data = efeitos,
  method = "FE"
)

summary(modelo_fixo)
```

O modelo utiliza os pesos inversos das variâncias individuais.

Script R: modelo de efeitos aleatórios

```r
modelo_aleatorio <- rma(
  yi = yi,
  vi = vi,
  data = efeitos,
  method = "REML",
  test = "knha"
)

summary(modelo_aleatorio)
```

O método REML estima a variância entre estudos. O argumento `test="knha"` aplica um ajuste de Hartung–Knapp na inferência.

Script R: heterogeneidade

```r
cat("Q =", modelo_aleatorio$QE, "\n")

cat("Graus de liberdade =",
    modelo_aleatorio$k - 1, "\n")

cat("p-valor do teste Q =",
    modelo_aleatorio$QEp, "\n")

cat("I2 (%) =",
    modelo_aleatorio$I2, "\n")

cat("Tau2 =",
    modelo_aleatorio$tau2, "\n")
```

Script R: intervalo de predição

```r
# Intervalo de predicao
# quando suportado pela versao instalada

predicao <- predict(modelo_aleatorio)

print(predicao)
```

O intervalo de predição procura representar a variação plausível do efeito verdadeiro num novo contexto comparável.

Script R: gráfico de floresta

```r
png("forest_plot.png",
    width = 1600,
    height = 1100,
    res = 160)

forest(
 modelo_aleatorio,
 slab = dados$estudo,
 xlab = "Diferenca media",
 mlab = "Modelo de efeitos aleatorios",
 refline = 0
)

dev.off()
```

Script R: gráfico de funil

```r
png("funnel_plot.png",
    width = 1200,
    height = 1000,
    res = 150)

funnel(
 modelo_aleatorio,
 xlab = "Diferenca media",
 yaxis = "sei"
)

dev.off()
```

Script R: exportação dos resultados

```r
resultados_individuais <- data.frame(
  estudo = dados$estudo,
  efeito = efeitos$yi,
  variancia = efeitos$vi,
  erro_padrao = sqrt(efeitos$vi),
  limite_inferior =
    efeitos$yi - 1.96 * sqrt(efeitos$vi),
  limite_superior =
    efeitos$yi + 1.96 * sqrt(efeitos$vi)
)

write.csv(
  resultados_individuais,
  "resultados_individuais.csv",
  row.names = FALSE
)
```

Script R: exportação dos resumos

```r
capture.output(
  summary(modelo_fixo),
  file = "resumo_modelo_fixo.txt"
)

capture.output(
  summary(modelo_aleatorio),
  file = "resumo_modelo_aleatorio.txt"
)

cat("Analise concluida.\n")
```

Verificação da versão do software

As funções e opções podem variar entre versões do pacote.

Antes de entregar o relatório, deve confirmar-se:

- que o script executa no ambiente utilizado;
- que os intervalos correspondem ao método seleccionado;
- que os resultados exportados estão completos.

Nota

`test="knha"` aplica um ajuste de Hartung–Knapp na inferência do modelo; não deve ser confundido com um estimador de τ^2.

Leitura dos resultados

A função `summary()` apresenta, entre outros elementos:

- estimativa combinada do efeito;
- erro-padrão e intervalo de confiança;
- teste da hipótese de efeito médio nulo;
- estatística Q e respectivo teste;
- estimativa de τ^2;
- estatística I^2;
- número de estudos incluídos.

Interpretação crítica dos resultados

O valor de p não deve ser interpretado isoladamente.

A interpretação deve considerar:

- magnitude e direcção do efeito;
- precisão;
- heterogeneidade;
- relevância científica;
- qualidade metodológica dos estudos.

Extensão para resultados binários

```r
dados_binarios <- data.frame(
  estudo = c("A", "B", "C"),
  eventosI = c(20, 15, 28),
  totalI = c(100, 80, 120),
  eventosC = c(30, 20, 35),
  totalC = c(100, 82, 118)
)
```

O pacote `metafor` permite calcular medidas como o logaritmo do risco relativo e o logaritmo da razão de possibilidades.

Cálculo do risco relativo em R

```r
efeitos_binarios <- escalc(
 measure = "RR",
 ai = eventosI,
 bi = totalI - eventosI,
 ci = eventosC,
 di = totalC - eventosC,
 data = dados_binarios,
 add = 0.5,
 to = "only0"
)

modelo_RR <- rma(
 yi = yi,
 vi = vi,
 data = efeitos_binarios,
 method = "REML"
)

summary(modelo_RR)
```

Transformação do risco relativo

```r
# Transformar a estimativa combinada
# para a escala do risco relativo

exp(coef(modelo_RR))

exp(confint(modelo_RR)$random)
```

Correcção de continuidade

A aplicação de uma correcção, especialmente em estudos com eventos raros ou braços sem eventos, pode afectar os resultados.
O método deve ser escolhido de acordo com a estrutura dos dados e descrito no relatório.

Meta-regressão em R

Considere-se que cada estudo registou uma variável moderadora, por exemplo, o ano médio de publicação.

```r
dados$ano <- c(2018, 2019, 2020, 2022, 2023)

efeitos$ano <- dados$ano

modelo_meta_reg <- rma(
  yi = yi,
  vi = vi,
  mods = ~ ano,
  data = efeitos,
  method = "REML"
)

summary(modelo_meta_reg)
```

Meta-regressão: coeficientes

```r
# Coeficientes do modelo
coef(modelo_meta_reg)

# Intervalos de confianca
confint(modelo_meta_reg)
```

Limitação do exemplo

Existem apenas cinco estudos. A meta-regressão tem capacidade limitada para avaliar moderadores. Os dados são fictícios e não devem receber interpretação substantiva.

Gráfico de floresta

O gráfico de floresta apresenta:

- estimativas individuais;
- intervalos de confiança;
- estimativa combinada.

Permite examinar visualmente:

- direcção dos efeitos;
- precisão dos estudos;
- dispersão das estimativas;
- posição do efeito combinado;
- consistência entre estudos.

Gráfico de funil

O gráfico de funil relaciona as estimativas dos efeitos com uma medida de precisão.
A assimetria pode resultar de:

- efeitos de estudos pequenos;
- heterogeneidade;
- enviesamento de publicação;
- outros mecanismos.

Limitações do gráfico de funil

Interpretação prudente

A assimetria não demonstra, por si só, enviesamento de publicação.
Os testes de assimetria também podem ter baixo poder com poucos estudos.
Os resultados devem ser interpretados em conjunto com o contexto da revisão e outras evidências.

Análises de sensibilidade e robustez

Uma análise de sensibilidade examina se as conclusões se mantêm quando determinadas decisões analíticas são alteradas de forma justificada.

Podem ser consideradas:

1. comparação entre modelos fixos e aleatórios;
2. comparação de estimadores de τ^2;
3. exclusão de estudos com risco de viés elevado, quando prevista;
4. avaliação da influência de estudos individuais;
5. comparação de definições de resultados;
6. avaliação de métodos alternativos para dados raros ou incompletos.

Princípios da análise de sensibilidade

Transparência

A análise de sensibilidade não deve ser utilizada para seleccionar apenas o resultado mais favorável. Todas as análises relevantes, incluindo as que alteram as conclusões, devem ser reportadas.

Actividade prática orientada

Trabalho de laboratório

Título: Meta-análise de dados contínuos utilizando R.
Duração sugerida: 120 a 180 minutos.
Organização: Trabalho individual ou em grupos de dois a três formandos.

Objectivo: aplicar os procedimentos estatísticos e computacionais desenvolvidos neste módulo.

Actividade prática: tarefas I

1. Introduzir os cinco estudos do conjunto de dados ilustrativo.
2. Calcular as diferenças médias e respectivas variâncias.
3. Ajustar um modelo de efeito fixo.
4. Ajustar um modelo de efeitos aleatórios com REML.
5. Comparar as estimativas combinadas e os intervalos de confiança.
6. Interpretar Q, I^2 e τ^2.

Actividade prática: tarefas II

7. Obter o intervalo de predição e explicar a sua diferença em relação ao intervalo de confiança da média.
8. Produzir um gráfico de floresta.
9. Produzir um gráfico de funil e discutir as suas limitações.
10. Executar uma meta-regressão exploratória com um moderador.
11. Exportar os resultados e preparar um relatório estatístico.

Questões para discussão I

1. Por que razão a diferença média é apropriada para os dados?
2. Em que condições seria preferível a diferença média padronizada?
3. O que representa a variância entre estudos?
4. Um valor de I^2 elevado implica necessariamente que a síntese seja inválida?

Questões para discussão II

5. Por que razão o intervalo de predição pode ser mais amplo do que o intervalo de confiança do efeito médio?
6. Que limitações decorrem de uma meta-regressão com apenas cinco estudos?
7. Como proceder quando os estudos utilizam definições diferentes do resultado?
8. Que elementos são indispensáveis para reproduzir a análise?

Produto esperado

Cada formando deverá entregar um conjunto de ficheiros organizados.

Produto	**Conteúdo mínimo**
Script R	Código completo, comentários, cálculo dos efeitos, modelos e exportação.
Dados de entrada	Ficheiro CSV ou conjunto de dados incorporado no script, com descrição das variáveis.
Relatório estatístico	Pergunta, métodos, medida de efeito, modelo, heterogeneidade, resultados e limitações.
Gráfico de floresta	Estimativas individuais, intervalos de confiança e resultado combinado.
Ficheiro de resultados	Estimativas, erros-padrão, intervalos de confiança e estatísticas de heterogeneidade.
Nota de reprodutibilidade	Versão do R, pacotes utilizados, decisões analíticas e instruções de execução.

Estrutura do relatório estatístico I

O relatório final deverá apresentar:

1. **Pergunta de investigação:** população, intervenção ou exposição, comparador e resultado.
2. **Dados:** número de estudos, características principais e critérios de inclusão.
3. **Medida de efeito:** justificação da escolha e definição da direcção do efeito.
4. **Métodos estatísticos:** modelo, estimador de heterogeneidade e método de construção dos intervalos.

Estrutura do relatório estatístico II

5. **Resultados:** efeito combinado, intervalo de confiança, heterogeneidade e, quando apropriado, intervalo de predição.
6. **Visualizações:** gráfico de floresta e outras figuras.
7. **Análises adicionais:** sensibilidade e meta-regressão, quando justificadas.
8. **Discussão:** relevância científica, limitações, risco de viés e generalização.
9. **Reprodutibilidade:** código, dados autorizados, dependências e decisões analíticas.

Grelha de avaliação

Critério	Peso	Pontuação
Escolha e justificação da medida de efeito	15%	/15
Cálculo e interpretação da incerteza	15%	/15
Implementação dos modelos estatísticos	20%	/20
Avaliação e interpretação da heterogeneidade	15%	/15
Gráficos e apresentação dos resultados	10%	/10
Interpretação crítica e limitações	15%	/15
Reprodutibilidade e organização do código	10%	/10
Total	**100%**	**/100**

Conclusões do módulo I

1. A medida de efeito deve ser seleccionada em função do tipo de resultado, das unidades e da pergunta de investigação.
2. A variância e o erro-padrão são essenciais para quantificar a incerteza das estimativas.
3. Os modelos de efeito fixo e de efeitos aleatórios assentam em pressupostos diferentes.
4. A heterogeneidade deve ser examinada através de medidas complementares, incluindo Q, I^2 e τ^2.

Conclusões do módulo II

5. Os intervalos de predição ajudam a compreender a possível variação dos efeitos verdadeiros entre contextos.
6. A meta-regressão pode investigar moderadores, mas exige número suficiente de estudos e interpretação prudente.
7. O script reproduzível e o relatório estatístico são partes essenciais de uma síntese quantitativa transparente.

Mensagem final

Uma meta-análise rigorosa

Não se limita a produzir uma estimativa combinada.
Deve explicar:

- como a estimativa foi obtida;
- qual é a sua incerteza;
- que diferenças existem entre os estudos;
- até que ponto as conclusões são sustentadas pela evidência disponível.

Referências bibliográficas I

1. Borenstein, M., Hedges, L. V., Higgins, J. P. T., & Rothstein, H. R. (2009). *Introduction to Meta-Analysis*. Wiley.
2. Higgins, J. P. T., Thomas, J., Chandler, J., Cumpston, M., Li, T., Page, M. J., & Welch, V. A. (Eds.). (2024). *Cochrane Handbook for Systematic Reviews of Interventions*. Cochrane. https://training.cochrane.org/handbook
3. DerSimonian, R., & Laird, N. (1986). Meta-analysis in clinical trials. *Controlled Clinical Trials*, 7(3), 177–188. https://doi.org/10.1016/0197-2456(86)90046-2

Referências bibliográficas II

4. Viechtbauer, W. (2010). Conducting meta-analyses in R with the metafor package. *Journal of Statistical Software*, 36(3), 1–48. https://doi.org/10.18637/jss.v036.i03
5. Higgins, J. P. T., Thompson, S. G., Deeks, J. J., & Altman, D. G. (2003). Measuring inconsistency in meta-analyses. *BMJ*, 327, 557–560. https://doi.org/10.1136/bmj.327.7414.557
6. Knapp, G., & Hartung, J. (2003). Improved tests for a random effects meta-regression with a single covariate. *Statistics in Medicine*, 22(17), 2693–2710. https://doi.org/10.1002/sim.1482

Referências bibliográficas III

7. Harrer, M., Cuijpers, P., Furukawa, T. A., & Ebert, D. D. (2021). *Doing Meta-Analysis with R: A Hands-On Guide*. Chapman and Hall/CRC. https://doi.org/10.1201/9781003107347
8. R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. https://www.r-project.org/
9. Viechtbauer, W. *metafor: Meta-Analysis Package for R*. Documentação do pacote. https://www.metafor-project.org/

MÓDULO 12

Estatística Avançada e Modelos de Meta-Análise

Universidade Eduardo Mondlane
Centro de Desenvolvimento Académico
Formação Avançada em Revisão Sistemática e Meta-Análises

Fernando Mucomole
Maputo – Moçambique
2026