**UNIVERSIDADE EDUARDO MONDLANE**

Centro de Desenvolvimento Académico




# FORMAÇÃO AVANÇADA EM REVISÃO SISTEMÁTICA E META-ANÁLISES

## MÓDULO 12

## Estatística Avançada e Modelos de Meta-Análise

Medidas de efeito, heterogeneidade,
modelos estatísticos e meta-regressão

**Formador: Fernando Mucomole**

Maputo – Moçambique
2026

# Índice

**1 Enquadramento do módulo** **3**

**2 Objectivos de aprendizagem** **3**

**3 Conceitos estatísticos fundamentais** **3**
3.1 Estimativa do efeito e incerteza . . . . . 3
3.2 Precisão e ponderação . . . . . 4

**4 Medidas de efeito para resultados contínuos** **4**
4.1 Diferença média . . . . . 4
4.2 Diferença média padronizada . . . . . 5

**5 Medidas de efeito para resultados binários** **6**
5.1 Risco relativo . . . . . 6
5.2 Razão de possibilidades . . . . . 6
5.3 Diferença de riscos . . . . . 7
5.4 Exemplo numérico . . . . . 7

**6 Outros tipos de dados e medidas de efeito** **8**

**7 Modelos estatísticos de meta-análise** **8**
7.1 Modelo de efeito fixo . . . . . 8
7.2 Modelo de efeitos aleatórios . . . . . 9
7.3 Comparação dos modelos . . . . . 10

**8 Heterogeneidade entre estudos** **10**
8.1 Estatística $Q$ de Cochran . . . . . 10
8.2 Estatística $I^2$ . . . . . 10
8.3 Variância entre estudos $\tau^2$ . . . . . 11

**9 Intervalos de predição** **11**

**10 Introdução à meta-regressão** **12**
10.1 Interpretação dos coeficientes . . . . . 12
10.2 Limitações da meta-regressão . . . . . 12

**11 Fluxo de decisão estatística** **13**

**12 Implementação prática com R** **13**
12.1 Objectivo da actividade . . . . . 13
12.2 Instalação dos pacotes . . . . . 14
12.3 Conjunto de dados ilustrativo . . . . . 14
12.4 Script R completo e reproduzível . . . . . 14
12.5 Leitura dos resultados . . . . . 17
12.6 Extensão para resultados binários . . . . . 17

**13 Meta-regressão em R** **18**

**14 Gráfico de floresta e gráfico de funil** **19**
14.1 Gráfico de floresta . . . . . 19
14.2 Gráfico de funil . . . . . 19

**15 Análises de sensibilidade e robustez** **19**

**16 Actividade prática orientada** **20**
16.1 Tarefas . . . . . 20
16.2 Questões para discussão . . . . . 20

**17 Produto esperado** **21**

**18 Estrutura recomendada do relatório estatístico** **21**

**19 Grelha de avaliação** **22**

**20 Conclusões do módulo** **22**

**21 Referências bibliográficas** **22**

# 1. Enquadramento do módulo

A meta-análise é um conjunto de métodos estatísticos utilizados para combinar quantitativamente os resultados de estudos que investigam uma questão de investigação comum. Quando os estudos são suficientemente comparáveis em termos de população, intervenção ou exposição, comparador, resultados e desenho, a síntese quantitativa permite estimar efeitos globais, quantificar a incerteza e investigar a variabilidade dos resultados entre estudos.

A realização de uma meta-análise não consiste apenas em calcular uma média dos resultados publicados. Exige a definição de uma medida de efeito apropriada, a estimação da sua variância, a escolha de um modelo estatístico, a avaliação da heterogeneidade e a interpretação crítica dos resultados.

Este módulo desenvolve os fundamentos matemáticos e computacionais necessários para efectuar meta-análises reprodutíveis, com particular atenção à utilização do software R.

**Ideia central**

A meta-análise combina estimativas de efeitos e a respectiva incerteza. O resultado deve ser interpretado à luz da qualidade dos estudos, da compatibilidade das medidas, da heterogeneidade e das limitações do conjunto de evidências.

# 2. Objectivos de aprendizagem

No final do módulo, o formando deverá ser capaz de:

1. Identificar a medida de efeito apropriada para resultados contínuos, binários e outros tipos de dados.
2. Calcular diferenças médias, diferenças médias padronizadas, razões de possibilidades, riscos relativos e diferenças de riscos.
3. Estimar variâncias, erros-padrão e intervalos de confiança.
4. Distinguir modelos de efeito fixo e modelos de efeitos aleatórios.
5. Quantificar e interpretar a heterogeneidade entre estudos.
6. Explicar a estimação da variância entre estudos.
7. Calcular e interpretar intervalos de predição.
8. Compreender os fundamentos da meta-regressão.
9. Implementar uma meta-análise utilizando R e pacotes especializados.
10. Produzir um relatório estatístico transparente e reproduzível.

# 3. Conceitos estatísticos fundamentais

## 3.1. Estimativa do efeito e incerteza

Considere-se um conjunto de $k$ estudos. Cada estudo fornece uma estimativa do efeito, representada por $y_i$, e uma variância amostral estimada, representada por $v_i$.

O erro-padrão da estimativa é:

$$SE(y_i) = \sqrt{v_i}.$$

Sob uma aproximação normal, o intervalo de confiança de 95% para uma estimativa contínua na escala original é:

$$IC_{95\%}(y_i) = y_i \pm 1.96\sqrt{v_i}.$$

O valor 1,96 corresponde aproximadamente ao quantil de 97,5% da distribuição normal padrão. Para amostras pequenas ou situações específicas, podem ser apropriados quantis de outras distribuições ou métodos de intervalo alternativos.

### 3.2. Precisão e ponderação

Um estudo com menor variância fornece, em geral, uma estimativa mais precisa. Nos modelos clássicos de meta-análise, a precisão é incorporada através de pesos estatísticos.

No modelo de efeito fixo, o peso inverso da variância é:

$$w_i = \frac{1}{v_i}.$$

No modelo de efeitos aleatórios, o peso é:

$$w_i^* = \frac{1}{v_i + \tau^2},$$

em que $\tau^2$ representa a variância entre os efeitos verdadeiros dos estudos.

**Distinção importante**

A variância $v_i$ representa a incerteza amostral da estimativa do estudo $i$. A variância $\tau^2$ representa a dispersão dos efeitos verdadeiros entre os estudos, no modelo de efeitos aleatórios. Não devem ser confundidas.

## 4. Medidas de efeito para resultados contínuos

Os resultados contínuos são variáveis numéricas, como pressão arterial, concentração de uma substância, temperatura, rendimento, velocidade do vento ou irradiância solar.

### 4.1. Diferença média

A diferença média (DM) é utilizada quando os estudos medem o mesmo resultado na mesma escala e com unidades comparáveis.

Para dois grupos independentes, intervenção e controlo:

$$DM = \bar{X}_I - \bar{X}_C,$$

em que:

- $\bar{X}_I$ é a média do grupo de intervenção;
- $\bar{X}_C$ é a média do grupo de controlo.

A variância estimada da diferença média é:

$$\mathrm{Var}(DM) = \frac{s_I^2}{n_I} + \frac{s_C^2}{n_C},$$

e o erro-padrão é:

$$SE(DM) = \sqrt{\frac{s_I^2}{n_I} + \frac{s_C^2}{n_C}}.$$

Aqui, $s_I$ e $s_C$ são os desvios-padrão amostrais e $n_I$ e $n_C$ são as dimensões dos grupos.

**Diferença média**

Um estudo compara a concentração média de um indicador entre dois grupos:

$$\bar{X}_I = 24, \quad \bar{X}_C = 20.$$

A diferença média é:

$$DM = 24 - 20 = 4.$$

A interpretação é que o grupo de intervenção apresenta uma média 4 unidades superior à do grupo de controlo. A conclusão sobre a incerteza exige também os desvios-padrão e as dimensões amostrais.

## 4.2. Diferença média padronizada

A diferença média padronizada (DMP) é útil quando os estudos medem o mesmo conceito através de escalas diferentes. Uma versão habitual é a estatística $d$ de Cohen:

$$d = \frac{\bar{X}_I - \bar{X}_C}{s_p},$$

em que o desvio-padrão combinado é:

$$s_p = \sqrt{\frac{(n_I - 1)s_I^2 + (n_C - 1)s_C^2}{n_I + n_C - 2}}.$$

Para reduzir o enviesamento em amostras pequenas, pode utilizar-se a correcção de Hedges:

$$g = Jd,$$

com a aproximação:

$$J \approx 1 - \frac{3}{4(n_I + n_C) - 9}.$$

A DMP é expressa em unidades de desvio-padrão, não nas unidades originais da variável.

**Limitação da padronização**

A DMP não deve ser utilizada automaticamente apenas porque os estudos usam escalas distintas. É necessário verificar se as escalas medem o mesmo constructo e se os desvios-padrão são comparáveis. Diferenças na variabilidade das populações podem alterar a interpretação da DMP.

# 5. Medidas de efeito para resultados binários

Os resultados binários apresentam duas categorias, por exemplo: evento/não evento, sucesso/insucesso ou presença/ausência.

Considere-se a tabela:

Tabela 1: Tabela de contingência para um resultado binário

| | Evento | Sem evento |
|---|---|---|
| Intervenção | $a$ | $b$ |
| Controlo | $c$ | $d$ |

As dimensões dos grupos são $n_I = a + b$ e $n_C = c + d$.

## 5.1. Risco relativo

O risco relativo (RR) compara a probabilidade do evento nos dois grupos:

$$RR = \frac{a/(a+b)}{c/(c+d)}.$$

Interpretação:

- $RR = 1$: os riscos são iguais;
- $RR > 1$: o risco é superior no grupo de intervenção;
- $RR < 1$: o risco é inferior no grupo de intervenção.

Para estudos sem células nulas, a variância aproximada do logaritmo do risco relativo é:

$$\text{Var}(\log RR) = \frac{1}{a} - \frac{1}{a+b} + \frac{1}{c} - \frac{1}{c+d}.$$

O erro-padrão é a raiz quadrada desta variância. O intervalo de confiança é calculado na escala logarítmica e depois transformado:

$$IC_{95\%}(RR) = \exp\left[\log(RR) \pm 1.96 SE(\log RR)\right].$$

## 5.2. Razão de possibilidades

A razão de possibilidades (odds ratio, OR) é:

$$OR = \frac{a/b}{c/d} = \frac{ad}{bc}.$$

A variância aproximada do logaritmo da OR, quando as células são positivas, é:

$$\text{Var}(\log OR) = \frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}.$$

O intervalo de confiança é:

$$IC_{95\%}(OR) = \exp\left[\log(OR) \pm 1.96 SE(\log OR)\right].$$

A OR e o RR não são, em geral, numericamente iguais. Quando o evento é frequente, a OR pode afastar-se substancialmente do RR.

## 5.3. Diferença de riscos

A diferença de riscos (DR) é:

$$DR = \frac{a}{a+b} - \frac{c}{c+d}.$$

Uma diferença de riscos igual a $-0.08$, por exemplo, corresponde a uma redução absoluta de 8 pontos percentuais no grupo de intervenção em relação ao grupo de controlo.

Uma aproximação para a variância é:

$$\mathrm{Var}(DR) = \frac{p_I(1-p_I)}{n_I} + \frac{p_C(1-p_C)}{n_C},$$

em que $p_I = a/n_I$ e $p_C = c/n_C$.

O intervalo normal aproximado é:

$$DR \pm 1.96\sqrt{\mathrm{Var}(DR)}.$$

Quando as proporções estão próximas de zero ou um, ou as amostras são pequenas, este intervalo pode ter propriedades inadequadas. Devem considerar-se métodos alternativos apropriados à situação.

## 5.4. Exemplo numérico

Considere-se um estudo com os seguintes resultados:

Tabela 2: Dados ilustrativos de um estudo binário

| Grupo | Eventos | Sem evento | Total |
|---|---|---|---|
| Intervenção | 20 | 80 | 100 |
| Controlo | 30 | 70 | 100 |

Obtêm-se:

$$p_I = 0.20, \qquad p_C = 0.30.$$

$$RR = \frac{0.20}{0.30} \approx 0.667.$$

$$OR = \frac{20 \times 70}{80 \times 30} \approx 0.583.$$

$$DR = 0.20 - 0.30 = -0.10.$$

Neste exemplo, o risco observado no grupo de intervenção é cerca de 33,3% inferior ao do grupo de controlo em termos relativos, enquanto a diferença absoluta observada é de menos 10 pontos percentuais. Estes cálculos, isoladamente, não estabelecem causalidade nem substituem a avaliação da incerteza e do desenho do estudo.

# 6. Outros tipos de dados e medidas de efeito

A escolha da medida de efeito deve respeitar a natureza do resultado e a estrutura dos dados.

Tabela 3: Exemplos de medidas de efeito por tipo de resultado

| **Tipo de resultado** | **Medidas possíveis** | **Observações** |
|---|---|---|
| Contínuo | DM, DMP, diferença de médias ajustadas | Verificar as unidades, escalas, desvios-padrão e desenho. |
| Binário | RR, OR, DR | Definir claramente o evento e a direcção da comparação. |
| Contagens | Razão de taxas, diferença de taxas | Considerar o tempo de exposição e o modelo de contagem. |
| Tempo até ao evento | Hazard ratio (HR) | Verificar a definição do evento e os pressupostos de análise de sobrevivência. |
| Correlação | Coeficiente $r$, transformação $z$ de Fisher | A transformação pode facilitar a síntese e a aproximação normal. |
| Diagnóstico | Sensibilidade, especificidade e modelos conjuntos | A síntese deve considerar a dependência entre sensibilidade e especificidade. |

Não se devem combinar directamente medidas em escalas incompatíveis. A transformação estatística, quando necessária, deve ter uma justificação metodológica explícita.

# 7. Modelos estatísticos de meta-análise

## 7.1. Modelo de efeito fixo

No modelo de efeito fixo, considera-se que todos os estudos estimam um único efeito subjacente comum, sendo as diferenças observadas atribuídas à variabilidade amostral.

O estimador combinado é:

$$\hat{\mu}_F = \frac{\sum_{i=1}^{k} w_i y_i}{\sum_{i=1}^{k} w_i}, \qquad w_i = \frac{1}{v_i}.$$

A variância estimada é:

$$\mathrm{Var}(\hat{\mu}_F) = \frac{1}{\sum_{i=1}^{k} w_i},$$

e o erro-padrão:

$$SE(\hat{\mu}_F) = \sqrt{\frac{1}{\sum_{i=1}^{k} w_i}}.$$

O intervalo de confiança aproximado é:

$$IC_{95\%}(\hat{\mu}_F) = \hat{\mu}_F \pm 1.96 SE(\hat{\mu}_F).$$

Este modelo pode ser adequado quando a hipótese de um efeito comum é defensável e a população de estudos permite essa interpretação. A ausência de heterogeneidade estatisticamente significativa não demonstra, por si só, que o efeito seja idêntico em todos os estudos.

## 7.2. Modelo de efeitos aleatórios

O modelo de efeitos aleatórios admite que os efeitos verdadeiros variam entre os estudos. Uma formulação habitual é:

$$y_i = \theta_i + \varepsilon_i,$$

$$\theta_i = \mu + u_i,$$

em que:

- $y_i$ é a estimativa observada no estudo $i$;
- $\theta_i$ é o efeito verdadeiro específico do estudo;
- $\varepsilon_i$ representa o erro amostral;
- $u_i$ representa o desvio do efeito verdadeiro em relação à média dos efeitos;
- $\mu$ é a média dos efeitos verdadeiros na população de estudos.

Uma hipótese clássica é:

$$u_i \sim N(0, \tau^2), \qquad \varepsilon_i \sim N(0, v_i).$$

Assim:

$$\mathrm{Var}(y_i) = v_i + \tau^2.$$

O estimador combinado é:

$$\hat{\mu}_R = \frac{\sum_{i=1}^{k} w_i^* y_i}{\sum_{i=1}^{k} w_i^*}, \qquad w_i^* = \frac{1}{v_i + \tau^2}.$$

A variância condicional estimada da média combinada, na formulação clássica, é:

$$\widehat{\mathrm{Var}}(\hat{\mu}_R) = \frac{1}{\sum_{i=1}^{k} w_i^*}.$$

A incerteza na estimação de $\tau^2$ e o número de estudos podem exigir métodos de inferência mais robustos, como o ajuste de Hartung–Knapp, conforme a situação.

## 7.3. Comparação dos modelos

Tabela 4: Diferenças entre os modelos de meta-análise

| Aspecto | Efeito fixo | Efeitos aleatórios |
|---|---|---|
| Hipótese central | Efeito comum | Distribuição de efeitos verdadeiros |
| Variância utilizada | $v_i$ | $v_i + \tau^2$ |
| Peso | $1/v_i$ | $1/(v_i + \tau^2)$ |
| Interpretação | Estimativa do efeito comum assumido | Média dos efeitos na população de estudos definida pelo modelo |
| Heterogeneidade | Não modelada como dispersão de efeitos verdadeiros | Modelada através de $\tau^2$ |
| Limitação principal | Pode ser inadequado se houver variação real entre efeitos | Exige estimar a variância entre estudos e definir a população de interesse |

**Não escolher apenas pelo teste de heterogeneidade**

A escolha entre modelos deve ser fundamentada na pergunta de investigação, no desenho dos estudos e na plausibilidade de um efeito comum. Não se deve escolher automaticamente o modelo de efeito fixo quando um teste de heterogeneidade apresenta $p > 0.05$.

# 8. Heterogeneidade entre estudos

A heterogeneidade corresponde à variabilidade dos resultados que não é explicada exclusivamente pelo erro amostral. Pode estar associada a diferenças de população, contexto, intervenção, exposição, medição, desenho ou qualidade metodológica.

## 8.1. Estatística $Q$ de Cochran

A estatística $Q$ é definida por:

$$Q = \sum_{i=1}^{k} w_i (y_i - \hat{\mu}_F)^2.$$

Sob determinadas hipóteses, $Q$ é comparada com uma distribuição qui-quadrado com $k - 1$ graus de liberdade. O teste pode ter baixa potência quando existem poucos estudos e detectar diferenças pequenas quando há muitos estudos.

## 8.2. Estatística $I^2$

Uma medida frequentemente utilizada é:

$$I^2 = \max\left\{0, \frac{Q - (k-1)}{Q}\right\} \times 100\%.$$

O valor de $I^2$ descreve a proporção da variabilidade observada atribuível à heterogeneidade, segundo esta formulação, e não a magnitude absoluta da diferença entre efeitos.

Como referências heurísticas, encontram-se frequentemente valores próximos de 25%, 50% e 75% para heterogeneidade baixa, moderada e elevada, respectivamente. Estas categorias não são regras universais: a interpretação depende do contexto, da precisão e das medidas de efeito utilizadas.

## 8.3. Variância entre estudos $\tau^2$

A variância entre estudos, $\tau^2$, quantifica a dispersão dos efeitos verdadeiros na escala de efeito utilizada.

Uma estimativa clássica é o método de momentos de DerSimonian–Laird:

$$\hat{\tau}^2_{\mathrm{DL}} = \max\left\{0, \frac{Q-(k-1)}{C}\right\},$$

com:

$$C = \sum_{i=1}^{k} w_i - \frac{\sum_{i=1}^{k} w_i^2}{\sum_{i=1}^{k} w_i}.$$

Existem outros estimadores, incluindo máxima verosimilhança (ML), máxima verosimilhança restrita (REML) e Paule–Mandel. Os métodos podem produzir resultados diferentes, sobretudo quando há poucos estudos ou heterogeneidade limitada. A escolha deve ser justificada e, quando relevante, acompanhada por análises de sensibilidade.

**Interpretação conjunta**

A estatística $I^2$ descreve a heterogeneidade relativa; $\tau^2$ representa a variância entre efeitos verdadeiros na escala escolhida; e o intervalo de predição procura descrever a distribuição plausível do efeito verdadeiro num novo contexto comparável.

# 9. Intervalos de predição

O intervalo de confiança da média combinada descreve a incerteza sobre a média dos efeitos. O intervalo de predição procura representar a incerteza sobre o efeito verdadeiro de um novo estudo pertencente à população de estudos definida pelo modelo.

Uma aproximação habitual é:

$$\hat{\mu}_R \pm t_{k-2,\,0.975}\sqrt{\hat{\tau}^2 + \widehat{\mathrm{Var}}(\hat{\mu}_R)},$$

em que $t_{k-2,\,0.975}$ é um quantil da distribuição $t$ de Student. A fórmula corresponde a uma aproximação utilizada em certas implementações e não é universal para todos os modelos e métodos de estimação.

**Cautela na interpretação**

O intervalo de predição depende do número de estudos, da estimação de $\tau^2$, da hipótese sobre a distribuição dos efeitos e do método de inferência. Com poucos estudos, pode ser muito impreciso. Não deve ser interpretado como um intervalo que contém 95% dos resultados observados de todos os estudos.

Um intervalo de confiança relativamente estreito para a média pode coexistir com um intervalo de predição amplo. Esta situação indica que a média global pode ser estimada com precisão, embora o efeito verdadeiro varie substancialmente entre contextos.

# 10. Introdução à meta-regressão

A meta-regressão é uma extensão da meta-análise que investiga se características dos estudos estão associadas à magnitude dos efeitos.

Considere-se uma variável moderadora $x_i$. Um modelo simples é:

$$y_i = \beta_0 + \beta_1 x_i + u_i + \varepsilon_i.$$

Neste modelo:

- $\beta_0$ é o intercepto;
- $\beta_1$ representa a associação entre o moderador e o efeito;
- $u_i$ representa a variação residual entre estudos;
- $\varepsilon_i$ representa o erro amostral.

Com vários moderadores:

$$y_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + u_i + \varepsilon_i.$$

Por exemplo, numa síntese de estudos de recurso eólico, os moderadores poderiam incluir altura de medição, período de observação ou região. Numa meta-análise de irradiância solar, poderiam incluir o tipo de instrumento, a estação do ano ou a categoria climática, desde que estejam disponíveis de forma comparável nos estudos.

## 10.1. Interpretação dos coeficientes

O coeficiente $\beta_1$ estima a mudança média na medida de efeito associada a uma unidade adicional de $x_i$, mantendo os restantes moderadores constantes no modelo especificado.

Se a medida de efeito for o logaritmo do risco relativo, por exemplo, o coeficiente está na escala logarítmica. A exponenciação do coeficiente permite obter uma razão multiplicativa na escala do RR.

## 10.2. Limitações da meta-regressão

- O número de estudos limita o número de moderadores que pode ser estimado com estabilidade.
- As associações entre características dos estudos não demonstram relações causais.
- A análise de características médias dos estudos pode sofrer de falácia ecológica.
- A colinearidade entre moderadores pode dificultar a interpretação.
- A selecção exploratória de muitos moderadores aumenta o risco de resultados espúrios.
- A ausência de dados dos moderadores pode introduzir enviesamento.

**Princípio metodológico**

Os moderadores principais devem, sempre que possível, ser definidos no protocolo. As análises exploratórias devem ser identificadas como tal e interpretadas com prudência.

# 11. Fluxo de decisão estatística

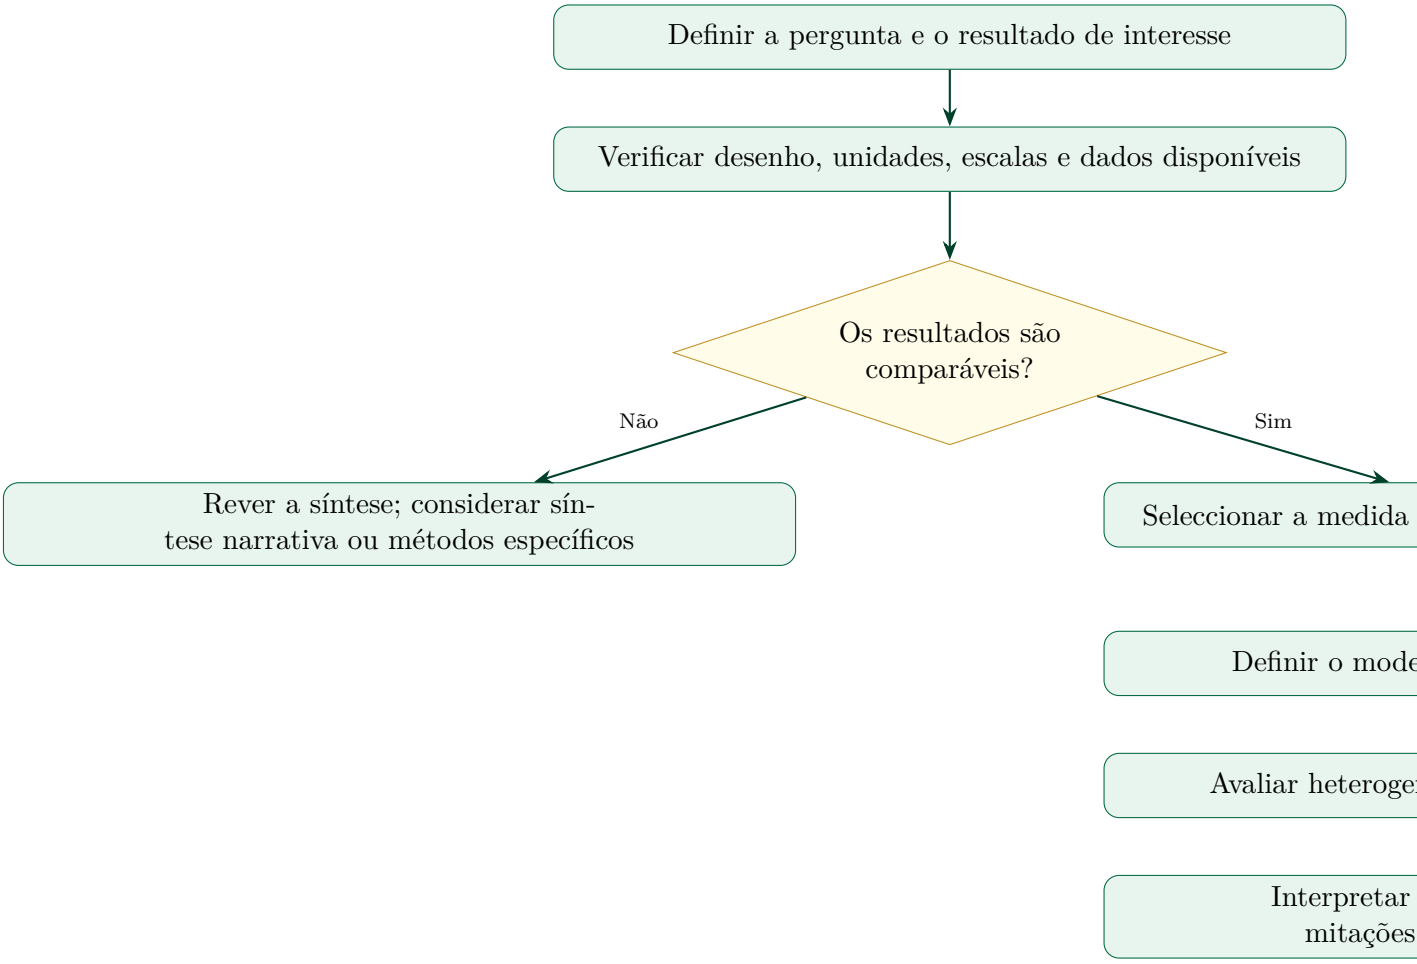



Figura 1: Fluxo geral para a decisão e execução de uma meta-análise.

# 12. Implementação prática com R

## 12.1. Objectivo da actividade

Nesta actividade, os formandos realizarão uma meta-análise de resultados contínuos a partir de dados ilustrativos de cinco estudos. O objectivo é calcular diferenças médias, ajustar modelos de efeito fixo e de efeitos aleatórios, avaliar a heterogeneidade, examinar o intervalo de predição e produzir um gráfico de floresta.

Os dados são exclusivamente didácticos e não representam resultados de uma investigação publicada.

## 12.2. Instalação dos pacotes

O pacote `metafor` disponibiliza funções para análise de efeitos, estimação de modelos, heterogeneidade, meta-regressão e gráficos. O pacote `meta` disponibiliza funções adicionais para sínteses estatísticas e visualização.

```r
install.packages(c("metafor", "meta"))
```

Listing 1: Instalação dos pacotes R

A instalação só é necessária uma vez em cada ambiente R. Em sessões posteriores, basta carregar os pacotes.

## 12.3. Conjunto de dados ilustrativo

Tabela 5: Dados fictícios para a meta-análise

| Estudo | $n_I$ | Média I | DP I | $n_C$ | Média C | DP C |
|---|---|---|---|---|---|---|
| Estudo A | 40 | 15.2 | 3.1 | 38 | 13.8 | 3.0 |
| Estudo B | 52 | 14.1 | 2.8 | 50 | 13.5 | 2.9 |
| Estudo C | 35 | 16.0 | 3.4 | 36 | 14.2 | 3.2 |
| Estudo D | 60 | 13.8 | 2.7 | 58 | 13.9 | 2.8 |
| Estudo E | 45 | 15.0 | 3.0 | 47 | 14.1 | 3.1 |

A variável de resultado está na mesma unidade nos cinco estudos. Por isso, a diferença média é uma medida de efeito plausível para esta demonstração.

## 12.4. Script R completo e reproduzível

O script seguinte inclui os dados, o cálculo dos efeitos, os dois modelos, a heterogeneidade, o intervalo de predição, o gráfico de floresta e a exportação dos resultados.

```r
# ============================================================
# MODULO 12: ESTATISTICA AVANCADA E META-ANALISE
# Dados exclusivamente didacticos
# ============================================================

# 1. Instalar uma unica vez, se necessario:
# install.packages("metafor")
# install.packages("meta")

library(metafor)

# 2. Criar os dados
dados <- data.frame(
  estudo = c("Estudo A", "Estudo B", "Estudo C",
             "Estudo D", "Estudo E"),
  nI = c(40, 52, 35, 60, 45),
  mediaI = c(15.2, 14.1, 16.0, 13.8, 15.0),
  dpI = c(3.1, 2.8, 3.4, 2.7, 3.0),
  nC = c(38, 50, 36, 58, 47),
```

```
  mediaC = c(13.8, 13.5, 14.2, 13.9, 14.1),
  dpC = c(3.0, 2.9, 3.2, 2.8, 3.1)
)

print(dados)

# 3. Calcular diferencas medias e variancias
efeitos <- escalc(
  measure = "MD",
  m1i = mediaI, sd1i = dpI, n1i = nI,
  m2i = mediaC, sd2i = dpC, n2i = nC,
  data = dados
)

print(efeitos[, c("estudo", "yi", "vi")])

# 4. Modelo de efeito fixo
modelo_fixo <- rma(
  yi = yi,
  vi = vi,
  data = efeitos,
  method = "FE"
)

summary(modelo_fixo)

# 5. Modelo de efeitos aleatorios por REML
modelo_aleatorio <- rma(
  yi = yi,
  vi = vi,
  data = efeitos,
  method = "REML",
  test = "knha"
)

summary(modelo_aleatorio)

# 6. Medidas de heterogeneidade
cat("Q =", modelo_aleatorio$QE, "\n")
cat("Graus de liberdade =", modelo_aleatorio$k - 1, "\n")
cat("p-valor do teste Q =", modelo_aleatorio$QEp, "\n")
cat("I2 (%) =", modelo_aleatorio$I2, "\n")
cat("Tau2 =", modelo_aleatorio$tau2, "\n")

# 7. Intervalo de predicao, quando suportado
# pela versao instalada do metafor
predicao <- predict(modelo_aleatorio)
print(predicao)

# 8. Grafico de floresta
png("forest_plot.png", width = 1600, height = 1100, res = 160)

```

```r
forest(
  modelo_aleatorio,
  slab = dados$estudo,
  xlab = "Diferenca media",
  mlab = "Modelo de efeitos aleatorios",
  refline = 0
)

dev.off()

# 9. Grafico de funil para exploracao
png("funnel_plot.png", width = 1200, height = 1000, res = 150)

funnel(
  modelo_aleatorio,
  xlab = "Diferenca media",
  yaxis = "sei"
)

dev.off()

# 10. Exportar os efeitos individuais
resultados_individuais <- data.frame(
  estudo = dados$estudo,
  efeito = efeitos$yi,
  variancia = efeitos$vi,
  erro_padrao = sqrt(efeitos$vi),
  limite_inferior = efeitos$yi - 1.96 * sqrt(efeitos$vi),
  limite_superior = efeitos$yi + 1.96 * sqrt(efeitos$vi)
)

write.csv(
  resultados_individuais,
  "resultados_individuais.csv",
  row.names = FALSE
)

# 11. Exportar o resumo dos modelos
capture.output(
  summary(modelo_fixo),
  file = "resumo_modelo_fixo.txt"
)

capture.output(
  summary(modelo_aleatorio),
  file = "resumo_modelo_aleatorio.txt"
)

cat("Analise concluida.\n")
```

Listing 2: Script completo para uma meta-análise de resultados contínuos

**Verificação da versão do software**

As funções e opções podem variar entre versões do pacote. Antes de entregar o relatório, deve confirmar-se que o script executa no ambiente utilizado e que os intervalos apresentados correspondem ao método efectivamente seleccionado. O argumento `test="knha"` aplica um ajuste de Hartung–Knapp na inferência do modelo; não deve ser confundido com um estimador de $\tau^2$.

## 12.5. Leitura dos resultados

A função `summary()` apresenta, entre outros elementos:

- a estimativa combinada do efeito;
- o erro-padrão e o intervalo de confiança;
- o teste da hipótese de efeito médio nulo;
- a estatística $Q$ e o respectivo teste;
- a estimativa de $\tau^2$;
- a estatística $I^2$;
- o número de estudos incluídos na síntese.

O valor de $p$ não deve ser interpretado isoladamente. A interpretação deve considerar a magnitude e a direcção do efeito, a precisão, a heterogeneidade, a relevância científica e a qualidade metodológica dos estudos.

## 12.6. Extensão para resultados binários

Para resultados binários, o pacote `metafor` permite calcular medidas como o logaritmo do risco relativo e o logaritmo da razão de possibilidades.

```
# Exemplo didactico: dois grupos independentes
dados_binarios <- data.frame(
  estudo = c("A", "B", "C"),
  eventosI = c(20, 15, 28),
  totalI = c(100, 80, 120),
  eventosC = c(30, 20, 35),
  totalC = c(100, 82, 118)
)

# Calculo do logaritmo do risco relativo
# com correcao automatica para casos adequados
efeitos_binarios <- escalc(
  measure = "RR",
  ai = eventosI,
  bi = totalI - eventosI,
  ci = eventosC,
  di = totalC - eventosC,
  data = dados_binarios,
```

```r
  add = 0.5,
  to = "only0"
)

modelo_RR <- rma(
  yi = yi,
  vi = vi,
  data = efeitos_binarios,
  method = "REML"
)

summary(modelo_RR)

# Transformar a estimativa combinada para a escala RR
exp(coef(modelo_RR))
exp(confint(modelo_RR)$random)
```

Listing 3: Exemplo de cálculo do risco relativo

A correcção de continuidade é uma decisão metodológica. A sua aplicação, especialmente em estudos com eventos raros ou braços sem eventos, pode afectar os resultados. O método deve ser escolhido de acordo com a estrutura dos dados e descrito no relatório.

## 13. Meta-regressão em R

Para ilustrar a meta-regressão, considere-se que cada estudo também registou uma variável moderadora, por exemplo, o ano médio de publicação. A associação não deve ser interpretada automaticamente como uma tendência causal.

```r
# Exemplo didactico: moderador definido por estudo
dados$ano <- c(2018, 2019, 2020, 2022, 2023)

# Juntar a variavel moderadora aos efeitos calculados
efeitos$ano <- dados$ano

modelo_meta_reg <- rma(
  yi = yi,
  vi = vi,
  mods = ~ ano,
  data = efeitos,
  method = "REML"
)

summary(modelo_meta_reg)

# Teste da associacao do moderador
coef(modelo_meta_reg)
confint(modelo_meta_reg)
```

Listing 4: Exemplo de meta-regressão

Como existem apenas cinco estudos no exemplo, a meta-regressão tem capacidade limitada para avaliar moderadores. Os dados foram criados para fins pedagógicos; não se deve

atribuir significado substantivo aos coeficientes obtidos com esta variável fictícia.

# 14. Gráfico de floresta e gráfico de funil

## 14.1. Gráfico de floresta

O gráfico de floresta apresenta as estimativas individuais, os seus intervalos de confiança e a estimativa combinada. Permite examinar visualmente a direcção dos efeitos, a precisão dos estudos e a dispersão das estimativas.

Na interpretação, deve observar-se:

- a posição de cada estimativa em relação à linha de efeito nulo;
- a largura dos intervalos de confiança;
- a consistência ou dispersão das estimativas;
- a posição e a precisão do efeito combinado;
- a compatibilidade entre a estimativa global e os resultados individuais.

## 14.2. Gráfico de funil

O gráfico de funil relaciona as estimativas dos efeitos com uma medida de precisão. A assimetria pode resultar de efeitos de estudos pequenos, heterogeneidade, enviesamento de publicação ou outros mecanismos.

**Limitação do gráfico de funil**

A assimetria não demonstra, por si só, enviesamento de publicação. Os testes de assimetria também podem ter baixo poder com poucos estudos. Por isso, os resultados devem ser interpretados em conjunto com o contexto da revisão e outras evidências.

# 15. Análises de sensibilidade e robustez

Uma análise de sensibilidade examina se as conclusões se mantêm quando determinadas decisões analíticas são alteradas de forma justificada.

Podem ser consideradas:

1. comparação entre modelos de efeito fixo e efeitos aleatórios;
2. comparação de estimadores de $\tau^2$;
3. exclusão de estudos com risco de viés elevado, quando prevista e metodologicamente justificada;
4. avaliação da influência de estudos individuais;
5. comparação de definições de resultados previamente justificadas;
6. avaliação de pressupostos e métodos alternativos para dados raros ou incompletos.

A análise de sensibilidade não deve ser utilizada para seleccionar apenas o resultado mais favorável. Todas as análises relevantes, incluindo as que alteram as conclusões, devem ser reportadas.

# 16. Actividade prática orientada

**Trabalho de laboratório**

**Título:** Meta-análise de dados contínuos utilizando R.
**Duração sugerida:** 120 a 180 minutos.
**Organização:** Trabalho individual ou em grupos de dois a três formandos.

## 16.1. Tarefas

1. Introduzir os cinco estudos do conjunto de dados ilustrativo.
2. Calcular as diferenças médias e respectivas variâncias.
3. Ajustar um modelo de efeito fixo.
4. Ajustar um modelo de efeitos aleatórios com REML.
5. Comparar as estimativas combinadas e os intervalos de confiança.
6. Interpretar $Q$, $I^2$ e $\tau^2$.
7. Obter o intervalo de predição e explicar a sua diferença em relação ao intervalo de confiança da média.
8. Produzir um gráfico de floresta.
9. Produzir um gráfico de funil e discutir as suas limitações.
10. Executar uma meta-regressão exploratória com um moderador.
11. Exportar os resultados e preparar um relatório estatístico.

## 16.2. Questões para discussão

1. Por que razão a diferença média é apropriada para os dados apresentados?
2. Em que condições seria preferível a diferença média padronizada?
3. O que representa a variância entre estudos?
4. Um valor de $I^2$ elevado implica necessariamente que a síntese seja inválida?
5. Por que razão o intervalo de predição pode ser mais amplo do que o intervalo de confiança do efeito médio?
6. Que limitações decorrem de uma meta-regressão com apenas cinco estudos?
7. Como se deve proceder quando os estudos utilizam definições diferentes do resultado?
8. Que elementos são indispensáveis para reproduzir a análise?

# 17. Produto esperado

Cada formando deverá entregar um conjunto de ficheiros organizados, com pelo menos os seguintes elementos:

Tabela 6: Elementos do produto final

| Produto | Conteúdo mínimo |
|---|---|
| Script R | Código completo, comentários, cálculo dos efeitos, modelos e exportação. |
| Dados de entrada | Ficheiro CSV ou conjunto de dados incorporado no script, com descrição das variáveis. |
| Relatório estatístico | Pergunta, métodos, medida de efeito, modelo, heterogeneidade, resultados e limitações. |
| Gráfico de floresta | Estimativas individuais, intervalos de confiança e resultado combinado. |
| Ficheiro de resultados | Estimativas, erros-padrão, intervalos de confiança e estatísticas de heterogeneidade. |
| Nota de reprodutibilidade | Versão do R, pacotes utilizados, decisões analíticas e instruções de execução. |

# 18. Estrutura recomendada do relatório estatístico

O relatório final deverá apresentar:

1. **Pergunta de investigação:** população, intervenção ou exposição, comparador e resultado.
2. **Dados:** número de estudos, características principais e critérios de inclusão.
3. **Medida de efeito:** justificação da escolha e definição da direcção do efeito.
4. **Métodos estatísticos:** modelo, estimador de heterogeneidade e método de construção dos intervalos.
5. **Resultados:** efeito combinado, intervalo de confiança, heterogeneidade e, quando apropriado, intervalo de predição.
6. **Visualizações:** gráfico de floresta e outras figuras relevantes.
7. **Análises adicionais:** sensibilidade e meta-regressão, quando justificadas.
8. **Discussão:** relevância científica, limitações, risco de viés e generalização.
9. **Reprodutibilidade:** código, dados autorizados, dependências e decisões analíticas.

# 19. Grelha de avaliação

Tabela 7: Rubrica de avaliação do Módulo 12

| Critério | Peso | Pontuação |
|---|---|---|
| Escolha e justificação da medida de efeito | 15% | /15 |
| Cálculo e interpretação da incerteza | 15% | /15 |
| Implementação dos modelos estatísticos | 20% | /20 |
| Avaliação e interpretação da heterogeneidade | 15% | /15 |
| Gráficos e apresentação dos resultados | 10% | /10 |
| Interpretação crítica e limitações | 15% | /15 |
| Reprodutibilidade e organização do código | 10% | /10 |
| **Total** | **100%** | **/100** |

# 20. Conclusões do módulo

1. A medida de efeito deve ser seleccionada em função do tipo de resultado, das unidades e da pergunta de investigação.
2. A variância e o erro-padrão são essenciais para quantificar a incerteza das estimativas.
3. Os modelos de efeito fixo e de efeitos aleatórios assentam em pressupostos diferentes e respondem a interpretações distintas.
4. A heterogeneidade deve ser examinada através de medidas complementares, incluindo $Q$, $I^2$ e $\tau^2$.
5. Os intervalos de predição ajudam a compreender a possível variação dos efeitos verdadeiros entre contextos.
6. A meta-regressão pode investigar moderadores, mas exige número suficiente de estudos, planeamento e interpretação prudente.
7. O script reproduzível e o relatório estatístico são partes essenciais de uma síntese quantitativa transparente.

**Mensagem final**

Uma meta-análise rigorosa não se limita a produzir uma estimativa combinada. Deve explicar como essa estimativa foi obtida, qual é a sua incerteza, que diferenças existem entre os estudos e até que ponto as conclusões são sustentadas pela evidência disponível.

# 21. Referências bibliográficas

[1] Borenstein, M., Hedges, L. V., Higgins, J. P. T., & Rothstein, H. R. (2009). *Introduction to Meta-Analysis*. Wiley.

[2] Higgins, J. P. T., Thomas, J., Chandler, J., Cumpston, M., Li, T., Page, M. J., & Welch, V. A. (Eds.). (2024). *Cochrane Handbook for Systematic Reviews of Interventions*. Cochrane. https://training.cochrane.org/handbook

[3] DerSimonian, R., & Laird, N. (1986). Meta-analysis in clinical trials. *Controlled Clinical Trials*, 7(3), 177–188. https://doi.org/10.1016/0197-2456(86)90046-2

[4] Viechtbauer, W. (2010). Conducting meta-analyses in R with the metafor package. *Journal of Statistical Software*, 36(3), 1–48. https://doi.org/10.18637/jss.v036.i03

[5] Higgins, J. P. T., Thompson, S. G., Deeks, J. J., & Altman, D. G. (2003). Measuring inconsistency in meta-analyses. *BMJ*, 327, 557–560. https://doi.org/10.1136/bmj.327.7414.557

[6] Knapp, G., & Hartung, J. (2003). Improved tests for a random effects meta-regression with a single covariate. *Statistics in Medicine*, 22(17), 2693–2710. https://doi.org/10.1002/sim.1482

[7] Harrer, M., Cuijpers, P., Furukawa, T. A., & Ebert, D. D. (2021). *Doing Meta-Analysis with R: A Hands-On Guide*. Chapman and Hall/CRC. https://doi.org/10.1201/9781003107347

[8] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. https://www.r-project.org/

[9] Viechtbauer, W. *metafor: Meta-Analysis Package for R*. Documentação do pacote. https://www.metafor-project.org/