UNIVERSIDADE EDUARDO MONDLANE

CENTRO DE DESENVOLVIMENTO ACADÉMICO

FORMAÇÃO AVANÇADA EM
REVISÃO SISTEMÁTICA E META-ANÁLISES

MÓDULO 15

INTELIGÊNCIA ARTIFICIAL E AUTOMAÇÃO DE REVISÕES SISTEMÁTICAS

Utilização crítica, transparente e responsável de ferramentas de inteligência artificial no processo de identificação, selecção, extracção e síntese da evidência científica.

Formador: Fernando Mucomole

Maputo, Moçambique — 2026

Percurso do módulo I

1. Enquadramento e objectivos
2. Conceitos fundamentais
3. Aplicações nas revisões sistemáticas
4. Fluxo de trabalho assistido por IA
5. Classificação e métricas
6. Exemplo numérico
7. Extracção de dados
8. Limitações, erros e enviesamentos
9. Privacidade e integridade científica
10. Formulação de instruções e verificação
11. Comparação entre procedimentos
12. Actividade computacional com R
13. Plano de utilização responsável
14. Declaração de utilização de IA
15. Actividade prática
16. Critérios de avaliação
17. Conclusões

Percurso do módulo II

18 Referências bibliográficas

1. Enquadramento do módulo

- Uma revisão sistemática envolve pesquisa, deduplicação, triagem, avaliação dos textos integrais, extracção, risco de viés e síntese.
- O volume de trabalho pode ser elevado quando se recuperam milhares de referências em várias bases de dados.
- Ferramentas digitais e sistemas de IA podem apoiar a priorização, classificação, identificação de informação e extracção preliminar.
- A automatização também introduz riscos: exclusões incorrectas, informação inventada, erros de extracção, enviesamentos e exposição indevida de dados.

Princípio orientador

Aproveitar os benefícios da IA sem transferir para sistemas automatizados a responsabilidade científica da equipa de revisão.

Objectivos de aprendizagem

No final do módulo, o estudante deverá ser capaz de:

1. identificar aplicações da IA nas diferentes etapas da revisão sistemática;
2. distinguir automatização, aprendizagem automática e modelos generativos;
3. utilizar critérios explícitos para classificar e priorizar referências;
4. verificar a exactidão dos dados extraídos automaticamente;
5. reconhecer erros, alucinações e enviesamentos;
6. avaliar riscos de privacidade e confidencialidade;
7. documentar ferramentas, versões, configurações e decisões assistidas por IA;
8. elaborar um plano de utilização responsável e reprodutível.

2. Inteligência artificial

Definição operacional

Conjunto de técnicas computacionais destinadas a executar tarefas que envolvem reconhecimento de padrões, classificação, previsão, processamento de linguagem e geração de conteúdo.

Na revisão sistemática, pode apoiar:

- análise de textos científicos;
- identificação de conceitos e relações;
- sugestão de classificações;
- organização de grandes volumes de referências.

Aprendizagem automática

Machine learning utiliza algoritmos que aprendem padrões a partir de dados.

- Um modelo pode ser treinado com referências previamente classificadas como relevantes ou irrelevantes.
- Aprende padrões para ordenar novas referências segundo uma relevância estimada.
- O desempenho depende da qualidade e representatividade dos dados de treino, dos rótulos e da semelhança entre os estudos de treino e os estudos a analisar.

Atenção

Um modelo treinado num domínio ou idioma pode não apresentar o mesmo desempenho noutro contexto científico.

Processamento de linguagem natural

O processamento de linguagem natural permite analisar texto, identificar entidades, reconhecer relações semânticas, classificar documentos e localizar informação em artigos.

- Identificação de população, intervenção e resultados;
- reconhecimento de nomes de instrumentos e escalas;
- classificação temática;
- extracção preliminar de valores numéricos;
- síntese de secções para posterior verificação.

Modelos generativos

Modelos generativos produzem texto, código, resumos, classificações ou outras saídas com base no contexto recebido.

- Podem apoiar estratégias de pesquisa e formulários de extracção.
- Podem ajudar a organizar informação científica e produzir código.
- Podem gerar respostas plausíveis mas incorrectas: referências inexistentes, citações imprecisas, números ausentes do artigo ou interpretações sem suporte.

Conceito fundamental

A IA é um instrumento de apoio; não substitui a estratégia metodológica, a leitura crítica, a verificação documental nem a responsabilidade dos investigadores.

3. Aplicações ao longo do processo

Etapa	Aplicação possível	Verificação necessária
Planeamento	Estruturar pergunta e protocolo.	Confirmar adequação e operacionalização dos critérios.
Pesquisa	Sugerir palavras-chave, sinónimos e termos.	Validar sintaxe nas bases e documentar a pesquisa executada.
Deduplicação	Detectar registos possivelmente duplicados.	Confirmar falsos positivos e duplicados não detectados.
Triagem	Classificar ou priorizar títulos e resumos.	Avaliar falsos negativos e aplicar elegibilidade.
Texto integral	Localizar critérios, métodos e resultados.	Conferir artigo e justificar exclusões.
Extracção	Identificar amostras, medidas e efeitos.	Conferir números, unidades, tabelas e páginas.
Risco de viés	Organizar evidência por domínio.	Fundamentar a decisão metodológica na equipa.
Síntese	Apoiar organização e código.	Reproduzir cálculos e validar interpretação.
Redacção	Rever linguagem e estruturar texto.	Confirmar fidelidade, autoria, citações e integridade.

Apoio à estratégia de pesquisa

A IA pode sugerir sinónimos, variantes ortográficas, termos técnicos e conceitos relacionados com a pergunta.

Exemplo

Numa revisão sobre intervenções educativas apoiadas por tecnologia, pode sugerir aprendizagem digital, ensino electrónico, plataformas educativas e desempenho académico.

A estratégia final deve ser traduzida para a sintaxe de cada base de dados e verificar:

- descritores controlados disponíveis;
- operadores booleanos e campos de pesquisa;
- truncaturas e expressões exactas;
- cobertura temporal e linguística;
- data em que a pesquisa foi executada.

Limite

A IA não é uma base de dados bibliográfica nem garante que a pesquisa é exaustiva.

Deduplicação

Registos duplicados surgem quando o mesmo artigo é recuperado em várias bases ou exportado em formatos diferentes.

- A deduplicação pode comparar DOI, título, autores, ano e outros campos.
- Metadados incompletos tornam a identificação incerta.

Registos a conservar

1. número inicial de registos;
2. número de duplicados removidos;
3. método ou ferramenta utilizada;
4. casos duvidosos verificados manualmente.

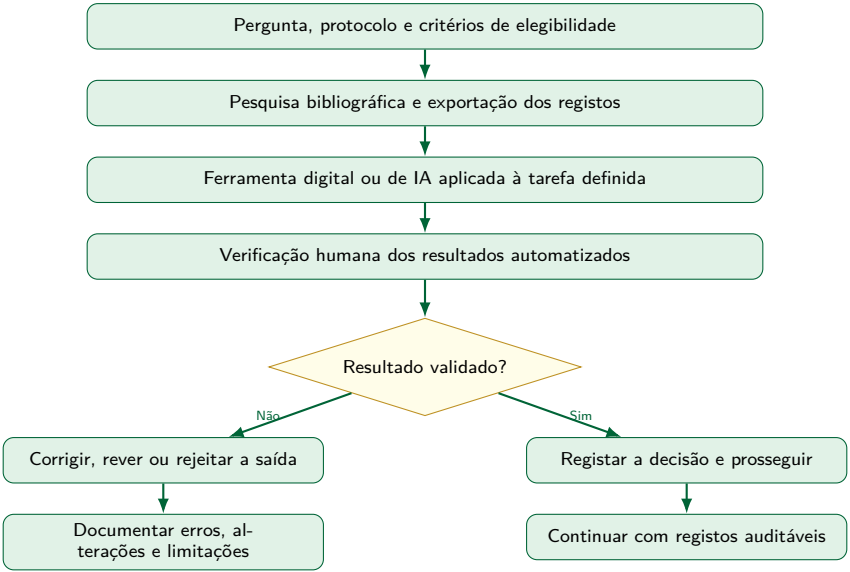
Classificação e priorização de referências

- Sistemas de aprendizagem automática podem ordenar referências segundo a probabilidade estimada de relevância.
- A priorização pode ajudar a encontrar referências potencialmente elegíveis mais cedo.
- Ordenar não equivale a excluir.
- Interromper a triagem depois das referências mais relevantes pode ocultar estudos elegíveis classificados incorrectamente.

Nota metodológica e ética

Não excluir automaticamente referências sem validação metodológica apropriada. O risco de falsos negativos deve ser avaliado e documentado.

4. Fluxo de trabalho recomendado



Princípios para integrar IA

- Nem todas as tarefas precisam de ser automatizadas.
- A escolha deve considerar o benefício esperado.
- A sensibilidade dos dados e o risco de erro devem ser avaliados.
- A equipa deve ter capacidade real para validar a saída.
- A ferramenta, a decisão e a correcção devem deixar registos auditáveis.

5. Matriz de confusão

A avaliação de um classificador compara as previsões com uma classificação de referência estabelecida através de procedimento humano apropriado.

	Elegível	**Não elegível**
Classificado como elegível	Verdadeiro positivo (VP)	Falso positivo (FP)
Classificado como não elegível	Falso negativo (FN)	Verdadeiro negativo (VN)

- VP: elegível identificado correctamente.
- FP: não elegível classificado como elegível.
- FN: elegível classificado como não elegível.
- VN: não elegível identificado correctamente.

Sensibilidade

A sensibilidade mede a proporção dos estudos elegíveis que o sistema identifica correctamente:

$$\text{Sensibilidade} = \frac{VP}{VP + FN}.$$

Interpretação

Uma sensibilidade elevada é particularmente importante quando se pretende evitar a exclusão de estudos relevantes.

O denominador inclui todos os estudos elegíveis segundo a classificação de referência: os identificados e os que foram perdidos.

Precisão positiva e especificidade

Precisão positiva (precision):

$$\text{Precisão} = \frac{VP}{VP + FP}.$$

Proporção dos estudos classificados como elegíveis que são efectivamente elegíveis. Uma precisão elevada reduz avaliações posteriores desnecessárias. **Especificidade:**

$$\text{Especificidade} = \frac{VN}{VN + FP}.$$

Proporção dos estudos não elegíveis correctamente identificados.

F1-score e avaliação crítica

O F1-score é a média harmónica entre precisão positiva e sensibilidade:

$$F_1 = 2\frac{\text{Precisão} \times \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}.$$

- Resume o compromisso entre precisão e sensibilidade.
- Não substitui a avaliação do risco de falsos negativos.
- Em revisões sistemáticas, excluir um estudo elegível pode ser mais grave do que avaliar uma referência irrelevante.

Qualidade da validação

As métricas exigem rótulos de referência fiáveis e representativos. Uma amostra mal classificada pode produzir uma avaliação enganadora.

6. Exemplo numérico de classificação

Considere-se um conjunto de 500 referências, das quais 100 são elegíveis. O sistema:

- identifica correctamente 90 referências elegíveis;
- classifica incorrectamente 60 referências irrelevantes como elegíveis;
- não identifica 10 referências elegíveis.

Assim:

$$VP = 90, \quad FP = 60, \quad FN = 10, \quad VN = 340.$$

Cálculo das métricas do exemplo

$$\text{Sensibilidade} = \frac{90}{90+10} = 0{,}90 = 90\%.$$

$$\text{Precisão} = \frac{90}{90+60} = 0{,}60 = 60\%.$$

$$\text{Especificidade} = \frac{340}{340+60} = 0{,}85 = 85\%.$$

$$F_1 = 2\frac{0{,}60 \times 0{,}90}{0{,}60+0{,}90} = 0{,}72.$$

Síntese interpretativa

O sistema identificou 90% dos estudos elegíveis, mas deixou escapar 10 estudos relevantes. A equipa deve analisar os falsos negativos e verificar a estabilidade do desempenho em diferentes subgrupos.

7. Apoio à extracção de dados

A IA pode localizar informação em textos integrais, mas a extracção deve seguir um formulário previamente definido e adaptado à pergunta.

Campos possíveis

- autor e ano;
- país e contexto;
- desenho do estudo;
- população e amostra;
- intervenção e comparador;
- definição dos resultados.

Campos quantitativos e adicionais

- medidas de efeito;
- intervalos de confiança;
- medidas de variância;
- limitações;
- financiamento.

Princípio da rastreabilidade

Cada valor extraído deve estar associado a uma fonte verificável, preferencialmente com página, tabela, figura ou secção.

1. Informação explicitamente comunicada no artigo;
2. informação calculada a partir de dados apresentados;
3. informação inferida a partir do contexto;
4. informação ausente ou impossível de verificar.

Regra de apresentação

A informação inferida não deve ser apresentada como se tivesse sido explicitamente comunicada pelos autores.

Verificação de dados numéricos

A extracção automatizada exige atenção a:

- separadores decimais e de milhares;
- unidades e conversões;
- tamanhos de amostra por grupo;
- sinais positivos e negativos;
- intervalos de confiança;
- erros-padrão e desvios-padrão;
- resultados ajustados e não ajustados;
- dados apresentados em gráficos ou anexos.

Erro frequente

Confundir desvio-padrão com erro-padrão ou extrair o tamanho total da amostra quando a análise utiliza apenas participantes com dados completos.

Protocolo de verificação da extracção

1. Definir previamente o formulário de extracção.
2. Solicitar a extracção de campos específicos.
3. Exigir a localização da fonte de cada valor.
4. Comparar a saída com texto, tabelas e figuras.
5. Verificar os cálculos derivados.
6. Resolver discrepâncias entre revisores.
7. Guardar a versão final validada.

8. Alucinações

Uma alucinação ocorre quando um sistema gera informação aparentemente plausível, mas não sustentada pelas fontes disponíveis.

- referências inexistentes;
- números incorrectos;
- citações inventadas;
- descrições falsas dos métodos;
- conclusões que não decorrem dos resultados.

Resposta metodológica

Verificar cada afirmação com a fonte original. Se não for possível confirmar, rejeitar ou assinalar explicitamente a incerteza.

Erros de classificação

Um sistema pode classificar incorrectamente um estudo porque:

- o resumo é incompleto;
- a população elegível só aparece no texto integral;
- os critérios de inclusão são complexos;
- existem sinónimos ou abreviaturas;
- a pergunta não está representada nos exemplos de treino.

A revisão humana deve considerar que a informação decisiva pode não estar no título ou resumo.

Enviesamento dos dados de treino

Os sistemas podem reproduzir limitações dos dados usados no seu desenvolvimento.

- Sub-representação de línguas, regiões ou revistas;
- preferência por determinados desenhos de estudo;
- terminologia pouco representada nos dados de treino;
- desempenho inferior em contextos científicos distintos.

Contextos africanos e multilingues

Revisões com estudos em português, línguas locais ou contextos africanos devem verificar se a ferramenta interpreta adequadamente a terminologia e as características dos documentos.

Objectividade aparente, deriva e reprodutibilidade

Falsa sensação de objectividade

- A automatização não elimina o julgamento subjectivo.
- Dados, critérios, parâmetros e limiares podem influenciar os resultados.

Deriva e reprodutibilidade

- Ferramentas podem mudar de versão, modelo, interface ou política.
- A mesma instrução pode produzir saídas diferentes no futuro.
- Registar versão, data, parâmetros e resultados validados.

9. Privacidade e confidencialidade

Antes de carregar documentos numa ferramenta externa, verificar se contêm:

- dados pessoais ou identificadores;
- informação clínica individual;
- dados não publicados sujeitos a confidencialidade;
- manuscritos submetidos ou documentos sob embargo;
- informação protegida por contrato ou licença;
- dados de participantes que não podem ser partilhados.

Nota metodológica e ética

Não assumir confidencialidade apenas porque a ferramenta exige autenticação ou está disponível numa conta institucional. Verificar armazenamento, processamento, retenção e utilização dos dados.

Direitos de autor e licenças

- O acesso a um artigo não implica autorização para redistribuir o texto integral.
- O acesso também não implica autorização para carregar o documento numa plataforma externa.
- Verificar os termos da licença, condições institucionais e regras da ferramenta.
- Sempre que possível, utilizar apenas a informação necessária à tarefa.
- Evitar expor documentos ou dados que não precisem de ser processados.

Autoria e responsabilidade

A IA não substitui a responsabilidade dos autores pela exactidão, originalidade e integridade do trabalho científico.

- Verificar a política da revista sobre declaração de IA.
- Confirmar se a ferramenta pode ser mencionada nos métodos.
- Confirmar que as referências existem e sustentam as afirmações.
- Garantir que o texto representa correctamente os dados.
- Respeitar regras de autoria e contributo.

Citações e referências

Nunca aceitar automaticamente uma referência produzida por IA. Confirmar cada referência através de uma fonte bibliográfica verificável.

Elementos mínimos a confirmar

- título e autores;
- ano;
- revista ou editora;
- volume e páginas, quando aplicáveis;
- DOI ou identificador persistente.

10. Características de uma instrução adequada

Uma instrução para um sistema generativo deve definir:

1. papel operacional do sistema;
2. tarefa exacta;
3. critérios de elegibilidade ou campos pretendidos;
4. limites da fonte de informação;
5. formato de saída;
6. procedimento para informação ausente;
7. obrigação de assinalar incerteza.

Exemplo de instrução para extracção

Instrução proposta

Analise o texto científico fornecido e extraia apenas: autor, ano, desenho do estudo, população, tamanho da amostra, intervenção, comparador e resultado primário.
Para cada campo, indique a secção, página ou tabela onde a informação aparece. Se um valor não estiver explicitamente disponível, escreva "Não comunicado". Não invente valores, não complete dados por inferência e não crie referências. Separe os valores comunicados pelos autores dos valores calculados.
Devolva o resultado numa tabela estruturada.

A instrução reduz a ambiguidade, mas não garante uma saída correcta. Todos os campos devem ser conferidos com a fonte.

Lista de verificação humana — I

Questão de controlo	**Sim**	**Não**
A saída responde à tarefa definida?	☐	☐
Todos os valores têm fonte verificável?	☐	☐
As unidades e os tamanhos amostrais estão correctos?	☐	☐
A ferramenta inventou ou inferiu informação?	☐	☐
Os critérios de inclusão foram aplicados correctamente?	☐	☐

Lista de verificação humana — II

Questão de controlo	Sim	Não
Foram avaliados possíveis falsos negativos?	☐	☐
A informação foi conferida por pessoa responsável?	☐	☐
A utilização foi documentada?	☐	☐
Foram respeitadas as regras de privacidade e licença?	☐	☐

11. Comparação entre procedimentos manuais e assistidos

A comparação deve utilizar os mesmos critérios de elegibilidade, o mesmo conjunto de referências e regras de validação explícitas.

- tempo necessário;
- proporção de decisões concordantes;
- falsos positivos e falsos negativos;
- exactidão da extracção;
- número e natureza dos erros;
- recursos necessários para verificação;
- reprodutibilidade.

Desenho comparativo

1. Seleccionar uma amostra de referências.
2. Aplicar os critérios de elegibilidade definidos.
3. Realizar triagem manual por revisores.
4. Executar classificação assistida na mesma amostra.
5. Comparar decisões com uma classificação de referência.
6. Investigar discrepâncias.
7. Calcular métricas de desempenho.
8. Comparar o tempo total, incluindo verificação.
9. Redigir conclusão sobre utilidade e limitações.

Interpretação

A concordância entre IA e revisor não demonstra que ambos estão correctos. A decisão de referência deve resultar de critérios explícitos e, quando necessário, revisão independente e resolução de discrepâncias.

Indicadores de comparação

Indicador	Definição operacional	Interpretação
Tempo total	Execução mais verificação e correcção.	Benefício real de eficiência.
Sensibilidade	Proporção de elegíveis identificados.	Risco de perder estudos relevantes.
Precisão positiva	Proporção dos classificados como elegíveis que são elegíveis.	Carga de triagem desnecessária.
Concordância	Proporção de decisões coincidentes.	Semelhança, não prova de correcção.
Erro de extracção	Proporção de campos extraídos incorrectamente.	Fiabilidade dos dados estruturados.
Rastreabilidade	Proporção de decisões e valores com fonte.	Auditabilidade e reprodução.

12. Actividade computacional com R

- O código calcula métricas de classificação a partir de decisões de referência e de um classificador assistido.
- Não utiliza um modelo de IA externo: avalia resultados produzidos por uma ferramenta utilizada separadamente.
- Os dados são fictícios e têm finalidade pedagógica.

Objectivo

Construir a matriz de confusão, calcular métricas, identificar falsos negativos e falsos positivos e exportar os resultados.

Código R — dados e matriz de confusão

```r
# MODULO 15: AVALIACAO DE CLASSIFICACAO ASSISTIDA
# Dados ficticios para fins pedagogicos

dados <- data.frame(
  referencia = paste0("R", 1:20),
  referencia_humana = c(
    1,1,1,1,1,1,1,1,1,1,
    0,0,0,0,0,0,0,0,0,0
  ),
  classificacao_ia = c(
    1,1,1,1,1,1,1,1,0,0,
    1,1,0,0,0,0,0,0,0,0
  )
)

VP <- sum(dados$referencia_humana == 1 &
          dados$classificacao_ia == 1)
FP <- sum(dados$referencia_humana == 0 &
          dados$classificacao_ia == 1)
FN <- sum(dados$referencia_humana == 1 &
          dados$classificacao_ia == 0)
VN <- sum(dados$referencia_humana == 0 &
          dados$classificacao_ia == 0)
```

Código R — matriz e métricas

```r
matriz <- matrix(
  c(VP, FN, FP, VN), nrow = 2, byrow = TRUE,
  dimnames = list(
    "Classificacao" = c("IA_Elegivel", "IA_Nao_Elegivel"),
    "Referencia" = c("Elegivel", "Nao_Elegivel")
  )
)
print(matriz)

sensibilidade <- VP / (VP + FN)
precisao <- VP / (VP + FP)
especificidade <- VN / (VN + FP)
acuracia <- (VP + VN) / (VP + FP + FN + VN)

f1 <- if ((precisao + sensibilidade) > 0) {
  2 * precisao * sensibilidade /
    (precisao + sensibilidade)
} else { NA_real_ }
```

Código R — exportação e erros

```r
metricas <- data.frame(
  metrica = c("Sensibilidade", "Precisao positiva",
              "Especificidade", "Acuracia", "F1_score"),
  valor = c(sensibilidade, precisao, especificidade,
            acuracia, f1)
)
print(metricas)

write.csv(metricas, "metricas_classificacao_IA.csv",
          row.names = FALSE)

falsos_negativos <- subset(
  dados, referencia_humana == 1 & classificacao_ia == 0
)
cat("\nReferencias elegiveis nao identificadas:\n")
print(falsos_negativos)

falsos_positivos <- subset(
  dados, referencia_humana == 0 & classificacao_ia == 1
)
cat("\nReferencias nao elegiveis classificadas como elegiveis:\n")
print(falsos_positivos)
```

Interpretação do exercício computacional

Os estudantes deverão:

1. confirmar a matriz de confusão;
2. calcular e interpretar a sensibilidade;
3. identificar os falsos negativos;
4. discutir o impacto de perder estudos elegíveis;
5. comparar precisão positiva e sensibilidade;
6. explicar por que a acurácia isolada pode ser insuficiente em conjuntos desequilibrados;
7. propor um procedimento de verificação humana.

Limitação dos rótulos

Os rótulos humanos também podem conter erros. Documentar como foi estabelecida a classificação de referência, incluindo revisão independente e resolução de discordâncias quando apropriado.

13. Plano de utilização responsável da IA

O plano deve ser elaborado antes da utilização da ferramenta ou actualizado e documentado quando a decisão surgir durante o projecto.

- uso previsto e finalidade;
- risco principal em cada etapa;
- medida de controlo;
- responsável pela decisão e verificação;
- registos necessários para auditoria.

Modelo de plano — I

Etapa	Uso previsto	Risco principal	Medida de controlo
Planeamento	Apoio ao protocolo.	Critérios inadequados ou omissões.	Aprovação e revisão humana.
Pesquisa	Sugestão de sinónimos e termos.	Estratégia incompleta.	Validar em cada base de dados.
Deduplicação	Identificação de duplicados.	Remoção de referências distintas.	Rever casos duvidosos e conservar registos.
Triagem	Priorizar referências.	Falsos negativos.	Avaliar sensibilidade e controlar exclusões.

Modelo de plano — II

Etapa	Uso previsto	Risco principal	Medida de controlo
Extracção	Localizar dados em artigos.	Valores inventados ou mal interpretados.	Conferir fonte e localização.
Síntese	Apoiar código e organização.	Erros de cálculo ou interpretação.	Reproduzir cálculos e validar resultados.
Redacção	Apoiar clareza e organização.	Citações falsas ou distorção.	Confirmar afirmações e referências.
Gestão de dados	Processar documentos e dados.	Exposição de informação confidencial.	Verificar licenças, permissões e políticas.

Responsabilidades da equipa

O plano deve identificar quem:

- selecciona e autoriza as ferramentas;
- define instruções e parâmetros;
- verifica classificações e dados extraídos;
- resolve discordâncias;
- guarda registos e versões;
- avalia riscos de privacidade;
- autoriza a utilização dos resultados no manuscrito.

A atribuição de responsabilidades evita que erros sejam justificados apenas por terem sido produzidos automaticamente.

Documentação mínima

Para cada utilização relevante, registar:

1. nome da ferramenta e entidade responsável;
2. versão ou modelo, quando disponível;
3. data de utilização;
4. finalidade específica;
5. tipo de dados processados;
6. instrução ou configuração relevante;
7. critérios de validação;
8. erros identificados e correcções;
9. responsável pela verificação;
10. influência da ferramenta nas decisões finais.

Se a versão interna não for conhecida, registar essa limitação em vez de inventar uma identificação técnica.

14. Modelo de declaração de utilização de IA

Declaração metodológica adaptável

Durante a preparação desta revisão sistemática, foram utilizadas ferramentas digitais e/ou de inteligência artificial para *[descrever as tarefas efectivamente realizadas]*. As ferramentas foram utilizadas como apoio operacional e não como substituto dos critérios de elegibilidade, da avaliação metodológica ou da responsabilidade dos investigadores.

As saídas relevantes foram verificadas pela equipa através da consulta das fontes originais e da aplicação dos critérios previamente definidos. Os erros identificados foram corrigidos ou as saídas não verificáveis foram rejeitadas.

A equipa assume a responsabilidade pela exactidão dos dados, pela interpretação dos resultados, pela integridade das referências e pelas conclusões apresentadas. A utilização das ferramentas, incluindo limitações conhecidas, foi documentada nos registos do projecto.

Cuidados na utilização da declaração

Atenção

O texto é um modelo e deve ser adaptado às ferramentas efectivamente utilizadas e às regras da revista ou instituição.

Não afirmar que houve:

- verificação, se esta não foi realizada;
- correcção, se os erros não foram corrigidos;
- documentação, se não existem registos;
- consulta das fontes originais, se as fontes não foram conferidas.

A declaração deve descrever procedimentos reais, não procedimentos ideais.

15. Actividade prática — objectivo e procedimento

Objectivo: comparar triagem manual com classificação assistida, identificando ganhos de eficiência, diferenças nas decisões e riscos metodológicos. **Procedimento**

1. seleccionar referências científicas;
2. definir critérios de inclusão e exclusão;
3. realizar triagem manual independente;
4. aplicar ferramenta digital ou IA à mesma amostra;
5. preservar as saídas originais;
6. comparar com a classificação de referência;
7. identificar falsos positivos e falsos negativos;
8. medir tempo de execução e verificação;
9. analisar a qualidade da extracção;
10. preencher o plano de utilização responsável.

Folha de registo da comparação

Indicador	Procedimento manual	Procedimento assistido
Número de referências analisadas	A preencher	A preencher
Tempo total, incluindo verificação	A preencher	A preencher
Referências elegíveis identificadas	A preencher	A preencher
Falsos positivos	A preencher	A preencher
Falsos negativos	A preencher	A preencher
Campos de extracção incorrectos	A preencher	A preencher
Decisões sem justificação verificável	A preencher	A preencher
Principais limitações	A preencher	A preencher

Questões para discussão

1. A ferramenta reduziu o tempo total depois da verificação humana?
2. Que tipos de referência foram mais frequentemente classificados incorrectamente?
3. O desempenho variou entre línguas ou áreas científicas?
4. Quantos falsos negativos foram encontrados?
5. Que decisões exigiram julgamento científico?
6. A extracção foi rastreável até à fonte?
7. Que informação não deveria ter sido carregada na ferramenta?
8. Que procedimentos devem ser alterados antes de aplicar a ferramenta a toda a revisão?

Produto esperado por cada grupo

- tabela comparativa entre procedimentos;
- métricas de desempenho calculadas;
- exemplos documentados de erros ou discrepâncias;
- avaliação das vantagens e limitações;
- plano de utilização responsável da IA;
- declaração sobre privacidade, integridade e documentação;
- conclusão sobre a adequação da ferramenta à tarefa.

16. Rubrica de avaliação do produto prático

Critério	Pontuação	Indicador de qualidade
Definição da tarefa e dos critérios	15%	Objectivo claro, critérios explícitos e aplicação consistente.
Comparação entre métodos	20%	Comparação justa, documentada e baseada na mesma amostra.
Cálculo e interpretação das métricas	15%	Cálculos correctos e interpretação do risco de falsos negativos.
Verificação humana e rastreabilidade	20%	Fontes, discrepâncias e decisões documentadas.
Privacidade e integridade científica	15%	Riscos identificados e medidas proporcionais.
Plano responsável de utilização da IA	15%	Plano operacional, transparente e adequado ao projecto.
Total	**100%**	

17. Conclusões do módulo

1 — IA como apoio metodológico

Pode apoiar diferentes etapas, da organização de referências à extracção preliminar. A utilidade depende da tarefa, dos dados e da capacidade de validação.

2 — Controlo dos erros

A automatização pode produzir falsos positivos, falsos negativos, erros numéricos e informação sem suporte. A verificação deve ser proporcional ao risco.

Conclusões do módulo — continuação

3 — Privacidade e integridade

A utilização responsável exige respeito pela confidencialidade, licenças, políticas institucionais e regras de integridade científica. Os investigadores mantêm a responsabilidade.

4 — Transparência e reprodutibilidade

Documentar ferramenta, finalidade, instruções, resultados e verificação permite auditar a utilização da IA e compreender a sua influência na revisão.

18. Referências bibliográficas I



Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., et al. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372, n71. https://doi.org/10.1136/bmj.n71



Higgins, J. P. T., Thomas, J., Chandler, J., Cumpston, M., Li, T., Page, M. J., & Welch, V. A. (Eds.). (2024). *Cochrane Handbook for Systematic Reviews of Interventions*, Version 6.5. Cochrane. https://training.cochrane.org/handbook



Marshall, I. J., & Wallace, B. C. (2019). Toward systematic review automation: a practical guide to using machine learning tools in research synthesis. *Systematic Reviews*, 8, 163. https://doi.org/10.1186/s13643-019-1074-9



O'Mara-Eves, A., Thomas, J., McNaught, J., Miwa, M., & Ananiadou, S. (2015). Using text mining for study identification in systematic reviews: a systematic review of current approaches. *Systematic Reviews*, 4, 5. https://doi.org/10.1186/2046-4053-4-5



van de Schoot, R., de Bruin, J., Schram, R., Zahedi, P., de Boer, J., Weijdema, F., et al. (2021). An open source machine learning framework for efficient and transparent systematic reviews. *Nature Machine Intelligence*, 3, 125–133. https://doi.org/10.1038/s42256-020-00287-7

18. Referências bibliográficas II


World Health Organization. (2021). *Ethics and governance of artificial intelligence for health: WHO guidance*. World Health Organization. https://www.who.int/publications/i/item/9789240029200


UNESCO. (2023). *Guidance for generative AI in education and research*. United Nations Educational, Scientific and Cultural Organization. https://unesdoc.unesco.org/ark:/48223/pf0000386693


National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. https://doi.org/10.6028/NIST.AI.100-1


Page, M. J., Moher, D., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., et al. (2021). PRISMA 2020 explanation and elaboration: updated guidance and exemplars for reporting systematic reviews. *BMJ*, 372, n160. https://doi.org/10.1136/bmj.n160


van der Mierden, S., Tsaioun, K., Bleich, A., & Leenaars, C. H. C. (2021). Software tools for literature screening in systematic reviews: a systematic review. *Systematic Reviews*, 10, 3. https://doi.org/10.1186/s13643-020-01517-y

Muito obrigado!

Inteligência Artificial e Automação de Revisões Sistemáticas

Formação Avançada em Revisão Sistemática e Meta-Análises

Universidade Eduardo Mondlane — Centro de Desenvolvimento Académico

Fernando Mucomole

Maputo, 2026