UNIVERSIDADE EDUARDO MONDLANE

CENTRO DE DESENVOLVIMENTO ACADÉMICO

FORMAÇÃO AVANÇADA EM

REVISÃO SISTEMÁTICA E META-ANÁLISES

MÓDULO 15

INTELIGÊNCIA ARTIFICIAL E AUTOMAÇÃO DE REVISÕES SISTEMÁTICAS

Utilização crítica, transparente e responsável de ferramentas de inteligência artificial no processo de identificação, selecção, extracção e síntese da evidência científica.

Formador:

Fernando Mucomole

Maputo, Moçambique

2026

Índice

1 Enquadramento do módulo **1**

2 Conceitos fundamentais **1**

2.1 Inteligência artificial 2

2.2 Aprendizagem automática 2

2.3 Processamento de linguagem natural 2

2.4 Modelos generativos 2

3 Aplicações da IA nas revisões sistemáticas **3**

3.1 Mapa das etapas e oportunidades de automatização 3

3.2 Apoio à estratégia de pesquisa 4

3.3 Deduplicação 4

3.4 Classificação e priorização de referências 5

4 Fluxo de trabalho assistido por IA **5**

5 Classificação de estudos e avaliação do desempenho **6**

5.1 Matriz de confusão 6

5.2 Sensibilidade 6

5.3 Precisão positiva 6

5.4 Especificidade 7

5.5 F1-score 7

6 Exemplo numérico de classificação automática **7**

7 Apoio à extracção de dados **8**

7.1 Campos de extracção 8

7.2 Princípio da rastreabilidade 9

7.3 Verificação de dados numéricos 9

7.4 Protocolo de verificação 10

8 Limitações, erros e enviesamentos dos sistemas **10**

8.1 Alucinações 10

8.2 Erros de classificação 10
8.3 Enviesamento dos dados de treino 11
8.4 Falsa sensação de objectividade 11
8.5 Deriva e reprodutibilidade 11

9 Privacidade, confidencialidade e integridade científica 11
9.1 Privacidade e confidencialidade 11
9.2 Direitos de autor e licenças 12
9.3 Autoria e responsabilidade 12
9.4 Citações e referências 12

10 Formulação de instruções e verificação humana 13
10.1 Características de uma instrução adequada 13
10.2 Exemplo de instrução para extracção 14
10.3 Lista de verificação humana 14

11 Comparação entre procedimentos manuais e assistidos 15
11.1 Princípios de comparação 15
11.2 Desenho comparativo 15
11.3 Indicadores de comparação 16

12 Actividade computacional com R 16
12.1 Interpretação do exercício computacional 19

13 Plano de utilização responsável da IA 20
13.1 Elementos do plano 20
13.2 Responsabilidades da equipa 21
13.3 Documentação mínima 21

14 Modelo de declaração de utilização de IA 22

15 Actividade prática: comparação entre procedimentos manuais e assistidos 23
15.1 Objectivo 23
15.2 Procedimento 23

15.3 Tabela de registo da comparação 24
15.4 Questões para discussão 24
15.5 Produto esperado 24

16 Critérios de avaliação **25**

17 Conclusões do módulo **25**

18 Referências bibliográficas **26**

1. Enquadramento do módulo

A realização de revisões sistemáticas envolve a identificação de referências, a remoção de duplicados, a triagem de títulos e resumos, a avaliação dos textos integrais, a extracção de dados, a avaliação do risco de viés e, quando apropriado, a síntese qualitativa ou quantitativa dos resultados.

Estes procedimentos podem exigir um volume considerável de trabalho, especialmente quando a pesquisa recupera milhares de referências provenientes de várias bases de dados.

As ferramentas digitais e os sistemas de inteligência artificial (IA) podem apoiar determinadas tarefas, nomeadamente a priorização de referências, a classificação de textos, a identificação de informação e a extracção preliminar de dados. Todavia, a automatização também introduz riscos: exclusões incorrectas, informação inventada, erros de extracção, reprodução de enviesamentos e exposição indevida de dados.

Este módulo procura desenvolver uma abordagem equilibrada: aproveitar os benefícios da IA sem transferir para sistemas automatizados a responsabilidade científica da equipa de revisão.

Objectivos de aprendizagem

No final do módulo, o estudante deverá ser capaz de:

- identificar aplicações da IA em diferentes etapas de uma revisão sistemática;
- distinguir automatização, aprendizagem automática e modelos generativos;
- utilizar critérios explícitos para classificar e priorizar referências;
- verificar a exactidão dos dados extraídos automaticamente;
- reconhecer erros, alucinações e enviesamentos;
- avaliar os riscos de privacidade e confidencialidade;
- documentar ferramentas, versões, configurações e decisões assistidas por IA;
- elaborar um plano de utilização responsável e reprodutível da IA.

2. Conceitos fundamentais

2.1. Inteligência artificial

A inteligência artificial corresponde a um conjunto de técnicas computacionais destinadas a executar tarefas que envolvem capacidades como reconhecimento de padrões, classificação, previsão, processamento de linguagem e geração de conteúdo.

Na revisão sistemática, estas técnicas podem ser utilizadas para apoiar a análise de textos científicos, identificar conceitos, sugerir classificações e organizar grandes volumes de referências.

2.2. Aprendizagem automática

A aprendizagem automática (*machine learning*) utiliza algoritmos que aprendem padrões a partir de dados. Um modelo pode, por exemplo, ser treinado com referências previamente classificadas como relevantes ou irrelevantes para aprender a ordenar novas referências.

O desempenho depende da qualidade e representatividade dos dados de treino, da definição dos rótulos e da semelhança entre os estudos usados no treino e os estudos a analisar.

2.3. Processamento de linguagem natural

O processamento de linguagem natural permite analisar texto, identificar entidades, reconhecer relações semânticas, classificar documentos e localizar informação em artigos.

Pode apoiar:

- identificação de população, intervenção e resultados;
- reconhecimento de nomes de instrumentos e escalas;
- classificação temática;
- extracção preliminar de valores numéricos;
- síntese de secções de artigos para posterior verificação.

2.4. Modelos generativos

Os modelos generativos produzem texto, código, resumos, classificações ou outras saídas com base no contexto recebido. Podem auxiliar na elaboração de estratégias de pesquisa, na criação de formulários de extracção e na organização de informação científica.

No entanto, podem produzir respostas plausíveis mas incorrectas, incluindo referências inexistentes, citações imprecisas, números não presentes no artigo ou interpretações sem suporte.

Conceito fundamental

A IA deve ser entendida como um instrumento de apoio ao processo científico, e não como substituto da estratégia metodológica, da leitura crítica, da verificação documental ou da responsabilidade dos investigadores.

3. Aplicações da IA nas revisões sistemáticas

3.1. Mapa das etapas e oportunidades de automatização

Tabela 1: Aplicações potenciais de ferramentas digitais e de IA

Etapa	Aplicação possível	Verificação necessária
Planeamento	Apoio à estruturação da pergunta e do protocolo.	Confirmar que os critérios correspondem ao objectivo científico e são operacionalizáveis.
Pesquisa	Sugestão de palavras-chave, sinónimos e termos relacionados.	Validar a estratégia nas bases de dados e documentar a pesquisa efectivamente executada.
Deduplicação	Identificação de registos possivelmente duplicados.	Confirmar falsos positivos e duplicados não detectados.
Triagem	Classificação ou priorização de títulos e resumos.	Avaliar falsos negativos e cumprir os critérios de elegibilidade.
Texto integral	Localização de critérios, métodos e resultados relevantes.	Conferir directamente o artigo e justificar exclusões.
Extracção	Identificação preliminar de amostras, medidas e efeitos.	Conferir números, unidades, tabelas e páginas de origem.
Risco de viés	Organização de evidência relevante para cada domínio.	A decisão metodológica deve ser fundamentada pela equipa.
Síntese	Apoio à organização de resultados e produção de código.	Reproduzir os cálculos e verificar a coerência da interpretação.
Redacção	Revisão linguística e estruturação do texto.	Confirmar fidelidade, autoria, citações e integridade científica.

3.2. Apoio à estratégia de pesquisa

A IA pode ajudar a identificar sinónimos, variantes ortográficas, termos técnicos e conceitos relacionados com a pergunta de investigação.

Por exemplo, numa revisão sobre a eficácia de intervenções educativas apoiadas por tecnologia, poderá sugerir termos relacionados com aprendizagem digital, ensino electrónico, plataformas educativas e desempenho académico.

Contudo, a estratégia final deve ser traduzida para a sintaxe específica de cada base de dados. A equipa deve verificar:

- os descritores controlados disponíveis;
- os operadores booleanos;
- os campos de pesquisa;
- as truncaturas e expressões exactas;
- a cobertura temporal e linguística;
- a data em que a pesquisa foi executada.

A IA não deve ser considerada uma base de dados bibliográfica nem uma garantia de que a pesquisa é exaustiva.

3.3. Deduplicação

Os registos duplicados podem surgir porque o mesmo artigo é recuperado em várias bases de dados ou exportado em formatos diferentes.

A deduplicação automática pode comparar DOI, título, autores, ano e outros campos. Quando os metadados são incompletos, a identificação de duplicados pode ser incerta.

É recomendável guardar:

- o número inicial de registos;
- o número de duplicados removidos;
- o método ou ferramenta utilizada;
- os casos duvidosos verificados manualmente.

3.4. Classificação e priorização de referências

Os sistemas de aprendizagem automática podem ordenar as referências segundo a probabilidade estimada de relevância. A priorização pode ajudar a equipa a encontrar referências potencialmente elegíveis mais cedo.

Todavia, ordenar não equivale a excluir. Se a equipa interromper a triagem após analisar apenas as referências classificadas como mais relevantes, poderá deixar de identificar estudos elegíveis que o modelo classificou incorrectamente.

Nota metodológica e ética

Uma ferramenta de priorização não deve ser utilizada para excluir automaticamente referências sem uma validação metodológica apropriada. O risco de falsos negativos deve ser avaliado e documentado.

4. Fluxo de trabalho assistido por IA

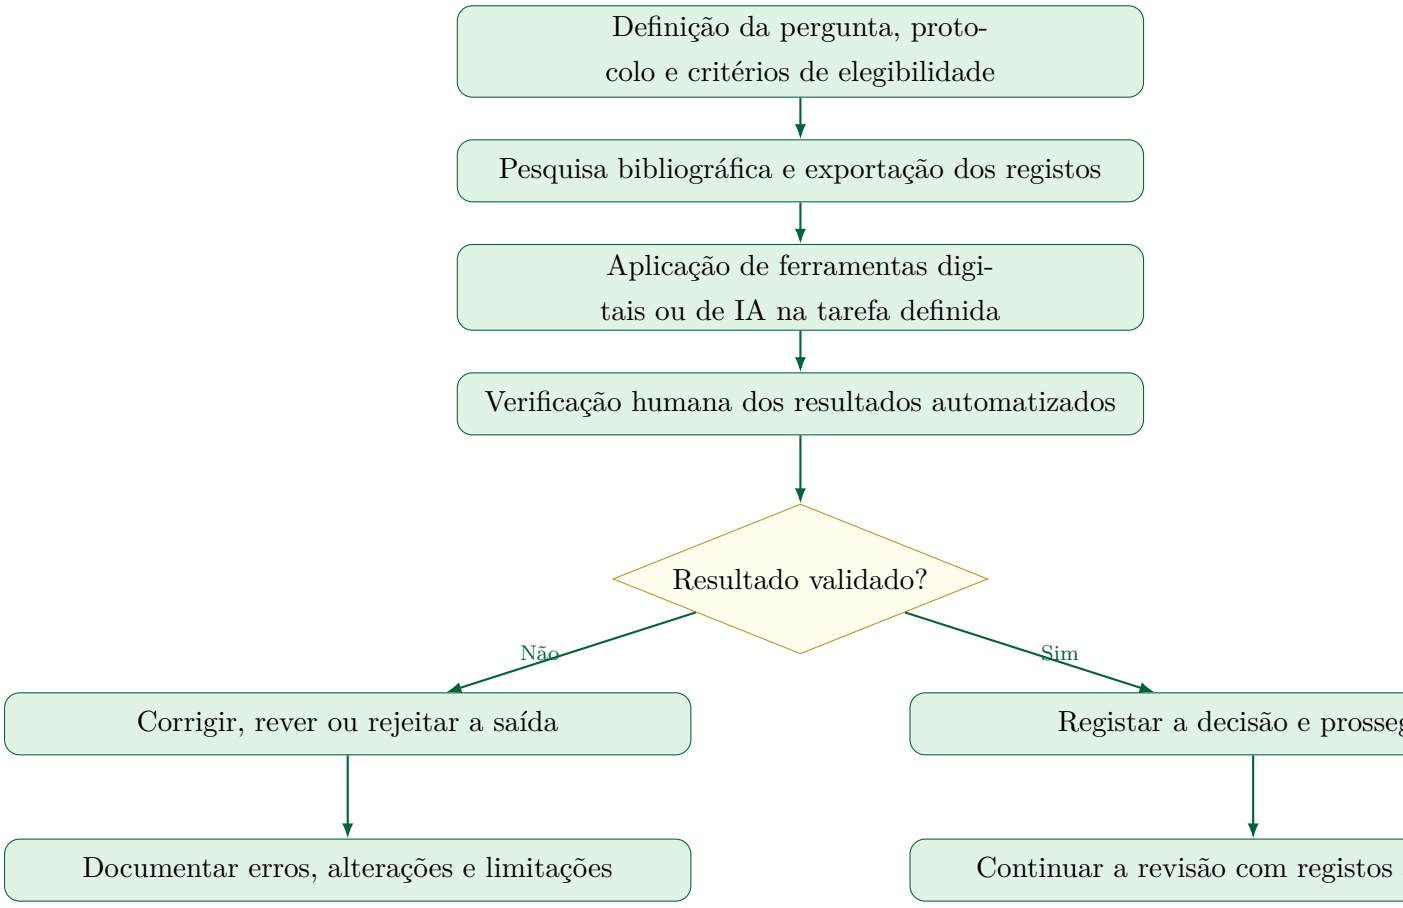


Figura 1: Fluxo recomendado para integrar IA com validação humana e documentação das decisões.

O fluxo não exige que todas as tarefas sejam automatizadas. A utilização deve ser seleccionada em função do benefício esperado, da sensibilidade dos dados, do risco de erro e da capacidade de validação.

5. Classificação de estudos e avaliação do desempenho

5.1. Matriz de confusão

Para avaliar um classificador de referências, é necessário comparar as suas previsões com uma classificação de referência estabelecida através de um procedimento humano apropriado.

Tabela 2: Matriz de confusão para a classificação de referências

	Elegível	**Não elegível**
Classificado como elegível	Verdadeiro positivo (VP)	Falso positivo (FP)
Classificado como não elegível	Falso negativo (FN)	Verdadeiro negativo (VN)

5.2. Sensibilidade

A sensibilidade mede a proporção dos estudos elegíveis que o sistema identifica correctamente:

$$\text{Sensibilidade} = \frac{VP}{VP + FN}.$$

Uma sensibilidade elevada é particularmente importante quando o objectivo é evitar a exclusão de estudos relevantes.

5.3. Precisão positiva

A precisão positiva (*precision*) mede a proporção dos estudos classificados como elegíveis que são efectivamente elegíveis:

$$\text{Precisão} = \frac{VP}{VP + FP}.$$

Uma precisão positiva elevada reduz o número de referências irrelevantes que necessitam de avaliação posterior.

5.4. Especificidade

A especificidade mede a proporção dos estudos não elegíveis correctamente identificados:

$$\text{Especificidade} = \frac{VN}{VN + FP}.$$

5.5. F1-score

O F1-score corresponde à média harmónica entre a precisão positiva e a sensibilidade:

$$F_1 = 2\frac{\text{Precisão} \times \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}}.$$

O F1-score pode resumir o compromisso entre estas métricas, mas não deve substituir a avaliação do risco de falsos negativos. Em revisões sistemáticas, o custo de excluir um estudo elegível pode ser superior ao custo de avaliar uma referência irrelevante.

Nota metodológica e ética

As métricas devem ser calculadas a partir de rótulos de referência fiáveis. Uma amostra de validação mal classificada ou não representativa pode produzir uma avaliação enganadora do desempenho do sistema.

6. Exemplo numérico de classificação automática

Exemplo aplicado

Considere-se um conjunto de 500 referências, das quais 100 são elegíveis segundo a avaliação de referência. Um sistema classifica correctamente 90 referências elegíveis, identifica incorrectamente 60 referências irrelevantes como elegíveis e não identifica 10 referências elegíveis.

Neste exemplo:

$$VP = 90, \quad FP = 60, \quad FN = 10, \quad VN = 340.$$

A sensibilidade é:

$$\text{Sensibilidade} = \frac{90}{90 + 10} = 0{,}90 = 90\%.$$

A precisão positiva é:

$$\text{Precisão} = \frac{90}{90+60} = 0{,}60 = 60\%.$$

A especificidade é:

$$\text{Especificidade} = \frac{340}{340+60} = 0{,}85 = 85\%.$$

O F1-score é:

$$F_1 = 2\frac{0{,}60 \times 0{,}90}{0{,}60+0{,}90} = 0{,}72.$$

Síntese interpretativa

O sistema identificou 90% dos estudos elegíveis neste exemplo, mas deixou escapar 10 estudos relevantes. Mesmo com uma sensibilidade aparentemente elevada, a equipa deve analisar o impacto dos falsos negativos e verificar se estes resultados se mantêm em diferentes subgrupos de referências.

7. Apoio à extracção de dados

7.1. Campos de extracção

A IA pode ajudar a localizar informação em textos integrais, mas a extracção deve obedecer a um formulário previamente definido e adaptado à pergunta de investigação.

Campos possíveis incluem:

- autor e ano de publicação;
- país e contexto;
- desenho do estudo;
- características da população;
- tamanho da amostra;
- intervenção e comparador;
- definição dos resultados;
- medidas de efeito;
- intervalos de confiança e valores de variância;

- limitações e financiamento.

7.2. Princípio da rastreabilidade

Cada valor extraído deve estar associado a uma fonte verificável, preferencialmente com número de página, tabela, figura ou secção do artigo.

A equipa deve distinguir:

1. informação explicitamente comunicada no artigo;
2. informação calculada a partir de dados apresentados;
3. informação inferida a partir do contexto;
4. informação ausente ou impossível de verificar.

A informação inferida não deve ser apresentada como se tivesse sido explicitamente comunicada pelos autores.

7.3. Verificação de dados numéricos

A extracção automatizada de números exige especial cuidado com:

- separadores decimais e de milhares;
- unidades e conversões;
- tamanhos de amostra por grupo;
- sinais positivos e negativos;
- intervalos de confiança;
- erros-padrão e desvios-padrão;
- resultados ajustados e não ajustados;
- dados apresentados em gráficos ou anexos.

Por exemplo, um sistema pode confundir o desvio-padrão com o erro-padrão ou extrair o tamanho total da amostra quando a análise utiliza apenas participantes com dados completos.

7.4. Protocolo de verificação

Recomenda-se o seguinte procedimento:

1. definir previamente o formulário de extracção;
2. solicitar a extracção de campos específicos;
3. exigir a localização da fonte de cada valor;
4. comparar a saída com o texto, as tabelas e as figuras;
5. verificar os cálculos derivados;
6. resolver discrepâncias entre revisores;
7. guardar a versão final validada.

8. Limitações, erros e enviesamentos dos sistemas

8.1. Alucinações

Uma alucinação ocorre quando um sistema gera informação que parece plausível, mas não é sustentada pelas fontes disponíveis. Pode incluir referências inexistentes, números incorrectos, citações inventadas ou descrições falsas de métodos.

8.2. Erros de classificação

Um sistema pode classificar incorrectamente um estudo porque:

- o resumo é incompleto;
- a população elegível só aparece no texto integral;
- os critérios de inclusão são complexos;
- existem sinónimos ou abreviaturas;
- a pergunta de investigação não está suficientemente representada nos exemplos usados pelo sistema.

8.3. Enviesamento dos dados de treino

Os sistemas podem reproduzir limitações dos dados usados no seu desenvolvimento. Se os dados de treino privilegiarem determinadas línguas, regiões, revistas ou desenhos de estudo, o desempenho pode ser inferior em contextos menos representados.

Uma revisão que inclua estudos em português, línguas locais ou contextos africanos deve verificar se as ferramentas interpretam adequadamente a terminologia e as características dos documentos relevantes.

8.4. Falsa sensação de objectividade

A automatização não elimina necessariamente o julgamento subjectivo. A escolha dos dados, dos critérios, dos parâmetros e do limiar de classificação pode influenciar os resultados.

A decisão automatizada deve, por isso, ser avaliada com a mesma exigência crítica aplicada aos procedimentos humanos.

8.5. Deriva e reprodutibilidade

As ferramentas podem mudar de versão, modelo, interface, política de utilização ou comportamento. Uma instrução aplicada hoje pode produzir uma saída diferente no futuro.

Para aumentar a reprodutibilidade, a equipa deve registar a versão disponível, a data, os parâmetros relevantes e os resultados validados.

9. Privacidade, confidencialidade e integridade científica

9.1. Privacidade e confidencialidade

Antes de carregar documentos numa ferramenta externa, a equipa deve verificar se os documentos contêm:

- dados pessoais ou identificadores;
- informação clínica individual;
- dados não publicados sujeitos a confidencialidade;
- manuscritos submetidos ou documentos sob embargo;

- informação protegida por contrato ou licença;
- dados de participantes que não podem ser partilhados.

A utilização de uma ferramenta deve respeitar as condições institucionais, os consentimentos aplicáveis, as regras de protecção de dados e as licenças dos documentos.

Nota metodológica e ética

Não se deve assumir que uma ferramenta é confidencial apenas porque exige autenticação ou está disponível através de uma conta institucional. É necessário verificar as condições aplicáveis ao armazenamento, processamento, retenção e utilização dos dados.

9.2. Direitos de autor e licenças

O acesso a um artigo não implica necessariamente autorização para redistribuir o seu texto integral ou carregá-lo numa plataforma externa.

A equipa deve verificar os termos da licença, as condições institucionais e as regras da ferramenta. Sempre que possível, deve utilizar-se apenas a informação necessária à tarefa, sem expor documentos ou dados que não precisem de ser processados.

9.3. Autoria e responsabilidade

A IA não substitui a responsabilidade dos autores pela exactidão, originalidade e integridade do trabalho científico. A utilização de sistemas generativos deve ser transparente e compatível com as políticas da revista, instituição ou entidade financiadora.

Os investigadores devem verificar:

- se a ferramenta pode ser mencionada nos métodos;
- se existe uma política de declaração de utilização de IA;
- se as referências citadas existem e sustentam as afirmações;
- se o texto final representa correctamente os dados;
- se foram respeitadas as regras de autoria e contributo.

9.4. Citações e referências

Nunca se deve aceitar automaticamente uma referência produzida por IA. Cada referência deve ser confirmada através de uma fonte bibliográfica verificável.

Devem ser confirmados, pelo menos:

- título;
- autores;
- ano;
- revista ou editora;
- volume e páginas, quando aplicáveis;
- DOI ou identificador persistente.

10. Formulação de instruções e verificação humana

10.1. Características de uma instrução adequada

Uma instrução destinada a um sistema generativo deve definir:

1. o papel operacional do sistema;
2. a tarefa exacta;
3. os critérios de elegibilidade ou campos pretendidos;
4. os limites da fonte de informação;
5. o formato de saída;
6. o procedimento para informação ausente;
7. a obrigação de assinalar incerteza.

10.2. Exemplo de instrução para extracção

Exemplo aplicado

Instrução proposta

Analise o texto científico fornecido e extraia apenas os seguintes campos: autor, ano, desenho do estudo, população, tamanho da amostra, intervenção, comparador e resultado primário.

Para cada campo, indique a secção, página ou tabela onde a informação aparece. Se um valor não estiver explicitamente disponível, escreva "Não comunicado". Não invente valores, não complete dados por inferência e não crie referências. Separe os valores comunicados pelos autores dos valores calculados. Devolva o resultado numa tabela estruturada.

A instrução reduz a ambiguidade, mas não garante uma saída correcta. Todos os campos devem ser conferidos com a fonte.

10.3. Lista de verificação humana

Tabela 3: Lista de verificação da saída automatizada

Questão de controlo	Sim	Não
A saída responde à tarefa definida?	☐	☐
Todos os valores têm fonte verificável?	☐	☐
As unidades e os tamanhos amostrais estão correctos?	☐	☐
A ferramenta inventou ou inferiu informação?	☐	☐
Os critérios de inclusão foram aplicados correctamente?	☐	☐
Foram avaliados possíveis falsos negativos?	☐	☐
A informação foi conferida por uma pessoa responsável?	☐	☐
A utilização foi documentada?	☐	☐
Foram respeitadas as regras de privacidade e licença?	☐	☐

11. Comparação entre procedimentos manuais e assistidos

11.1. Princípios de comparação

A comparação entre métodos manuais e assistidos por IA deve utilizar os mesmos critérios de elegibilidade, o mesmo conjunto de referências e regras de validação explícitas.

É necessário distinguir:

- o tempo necessário;
- a proporção de decisões concordantes;
- os falsos positivos e falsos negativos;
- a exactidão da extracção de dados;
- o número e a natureza dos erros;
- os recursos necessários para verificação;
- a reprodutibilidade do procedimento.

11.2. Desenho comparativo

Uma comparação didáctica pode seguir as seguintes etapas:

1. seleccionar uma amostra de referências;
2. aplicar os critérios de elegibilidade definidos;
3. realizar a triagem manual por revisores;
4. executar a classificação assistida por ferramenta digital;
5. comparar as decisões com uma classificação de referência;
6. investigar as discrepâncias;
7. calcular as métricas de desempenho;
8. comparar o tempo total, incluindo a verificação;
9. redigir uma conclusão sobre utilidade e limitações.

Nota metodológica e ética

A concordância entre a IA e um revisor não demonstra automaticamente que ambos estão correctos. A avaliação deve utilizar critérios explícitos e, quando necessário, uma decisão de referência obtida através de revisão independente e resolução de discrepâncias.

11.3. Indicadores de comparação

Tabela 4: Indicadores para a comparação dos procedimentos

Indicador	Definição operacional	Interpretação
Tempo total	Tempo de execução mais tempo de verificação e correcção.	Permite avaliar o benefício real de eficiência.
Sensibilidade	Proporção de referências elegíveis identificadas.	Quantifica o risco de perder estudos relevantes.
Precisão positiva	Proporção das referências classificadas como elegíveis que são elegíveis.	Quantifica a carga de triagem desnecessária.
Concordância	Proporção de decisões coincidentes entre métodos.	Resume a semelhança, mas não estabelece qual método é correcto.
Erro de extracção	Proporção de campos extraídos incorrectamente.	Avalia a fiabilidade dos dados estruturados.
Rastreabilidade	Proporção de decisões e valores com fonte documentada.	Avalia a possibilidade de auditoria e reprodução.

12. Actividade computacional com R

O código seguinte permite calcular métricas de classificação a partir de decisões de referência e de um classificador assistido por ferramenta digital. Não utiliza um modelo de IA externo: avalia os resultados produzidos por uma ferramenta que tenha sido utilizada separadamente.

```
# ============================================================
# MODULO 15: AVALIACAO DE CLASSIFICACAO ASSISTIDA
# Dados ficticios para fins pedagogicos
# ============================================================

# 1. Criar um conjunto ilustrativo
dados <- data.frame(
```

```r
  referencia = paste0("R", 1:20),

  # Classificacao de referencia:
  # 1 = elegivel; 0 = nao elegivel
  referencia_humana = c(
    1,1,1,1,1,1,1,1,1,1,
    0,0,0,0,0,0,0,0,0,0
  ),

  # Classificacao produzida por uma ferramenta:
  # 1 = elegivel; 0 = nao elegivel
  classificacao_ia = c(
    1,1,1,1,1,1,1,1,0,0,
    1,1,0,0,0,0,0,0,0,0
  )
)

# 2. Calcular a matriz de confusao
VP <- sum(
  dados$referencia_humana == 1 &
  dados$classificacao_ia == 1
)

FP <- sum(
  dados$referencia_humana == 0 &
  dados$classificacao_ia == 1
)

FN <- sum(
  dados$referencia_humana == 1 &
  dados$classificacao_ia == 0
)

VN <- sum(
  dados$referencia_humana == 0 &
  dados$classificacao_ia == 0
)

matriz <- matrix(
  c(VP, FN, FP, VN),
  nrow = 2,
```

```
  byrow = TRUE,
  dimnames = list(
    "Classificacao" = c("IA_Elegivel", "IA_Nao_Elegivel"),
    "Referencia" = c("Elegivel", "Nao_Elegivel")
  )
)

print(matriz)

# 3. Calcular as metricas
sensibilidade <- VP / (VP + FN)
precisao <- VP / (VP + FP)
especificidade <- VN / (VN + FP)
acuracia <- (VP + VN) / (VP + FP + FN + VN)

f1 <- if ((precisao + sensibilidade) > 0) {
  2 * precisao * sensibilidade /
    (precisao + sensibilidade)
} else {
  NA_real_
}

metricas <- data.frame(
  metrica = c(
    "Sensibilidade",
    "Precisao positiva",
    "Especificidade",
    "Acuracia",
    "F1_score"
  ),
  valor = c(
    sensibilidade,
    precisao,
    especificidade,
    acuracia,
    f1
  )
)

print(metricas)

```

```r
# 4. Exportar resultados
write.csv(
  metricas,
  "metricas_classificacao_IA.csv",
  row.names = FALSE
)

# 5. Identificar falsos negativos
falsos_negativos <- subset(
  dados,
  referencia_humana == 1 &
  classificacao_ia == 0
)

cat("\nReferencias elegiveis nao identificadas:\n")
print(falsos_negativos)

# 6. Identificar falsos positivos
falsos_positivos <- subset(
  dados,
  referencia_humana == 0 &
  classificacao_ia == 1
)

cat("\nReferencias nao elegiveis classificadas como elegiveis:\n"
    )
print(falsos_positivos)
```

Listing 1: Avaliação de um classificador de referências

12.1. Interpretação do exercício computacional

Os estudantes deverão:

1. confirmar a matriz de confusão;
2. calcular e interpretar a sensibilidade;
3. identificar os falsos negativos;
4. discutir o impacto de perder estudos elegíveis;
5. comparar a precisão positiva com a sensibilidade;

6. explicar por que razão a acurácia isolada pode ser insuficiente em conjuntos desequilibrados;

7. propor um procedimento de verificação humana.

Nota metodológica e ética

Os rótulos humanos usados como referência também podem conter erros. Em aplicações reais, a avaliação deve documentar como foi estabelecida a classificação de referência, incluindo revisão independente e resolução de discordâncias quando apropriado.

13. Plano de utilização responsável da IA

13.1. Elementos do plano

O plano deve ser elaborado antes da utilização da ferramenta ou, quando a decisão surgir durante o projecto, actualizado e documentado.

Tabela 5: Modelo de plano de utilização responsável da IA

Etapa	Uso previsto	Risco principal	Medida de controlo
Planeamento	Apoio à organização do protocolo.	Critérios inadequados ou omissões.	Aprovação e revisão humana do protocolo.
Pesquisa	Sugestão de sinónimos e termos.	Estratégia incompleta.	Validar a pesquisa em cada base de dados.
Deduplicação	Identificação de possíveis duplicados.	Remoção indevida de referências distintas.	Rever casos duvidosos e conservar registos.
Triagem	Priorizar referências.	Falsos negativos.	Avaliar sensibilidade e manter controlo das exclusões.
Extracção	Localizar dados em artigos.	Valores inventados ou mal interpretados.	Conferência com a fonte e registo da localização.

Etapa	Uso previsto	Risco principal	Medida de controlo
Síntese	Apoiar código e organização de resultados.	Erros de cálculo ou interpretação.	Reproduzir os cálculos e validar os resultados.
Redacção	Apoiar clareza e organização do texto.	Citações falsas ou distorção do conteúdo.	Confirmar cada afirmação e cada referência.
Gestão de dados	Processar documentos e dados.	Exposição de informação confidencial.	Verificar licenças, permissões e políticas de dados.

13.2. Responsabilidades da equipa

O plano deve identificar quem:

- selecciona e autoriza as ferramentas;
- define as instruções e os parâmetros;
- verifica as classificações e os dados extraídos;
- resolve discordâncias;
- guarda os registos e as versões;
- avalia os riscos de privacidade;
- autoriza a utilização dos resultados no manuscrito.

A atribuição de responsabilidades evita que erros sejam justificados apenas com a alegação de que foram produzidos automaticamente.

13.3. Documentação mínima

Para cada utilização relevante, recomenda-se registar:

1. nome da ferramenta e entidade responsável;
2. versão ou modelo, quando disponível;
3. data de utilização;

4. finalidade específica;
5. tipo de dados processados;
6. instrução ou configuração relevante;
7. critérios de validação;
8. erros identificados e correcções;
9. responsável pela verificação;
10. influência da ferramenta nas decisões finais.

Quando não for possível conhecer a versão interna do modelo, essa limitação deve ser registada, em vez de se inventar uma identificação técnica.

14. Modelo de declaração de utilização de IA

A declaração seguinte deve ser adaptada às ferramentas efectivamente utilizadas e às regras da revista ou instituição.

Declaração metodológica adaptável

Durante a preparação desta revisão sistemática, foram utilizadas ferramentas digitais e/ou de inteligência artificial para *[descrever as tarefas efectivamente realizadas]*. As ferramentas foram utilizadas como apoio operacional e não como substituto dos critérios de elegibilidade, da avaliação metodológica ou da responsabilidade dos investigadores.

As saídas relevantes foram verificadas pela equipa através da consulta das fontes originais e da aplicação dos critérios previamente definidos. Os erros identificados foram corrigidos ou as saídas não verificáveis foram rejeitadas.

A equipa assume a responsabilidade pela exactidão dos dados, pela interpretação dos resultados, pela integridade das referências e pelas conclusões apresentadas. A utilização das ferramentas, incluindo limitações conhecidas, foi documentada nos registos do projecto.

Nota metodológica e ética

Este texto é um modelo. Não deve afirmar que houve verificação, correcção ou documentação se esses procedimentos não tiverem sido efectivamente realizados.

15. Actividade prática: comparação entre procedimentos manuais e assistidos

15.1. Objectivo

Comparar a triagem manual com uma classificação assistida por ferramenta digital, identificando ganhos de eficiência, diferenças nas decisões e riscos metodológicos.

15.2. Procedimento

Cada grupo deverá:

1. seleccionar um conjunto de referências científicas;
2. definir critérios de inclusão e exclusão;
3. realizar uma triagem manual independente;
4. aplicar uma ferramenta digital ou de IA à mesma amostra;
5. preservar as saídas originais da ferramenta;
6. comparar as decisões com a classificação de referência;
7. identificar falsos positivos e falsos negativos;
8. medir o tempo de execução e verificação;
9. analisar a qualidade da informação extraída;
10. preencher o plano de utilização responsável.

15.3. Tabela de registo da comparação

Tabela 6: Folha de registo dos resultados da actividade

Indicador	Procedimento manual	Procedimento assistido
Número de referências analisadas	A preencher	A preencher
Tempo total, incluindo verificação	A preencher	A preencher
Referências elegíveis identificadas	A preencher	A preencher
Falsos positivos	A preencher	A preencher
Falsos negativos	A preencher	A preencher
Campos de extracção incorrectos	A preencher	A preencher
Decisões sem justificação verificável	A preencher	A preencher
Principais limitações	A preencher	A preencher

15.4. Questões para discussão

1. A ferramenta reduziu o tempo total depois de incluída a verificação humana?
2. Que tipos de referência foram mais frequentemente classificados de forma incorrecta?
3. A ferramenta teve desempenho diferente em textos de línguas ou áreas científicas distintas?
4. Quantos falsos negativos foram encontrados?
5. Que decisões exigiram julgamento científico?
6. A extracção automática foi rastreável até à fonte?
7. Que informação não deveria ter sido carregada na ferramenta utilizada?
8. Que procedimentos devem ser alterados antes de aplicar a ferramenta a toda a revisão?

15.5. Produto esperado

Cada grupo deverá entregar:

- uma tabela comparativa entre os procedimentos;
- as métricas de desempenho calculadas;
- exemplos documentados de erros ou discrepâncias;
- uma avaliação das vantagens e limitações;
- um plano de utilização responsável da IA;
- uma declaração sobre privacidade, integridade e documentação;
- uma conclusão sobre a adequação da ferramenta à tarefa.

16. Critérios de avaliação

Tabela 7: Rubrica de avaliação do produto prático

Critério	**Pontuação**	**Indicador de qualidade**
Definição da tarefa e dos critérios	15%	Objectivo claro, critérios explícitos e aplicação consistente.
Comparação entre métodos	20%	Comparação justa, documentada e baseada na mesma amostra.
Cálculo e interpretação das métricas	15%	Cálculos correctos e interpretação do risco de falsos negativos.
Verificação humana e rastreabilidade	20%	Fontes, discrepâncias e decisões devidamente documentadas.
Privacidade e integridade científica	15%	Identificação dos riscos e medidas de controlo proporcionais.
Plano responsável de utilização da IA	15%	Plano operacional, transparente e adequado ao projecto.
Total	**100%**	

17. Conclusões do módulo

Conclusão 1 – IA como apoio metodológico

A inteligência artificial pode apoiar diferentes etapas da revisão sistemática, desde a organização de referências até à extracção preliminar de informação. A utilidade depende da tarefa, da qualidade dos dados e da capacidade de validação.

Conclusão 2 – Controlo dos erros

A automatização pode produzir falsos positivos, falsos negativos, erros numéricos e informação não sustentada pelas fontes. A verificação humana deve ser proporcional ao risco da tarefa.

Conclusão 3 – Privacidade e integridade

A utilização responsável exige respeito pela confidencialidade, pelas licenças, pelas políticas institucionais e pelas regras de integridade científica. Os investigadores mantêm a responsabilidade pelas decisões e conclusões.

Conclusão 4 – Transparência e reprodutibilidade

A documentação da ferramenta, da finalidade, das instruções, dos resultados e dos procedimentos de verificação permite auditar a utilização da IA e compreender a sua influência na revisão sistemática.

18. Referências bibliográficas

[1] Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., et al. (2021). The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ*, 372, n71. https://doi.org/10.1136/bmj.n71

[2] Higgins, J. P. T., Thomas, J., Chandler, J., Cumpston, M., Li, T., Page, M. J., & Welch, V. A. (Eds.). (2024). *Cochrane Handbook for Systematic Reviews of Interventions*, Version 6.5. Cochrane. https://training.cochrane.org/handbook

[3] Marshall, I. J., & Wallace, B. C. (2019). Toward systematic review automation: a practical guide to using machine learning tools in research synthesis. *Systematic Reviews*, 8, 163. https://doi.org/10.1186/s13643-019-1074-9

[4] O'Mara-Eves, A., Thomas, J., McNaught, J., Miwa, M., & Ananiadou, S. (2015). Using text mining for study identification in systematic reviews: a systematic review of current approaches. *Systematic Reviews*, 4, 5. https://doi.org/10.1186/2046-4053-4-5

[5] van de Schoot, R., de Bruin, J., Schram, R., Zahedi, P., de Boer, J., Weijdema, F., et al. (2021). An open source machine learning framework for efficient and transparent systematic reviews. *Nature Machine Intelligence*, 3, 125–133. https://doi.org/10.1038/s42256-020-00287-7

[6] World Health Organization. (2021). *Ethics and governance of artificial intelligence for health: WHO guidance*. World Health Organization. https://www.who.int/publications/i/item/9789240029200

[7] UNESCO. (2023). *Guidance for generative AI in education and research*. United Nations Educational, Scientific and Cultural Organization. https://unesdoc.unesco.org/ark:/48223/pf0000386693

[8] National Institute of Standards and Technology. (2023). *Artificial Intelligence Risk Management Framework (AI RMF 1.0)*. NIST AI 100-1. https://doi.org/10.6028/NIST.AI.100-1

[9] Page, M. J., Moher, D., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D., et al. (2021). PRISMA 2020 explanation and elaboration: updated guidance and exemplars for reporting systematic reviews. *BMJ*, 372, n160. https://doi.org/10.1136/bmj.n160

[10] van der Mierden, S., Tsaioun, K., Bleich, A., & Leenaars, C. H. C. (2021). Software tools for literature screening in systematic reviews: a systematic review. *Systematic Reviews*, 10, 3. https://doi.org/10.1186/s13643-020-01517-y