UNIVERSIDADE EDUARDO MONDLANE

Centro de Desenvolvimento Académico

FORMAÇÃO AVANÇADA

Revisão Sistemática e Meta-análises

MÓDULO 18

Revisões de Estudos de Diagnóstico e Prognóstico

Objectivo central

Desenvolver competências para formular perguntas, seleccionar estudos, avaliar o risco

Organização do módulo

1. Enquadramento e objectivos
2. Diagnóstico e prognóstico
3. Formulação da pergunta
4. Medidas de acurácia diagnóstica
5. Curvas ROC e limiares
6. Modelos estatísticos de síntese diagnóstica
7. Modelos prognósticos
8. Risco de viés e aplicabilidade
9. Pesquisa, selecção e extracção
10. Plano de síntese estatística
11. Implementação em R
12. Actividade prática
13. Plano metodológico e avaliação
14. Orientações de relato
15. Conclusões
16. Referências bibliográficas

1. Enquadramento do módulo

As revisões sistemáticas de estudos de diagnóstico e prognóstico sintetizam evidência sobre a capacidade de testes, instrumentos ou modelos para:

- identificar condições de saúde presentes;
- estimar acontecimentos futuros;
- avaliar o desempenho de modelos de previsão;
- examinar a consistência dos resultados entre populações;
- apoiar decisões clínicas e práticas.

Distinção fundamental

Diagnóstico: avalia se um teste identifica correctamente uma condição presente.
Prognóstico: avalia se um modelo estima a probabilidade de um acontecimento futuro.

A diferença determina os critérios de inclusão, as medidas estatísticas, os modelos de síntese e os instrumentos de avaliação.

2. O que deve ser distinguido?

É essencial distinguir cinco conceitos:

1. **Acurácia de um teste:** capacidade para classificar correctamente uma condição relativamente a um padrão de referência.
2. **Associação:** relação estatística entre um marcador e um resultado.
3. **Discriminação:** capacidade de um modelo distinguir indivíduos com resultados diferentes.
4. **Calibração:** concordância entre riscos previstos e resultados observados.
5. **Utilidade:** valor das previsões para apoiar decisões.

Atenção

Um marcador associado a um resultado não constitui necessariamente um modelo prognóstico útil. Uma AUC elevada também não garante boa calibração ou utilidade clínica.

3. Objectivos de aprendizagem

No final do módulo, o participante deverá ser capaz de:

1. Distinguir perguntas de diagnóstico e prognóstico.
2. Formular perguntas estruturadas para cada revisão.
3. Interpretar sensibilidade, especificidade, VPP, VPN e LR.
4. Interpretar curvas ROC e área sob a curva.
5. Explicar a dependência entre sensibilidade e especificidade.
6. Reconhecer modelos estatísticos de síntese diagnóstica.
7. Distinguir discriminação, calibração e utilidade prognóstica.
8. Compreender validação interna e externa.
9. Aplicar QUADAS-2 e PROBAST, conforme a finalidade.
10. Elaborar um plano metodológico de revisão especializada.

4. Estudos de acurácia diagnóstica

Um estudo de acurácia diagnóstica compara:

- um **teste índice**, que está a ser avaliado;
- um **padrão de referência**, utilizado para determinar a presença ou ausência da condição.

Exemplos de perguntas:

- Qual é a sensibilidade e a especificidade de um teste rápido?
- O desempenho varia entre diferentes contextos?
- Qual é a acurácia de um método de imagem?
- Como varia a acurácia entre diferentes limiares?

Finalidade

Determinar até que ponto o teste classifica correctamente os indivíduos com e sem a condição de interesse.

5. Estudos de prognóstico

Os estudos prognósticos descrevem a evolução de uma condição ou avaliam modelos que estimam acontecimentos futuros.

Exemplos de perguntas:

- Qual é o risco de recorrência durante determinado período?
- Que factores estão associados à progressão de uma doença?
- Qual é a capacidade de um modelo para estimar mortalidade?
- O modelo mantém a calibração em populações diferentes?

Finalidade

Estimar a probabilidade de um resultado futuro para uma pessoa ou grupo, considerando um horizonte temporal definido.

6. Diagnóstico versus prognóstico

Dimensão	Diagnóstico	Prognóstico
Pergunta	O teste identifica uma condição presente?	O modelo estima um resultado futuro?
Comparador	Padrão de referência	Resultado observado durante seguimento
Medidas	Sensibilidade, especificidade, LR e AUC	Discriminação, calibração e erro preditivo
Dados	Resultados do teste e padrão de referência	Preditores, resultados e tempo de seguimento
Risco de viés	Participantes, teste, referência, fluxo e tempo	Participantes, preditores, resultados e análise
Aplicabilidade	População, contexto, teste e limiar	População, horizonte, preditores e contexto

7. Pergunta de revisão diagnóstica

Uma pergunta diagnóstica deve especificar:

- **População:** participantes nos quais o teste será utilizado;
- **Teste índice:** teste ou procedimento avaliado;
- **Padrão de referência:** método que determina a condição;
- **Condição-alvo:** doença, estado ou característica;
- **Contexto:** local e circunstâncias de utilização;
- **Limiar:** ponto de corte, quando aplicável.

Exemplo

Em adultos com suspeita da condição X, qual é a sensibilidade e a especificidade do teste Y, comparado com o padrão de referência Z, em contextos de cuidados primários?

8. Pergunta de revisão prognóstica

Uma pergunta prognóstica deve identificar:

- população de interesse;
- resultado a prever;
- horizonte temporal;
- preditores ou modelo prognóstico;
- contexto de utilização;
- tipo de desempenho que será sintetizado.

Exemplo

Em adultos diagnosticados com a condição X, qual é o desempenho discriminativo e a calibração dos modelos que estimam o risco de recorrência aos dois anos?

9. Definição prévia do protocolo

O protocolo deve especificar:

- pergunta e critérios de elegibilidade;
- fontes de informação e estratégia de pesquisa;
- processos de selecção e extracção;
- instrumentos de avaliação crítica;
- métodos de síntese estatística;
- tratamento de dados incompletos.

Deve prever o tratamento de:

- diferentes limiares diagnósticos;
- diferentes padrões de referência;
- diferentes horizontes temporais;
- populações e contextos distintos;
- modelos desenvolvidos e validados externamente;
- resultados não reportados.

10. Tabela de contingência

A acurácia diagnóstica é frequentemente organizada numa tabela de contingência 2×2.

	Padrão de referência		**Total**
Teste índice	Presente	Ausente	
Positivo	VP	FP	VP+FP
Negativo	FN	VN	FN+VN
Total	VP+FN	FP+VN	N

$$N = VP + FP + FN + VN$$

- VP: verdadeiro positivo;
- FP: falso positivo;
- FN: falso negativo;
- VN: verdadeiro negativo.

11. Sensibilidade

A sensibilidade é a proporção de indivíduos com a condição que obtêm um resultado positivo no teste.

$$\boxed{Se = \frac{VP}{VP + FN}}$$

- Sensibilidade elevada: identifica uma proporção elevada dos indivíduos com a condição.
- Sensibilidade baixa: pode produzir muitos falsos negativos.

Interpretação

Uma sensibilidade de 80% significa que, entre os indivíduos que têm a condição, 80% apresentam resultado positivo.

12. Especificidade

A especificidade é a proporção de indivíduos sem a condição que obtêm um resultado negativo.

$$Sp = \frac{VN}{VN + FP}$$

- Especificidade elevada: classifica correctamente uma proporção elevada dos indivíduos sem a condição.
- Especificidade baixa: pode produzir muitos falsos positivos.

Interpretação

Uma especificidade de 85% significa que, entre os indivíduos sem a condição, 85% apresentam resultado negativo.

13. Valores preditivos

O valor preditivo positivo (VPP) é a proporção de resultados positivos que correspondem a indivíduos com a condição.

$$VPP = \frac{VP}{VP + FP}$$

O valor preditivo negativo (VPN) é a proporção de resultados negativos que correspondem a indivíduos sem a condição.

$$VPN = \frac{VN}{VN + FN}$$

Dependência da prevalência

Os valores preditivos dependem da prevalência da condição na população em que o teste é utilizado. Não devem ser transferidos automaticamente para populações com prevalências diferentes.

14. Razões de verosimilhança

As razões de verosimilhança relacionam a probabilidade de um resultado do teste entre pessoas com e sem a condição.

$$\boxed{LR^{+} = \frac{Se}{1 - Sp}}$$

$$\boxed{LR^{-} = \frac{1 - Se}{Sp}}$$

- Um LR^{+} maior aumenta a probabilidade da condição após um resultado positivo.
- Um LR^{-} mais próximo de zero reduz a probabilidade da condição após um resultado negativo.

A interpretação deve considerar os valores concretos, a incerteza estatística, a população e a finalidade do teste.

15. Exemplo numérico: dados

Considere-se um teste aplicado a 1 000 indivíduos.
O padrão de referência identifica:

- 200 indivíduos com a condição;
- 800 indivíduos sem a condição.

Resultados do teste:

- VP = 160;
- FN = 40;
- FP = 120;
- VN = 680.

	Condição presente	Condição ausente	Total
Teste positivo	160	120	280
Teste negativo	40	680	720
Total	200	800	1 000

16. Exemplo numérico: sensibilidade e especificidade

Sensibilidade:

$$Se = \frac{160}{160 + 40} = \frac{160}{200} = 0.80 = 80\%.$$

Especificidade:

$$Sp = \frac{680}{680 + 120} = \frac{680}{800} = 0.85 = 85\%.$$

Interpretação

O teste identifica 80% dos indivíduos com a condição e classifica correctamente 85% dos indivíduos sem a condição.

17. Exemplo numérico: valores preditivos

Valor preditivo positivo:

$$VPP = \frac{160}{160 + 120} = \frac{160}{280} = 0.5714$$

$$\boxed{VPP \approx 57.1\%}$$

Valor preditivo negativo:

$$VPN = \frac{680}{680 + 40} = \frac{680}{720} = 0.9444$$

$$\boxed{VPN \approx 94.4\%}$$

O VPP é aproximadamente 57.1%, enquanto o VPN é aproximadamente 94.4%, nesta população específica.

18. Exemplo numérico: LR e acurácia global

Razão de verosimilhança positiva:

$$LR^{+} = \frac{0.80}{1 - 0.85} = \frac{0.80}{0.15} = 5.33$$

Razão de verosimilhança negativa:

$$LR^{-} = \frac{1 - 0.80}{0.85} = \frac{0.20}{0.85} = 0.235$$

Acurácia global:

$$A = \frac{VP + VN}{N} = \frac{160 + 680}{1000} = 84\%$$

Interpretação

A acurácia global de 84% não substitui a análise separada da sensibilidade, especificidade, valores preditivos e consequências dos erros de classificação.

19. Curva ROC

A curva ROC (*Receiver Operating Characteristic*) representa a sensibilidade em função da taxa de falsos positivos para diferentes limiares de decisão.

$$FPR = 1 - Sp$$

Cada limiar c produz um ponto:

$$(1 - Sp(c), Se(c))$$

Um teste com resultados contínuos pode produzir vários pares de sensibilidade e especificidade, consoante o limiar escolhido.

Finalidade

Avaliar a capacidade discriminativa do teste ao longo de diferentes limiares de classificação.

20. Área sob a curva ROC

A área sob a curva ROC (AUC) resume a capacidade discriminativa do teste ao longo dos limiares.

$$AUC = \int_0^1 ROC(x)\, dx$$

Interpretação convencional:

- $AUC = 0.5$: discriminação equivalente à classificação aleatória no sentido convencional da ROC;
- AUC mais elevada: melhor discriminação global;
- $AUC = 1$: discriminação perfeita nos dados considerados.

Limitação

Uma AUC elevada não garante utilidade clínica, calibração, desempenho consistente em novas populações ou um limiar adequado para a decisão.

21. Escolha do limiar diagnóstico

A selecção de um limiar depende de:

- consequências dos falsos positivos;
- consequências dos falsos negativos;
- prevalência da condição;
- recursos disponíveis;
- objectivo do teste;
- contexto de utilização.

Um limiar pode ser adequado para rastreio, mas inadequado para confirmar uma condição.

Princípio metodológico

A escolha do limiar não deve basear-se exclusivamente na maximização de uma estatística, sem considerar o contexto e as consequências da decisão.

22. Dependência entre sensibilidade e especificidade

Quando um teste contínuo utiliza um limiar mais baixo para classificar um resultado como positivo:

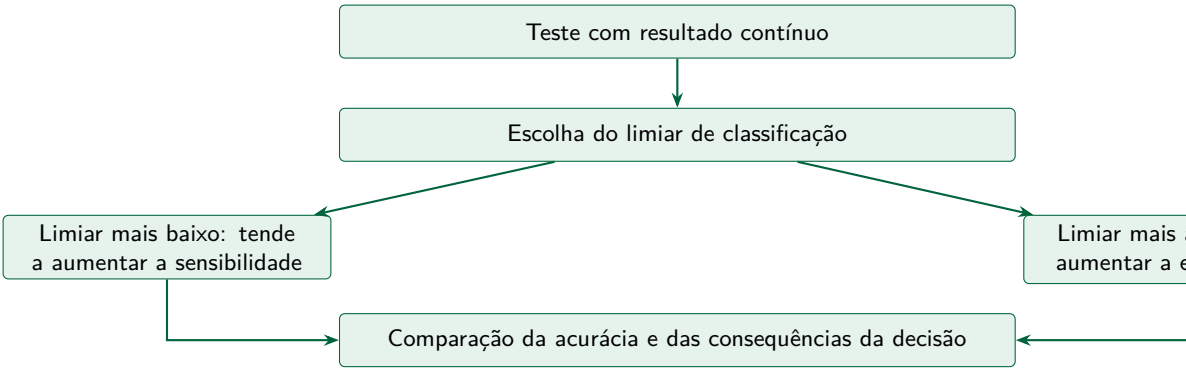
- tende a aumentar a sensibilidade;
- tende a diminuir a especificidade.

Quando o limiar aumenta:

- tende a diminuir a sensibilidade;
- tende a aumentar a especificidade.

Esta relação depende da distribuição dos resultados do teste entre indivíduos com e sem a condição.

23. Efeito do limiar: esquema conceptual



24. Implicações para a meta-análise

Uma abordagem inadequada consiste em calcular uma média simples das sensibilidades e outra das especificidades, ignorando a relação entre elas.
A síntese deve considerar:

- utilização do mesmo limiar ou de limiares diferentes;
- testes contínuos ou categóricos;
- definição prévia dos limiares;
- comparabilidade das populações;
- semelhança dos padrões de referência;
- diferenças clínicas, metodológicas ou de medição.

25. Por que utilizar modelos específicos?

Os estudos de acurácia diagnóstica apresentam frequentemente uma estrutura bivariada:

- cada estudo fornece informação sobre sensibilidade;
- cada estudo fornece informação sobre especificidade;
- as duas medidas podem estar estatisticamente relacionadas;
- existe incerteza amostral;
- o desempenho pode variar entre estudos.

A variação pode resultar de diferenças na população, limiares, execução do teste, interpretação e padrões de referência.

Princípio

Os modelos devem considerar a estrutura dos dados e não apenas a disponibilidade de medidas agregadas.

26. Modelo bivariado de efeitos aleatórios

O modelo bivariado sintetiza conjuntamente sensibilidade e especificidade, frequentemente através de transformações logit.

$$\text{logit}(Se_i) = \mu_{Se} + u_{Se,i}$$

$$\text{logit}(Sp_i) = \mu_{Sp} + u_{Sp,i}$$

Os efeitos aleatórios seguem uma distribuição normal bivariada:

$$\begin{pmatrix} u_{Se,i} \\ u_{Sp,i} \end{pmatrix} \sim N\left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \tau^2_{Se} & \rho\tau_{Se}\tau_{Sp} \\ \rho\tau_{Se}\tau_{Sp} & \tau^2_{Sp} \end{pmatrix} \right]$$

27. Interpretação do modelo bivariado

- μ_{Se}: média na escala logit da sensibilidade;
- μ_{Sp}: média na escala logit da especificidade;
- τ^2_{Se}: variabilidade entre estudos na sensibilidade;
- τ^2_{Sp}: variabilidade entre estudos na especificidade;
- ρ: correlação entre os efeitos aleatórios.

A formulação é esquemática. A estimação real inclui modelos binomiais para os números de:

- verdadeiros positivos;
- falsos negativos;
- verdadeiros negativos;
- falsos positivos.

Também considera as particularidades do método de estimação.

28. Modelo HSROC

O modelo HSROC (*Hierarchical Summary Receiver Operating Characteristic*) descreve a relação entre sensibilidade e especificidade através de uma estrutura hierárquica de acurácia e limiar.
Pode ser especialmente útil quando:

- existem limiares diferentes entre estudos;
- se pretende caracterizar a relação ROC subjacente;
- existe heterogeneidade na acurácia e nos limiares.

O modelo bivariado e o HSROC estão relacionados, mas não são idênticos em todas as parametrizações e condições.
A escolha deve ser justificada pela estrutura dos dados, pela pergunta e pelos pressupostos do modelo.

29. Curva ROC sumária

Uma curva ROC sumária apresenta a relação estimada entre sensibilidade e especificidade.
Pode ser acompanhada por:

- **Região de confiança:** incerteza sobre os parâmetros sumários;
- **Região de predição:** variação esperada entre novos contextos ou estudos, quando adequadamente estimada.

Não confundir

A região de confiança e a região de predição não são equivalentes. A primeira representa a incerteza sobre o resultado sumário; a segunda representa a variabilidade esperada entre contextos, sob os pressupostos do modelo.

30. Razão de possibilidades diagnóstica

A razão de possibilidades diagnóstica (*Diagnostic Odds Ratio*, DOR) é:

$$DOR = \frac{VP/FN}{FP/VN}$$

$$\boxed{DOR = \frac{VP \times VN}{FP \times FN}}$$

Uma DOR mais elevada indica maior separação entre os resultados do teste nos indivíduos com e sem a condição.

Limitação

A DOR combina informação sobre falsos positivos e falsos negativos. Não substitui a apresentação separada da sensibilidade e da especificidade, nem descreve directamente os valores preditivos numa população específica.

31. Células com zero observações

Quando existem células com zero observações, a DOR pode ser indefinida ou exigir métodos específicos de estimação.

- A aplicação automática de correcções numéricas deve ser justificada.
- A estrutura dos dados esparsos deve ser examinada.
- A escolha do método deve considerar o número de estudos e a dimensão das amostras.

Recomendação

Documentar o método utilizado e avaliar a estabilidade dos resultados através de análises de sensibilidade apropriadas.

32. Heterogeneidade em estudos diagnósticos

A heterogeneidade pode resultar de:

- diferenças na gravidade da condição;
- variação da prevalência e do espectro clínico;
- diferenças nos limiares;
- padrões de referência distintos;
- diferenças na execução ou interpretação do teste;
- desenhos de estudo diferentes;
- selecção de participantes e contextos de utilização.

A heterogeneidade não deve ser avaliada apenas por um indicador genérico. É necessário examinar os mecanismos clínicos e metodológicos que podem produzir diferenças no desempenho.

33. Limitações dos modelos hierárquicos

Os modelos hierárquicos podem ser instáveis quando existem:

- poucos estudos;
- amostras pequenas;
- tabelas de contingência esparsas;
- poucos eventos positivos ou negativos;
- grande heterogeneidade entre estudos.

Atenção

A complexidade do modelo deve ser proporcional à informação disponível. As limitações da estimação devem ser relatadas explicitamente.

34. Modelo prognóstico

Um modelo prognóstico utiliza uma ou mais características dos participantes para estimar a probabilidade de um resultado futuro, num horizonte temporal definido.

$$\widehat{p}_i = f(X_{i1}, X_{i2}, \ldots, X_{ik})$$

Em que:

- $\widehat{p}_i$: risco estimado para o indivíduo i;
- X_{ij}: preditores;
- f: função estimada a partir dos dados.

Em modelos de sobrevivência, a previsão pode corresponder ao risco de um acontecimento até determinado tempo t, considerando o seguimento e a censura.

35. Discriminação

A discriminação mede a capacidade do modelo para atribuir previsões diferentes a indivíduos que apresentam resultados distintos.
Para resultados binários, podem utilizar-se:

- AUC;
- estatísticas relacionadas com a concordância.

Em modelos de sobrevivência, podem utilizar-se medidas de concordância adequadas ao tempo e à censura.

Limitação

Uma discriminação elevada não garante que os riscos previstos sejam numericamente correctos.

36. Calibração

A calibração avalia a concordância entre os riscos previstos e os resultados observados.
Se um modelo prevê um risco de 20% para um grupo de indivíduos comparáveis, a calibração examina se a frequência observada do resultado se aproxima desse valor.
A avaliação deve considerar:

- horizonte temporal;
- população;
- definição do resultado;
- método de avaliação;
- incerteza das estimativas.

37. Calibração global

Para resultados binários, a calibração pode ser examinada comparando probabilidades previstas e frequências observadas.
Podem utilizar-se:

- gráficos de calibração;
- modelos de calibração;
- intercepto de calibração;
- declive de calibração.

Objectivo

Verificar se os riscos estimados pelo modelo correspondem aos resultados observados na população avaliada.

38. Intercepto e declive de calibração

Intercepto de calibração:
Examina, de forma simplificada, a tendência global de subestimação ou sobrestimação do risco.
Declive de calibração:
Avalia se as previsões são demasiado extremas ou demasiado concentradas.
Um declive inferior a 1 pode indicar previsões excessivamente extremas, frequentemente associadas a sobreajustamento.
A interpretação depende do modelo e do procedimento de avaliação utilizado.

39. Erro de previsão: escore de Brier

Para resultados binários, o escore de Brier é:

$$BS = \frac{1}{N} \sum_{i=1}^{N} (\widehat{p}_i - y_i)^2$$

Em que:

- $\widehat{p}_i$: probabilidade prevista;
- $y_i \in \{0, 1\}$: resultado observado;
- N: número de indivíduos.

Valores menores indicam menor erro quadrático médio das probabilidades previstas.
Para resultados de sobrevivência, devem utilizar-se versões adequadas que considerem a censura e o tempo.

40. Validação interna e externa

Tipo	Procedimento	Finalidade e limitações
Interna	Bootstrap ou validação cruzada adequadamente implementada.	Estima estabilidade e optimismo dentro do contexto de desenvolvimento. Não demonstra, por si só, transportabilidade.
Temporal	Avaliação em participantes recrutados posteriormente.	Examina estabilidade do desempenho ao longo do tempo.
Geográfica	Avaliação em instituições ou regiões diferentes.	Examina transportabilidade para outros contextos geográficos.
Externa independente	Aplicação a dados independentes dos utilizados no desenvolvimento.	Avalia desempenho numa população ou contexto distinto.

41. Desenvolvimento versus validação

É essencial distinguir estudos que desenvolvem um modelo dos estudos que avaliam um modelo já definido.

Desenvolvimento:

- selecção de preditores;
- estimação dos parâmetros;
- construção do modelo.

Validação:

- avaliação do modelo num conjunto de dados adequado;
- exame da discriminação e calibração;
- avaliação sem reajustar o modelo para favorecer os resultados.

A actualização ou recalibração deve ser explicitada e distinguida da avaliação do modelo original.

42. Risco de sobreajustamento

O sobreajustamento ocorre quando o modelo capta características específicas dos dados de desenvolvimento que não se reproduzem em novos dados.
Pode resultar de:

- número insuficiente de participantes ou acontecimentos;
- selecção excessiva de preditores;
- procedimentos de selecção instáveis;
- ausência de validação interna adequada;
- fuga de informação entre conjuntos;
- optimização repetida com base nos mesmos dados.

43. O que examinar na avaliação prognóstica?

A avaliação prognóstica deve examinar:

- desenho do estudo;
- tamanho da amostra;
- número de acontecimentos;
- estratégia de modelação;
- tratamento de dados em falta;
- método de selecção de preditores;
- procedimentos de validação;
- calibração e discriminação;
- horizonte temporal e aplicabilidade.

44. QUADAS-2: estudos diagnósticos

O QUADAS-2 avalia o risco de viés e as preocupações relativas à aplicabilidade em estudos de acurácia diagnóstica.
Considera quatro domínios:

1. **Selecção de participantes:** selecção e exclusões;
2. **Teste índice:** execução, interpretação e limiares;
3. **Padrão de referência:** adequação e interpretação;
4. **Fluxo e tempo:** sequência, intervalo e resultados incompletos.

Os primeiros três domínios são também utilizados na avaliação das preocupações com a aplicabilidade. O domínio de fluxo e tempo contribui para a avaliação do risco de viés.

45. Exemplos de problemas de viés diagnóstico

Problema	Exemplo	Possível consequência
Viés de selecção	Inclusão apenas de casos graves e controlos saudáveis.	Resultados pouco representativos da prática habitual.
Viés de revisão	Avaliador conhece o teste índice ao interpretar o padrão.	Pode influenciar a classificação final.
Limiar pós-hoc	Melhor ponto de corte escolhido e avaliado na mesma amostra.	Pode sobrestimar o desempenho.
Referência inadequada	Método imperfeito ou inconsistente para definir a condição.	Erros na classificação dos participantes.
Verificação parcial	Nem todos recebem o padrão de referência.	Pode distorcer sensibilidade e especificidade.
Perdas e exclusões	Participantes sem resultados completos são excluídos.	Pode introduzir viés.

46. PROBAST: modelos prognósticos

O PROBAST avalia o risco de viés e a aplicabilidade de estudos de modelos de previsão diagnóstica e prognóstica.
Organiza a avaliação em quatro domínios:

1. **Participantes:** selecção, elegibilidade e representatividade.
2. **Preditores:** definição, medição e disponibilidade.
3. **Resultados:** definição, determinação e momento de avaliação.
4. **Análise:** amostra, dados em falta, selecção de preditores, sobreajustamento e desempenho.

47. Problemas de viés prognóstico

Exemplos de problemas metodológicos:

- exclusão de participantes sem justificação adequada;
- preditores medidos de forma inconsistente;
- definição ambígua do resultado;
- horizonte temporal incompatível com a pergunta;
- tratamento inadequado de dados em falta;
- selecção de preditores sem controlo do sobreajustamento;
- avaliação nos mesmos dados de desenvolvimento;
- ausência de avaliação da calibração;
- apresentação selectiva de medidas de desempenho.

48. Risco de viés não é sinónimo de desempenho

Um modelo pode apresentar uma AUC elevada e, simultaneamente:

- ter elevado risco de viés;
- apresentar calibração inadequada;
- não ser aplicável a outras populações;
- ter sido avaliado nos mesmos dados de desenvolvimento.

Princípio

A avaliação metodológica deve ser separada da apresentação dos resultados de desempenho.

49. Fontes de informação

A selecção das fontes depende da pergunta e da área temática.
Podem considerar-se:

- MEDLINE/PubMed;
- Embase;
- Scopus;
- Web of Science;
- fontes especializadas relevantes.

A estratégia deve ser adaptada a cada base de dados, utilizando:

- vocabulários controlados, quando disponíveis;
- termos livres e sinónimos;
- operadores booleanos;
- conceitos relativos à população e à condição.

50. Estratégia genérica: diagnóstico

Exemplo conceptual de pesquisa para estudos diagnósticos:

Expressão de pesquisa

```
(diagnostic accuracy OR sensitivity OR specificity OR ROC)
AND
(index test OR diagnostic test)
AND
(target condition)
```

Esta expressão não está pronta para submissão.
Deve ser adaptada à base de dados, aos termos indexados e à pergunta concreta.

51. Estratégia genérica: prognóstico

Exemplo conceptual de pesquisa para modelos prognósticos:

Expressão de pesquisa

```
(prognostic model OR prediction model OR risk prediction)
AND
(validation OR discrimination OR calibration)
AND
(target outcome)
```

A estratégia deve ser adaptada aos termos de indexação, aos sinónimos e às características da área de investigação.

52. Selecção dos estudos

O processo de selecção deve incluir:

1. remoção de duplicados;
2. triagem de títulos e resumos;
3. avaliação do texto integral;
4. registo dos motivos de exclusão;
5. resolução de discordâncias segundo o protocolo;
6. apresentação do fluxo de selecção.

Sempre que possível, a elegibilidade deve ser avaliada por dois revisores independentes, com procedimento predefinido para resolver discordâncias.

53. Dados a extrair: estudos diagnósticos

A extracção deve incluir, conforme aplicável:

- referência e características do estudo;
- desenho e contexto;
- critérios de inclusão e exclusão;
- características dos participantes;
- prevalência ou proporção com a condição;
- descrição do teste índice e limiar;
- descrição do padrão de referência;
- VP, FP, FN e VN;
- sensibilidade e especificidade;
- informação sobre dados em falta;
- elementos para avaliar o risco de viés.

54. Dados a extrair: estudos prognósticos

A extracção pode incluir:

- finalidade e tipo de modelo;
- população, contexto e período de recrutamento;
- resultado previsto e horizonte temporal;
- definição e medição dos preditores;
- número de participantes e acontecimentos;
- tratamento dos dados em falta;
- método de desenvolvimento;
- validação interna ou externa;
- discriminação, calibração e medidas de erro;
- actualização ou recalibração;
- elementos para avaliar o risco de viés.

55. Dados incompletos e resultados não reportados

A equipa deve documentar:

- dados que não foram reportados;
- dados obtidos por contacto com os autores;
- dados calculados a partir da informação disponível;
- procedimentos utilizados para lidar com informação incompleta.

Atenção

Não se devem reconstruir tabelas de contingência sem informação suficiente. Resultados prognósticos não devem ser tratados como equivalentes quando utilizam horizontes temporais, definições de resultados ou métricas diferentes.

56. Plano de síntese diagnóstica

O plano deve indicar:

1. medida principal de acurácia;
2. modelo estatístico escolhido;
3. tratamento de dados esparsos;
4. análise de diferentes limiares;
5. factores de heterogeneidade;
6. análises de sensibilidade;
7. apresentação da incerteza.

Se os estudos forem comparáveis, pode considerar-se um modelo bivariado ou HSROC.
Se a heterogeneidade clínica ou metodológica impedir uma síntese estatística defensável, deve privilegiar-se uma síntese estruturada sem combinar resultados inadequadamente.

57. Plano de síntese prognóstica

O protocolo deve especificar:

- síntese de modelos de desenvolvimento, validação ou ambos;
- medidas de desempenho prioritárias;
- tratamento de diferentes horizontes temporais;
- comparabilidade dos resultados e populações;
- consideração das diferenças de calibração;
- condições para efectuar uma meta-análise;
- descrição de modelos sem resultados comparáveis.

Uma média simples de AUC de populações, horizontes e métodos de validação muito diferentes pode ser enganadora.

58. Análises de subgrupos

Os subgrupos devem ser definidos previamente e fundamentados.

Em estudos diagnósticos:

- tipo de teste;
- limiar de decisão;
- gravidade da condição;
- contexto de utilização;
- tipo de padrão de referência;
- desenho do estudo.

Em estudos prognósticos:

- desenvolvimento ou validação;
- horizonte temporal;
- contexto geográfico ou institucional;
- tipo de modelo e resultado previsto;
- disponibilidade e qualidade dos preditores.

59. Interpretação das análises de subgrupos

As análises de subgrupos devem ser interpretadas com cautela:

- quando existem poucos estudos;
- quando as comparações não foram previstas no protocolo;
- quando os subgrupos são definidos após observar os resultados;
- quando existem diferenças importantes entre populações;
- quando as estimativas são imprecisas.

Boa prática

Justificar previamente os subgrupos e relatar todas as análises planeadas, incluindo resultados não conclusivos.

60. R: cálculo das medidas diagnósticas

O exemplo calcula as medidas a partir de uma tabela fictícia.

```
sensibilidade <- VP / (VP + FN) especificidade <- VN / (VN + FP)
VPP <- VP / (VP + FP) VPN <- VN / (VN + FN)
LR_positivo < -sensibilidade/(1 - especificidade)LR_negativo < -(1 - sensibilidade)/especificidade
acuracia <- (VP + VN) / (VP + FN + FP + VN)
```

61. R: organizar e apresentar os resultados

```
print(resultados)
```

O código utiliza valores fictícios e não substitui a estimação de intervalos de confiança nem uma síntese de múltiplos estudos.

62. R: pacote mada

O pacote mada disponibiliza ferramentas para análise de dados de acurácia diagnóstica, incluindo modelos bivariados e abordagens HSROC.

```
dados <- data.frame( TP = c(45, 62, 38, 71, 54), FN = c(15, 18, 12, 19, 16), FP = c(12, 20, 10, 25, 14), TN = c(88, 100, 75, 110, 92) )
d <- mada::mada(dados)
modelo <- mada::reitsma(d)
summary(modelo) plot(modelo)
```

63. R: interpretação do exemplo mada

O exemplo utiliza dados fictícios de cinco estudos.
Antes da análise definitiva:

- verificar a documentação da versão instalada;
- confirmar os argumentos aceites;
- verificar a estrutura de dados exigida;
- confirmar o mapeamento de VP, FN, FP e VN;
- verificar os pressupostos do modelo;
- avaliar a estabilidade da estimação.

Verificação do software

A sintaxe exacta deve ser confirmada na documentação da versão do pacote instalada. O código é ilustrativo e deve ser testado antes de ser utilizado numa análise real.

64. R: avaliação de previsões prognósticas

O exemplo calcula o escore de Brier e a AUC para dados binários.

```
observado <- c(1,0,1,0,0,1,0,1,0,1)
previsto <- c( 0.80,0.25,0.65,0.30,0.40, 0.75,0.20,0.70,0.35,0.60 )
brier <- mean((previsto - observado)^2)
roc_obj < −roc(response = observado, predictor = previsto, quiet = TRUE)
auc_valor < −as.numeric(auc(roc_obj))
```

65. R: resultados e gráfico ROC

```
plot( roc_obj, main =
"Curva ROC - exemplo ilustrativo" )
```

Limitações do exemplo

O exemplo não avalia a calibração, não considera censura e não demonstra validação externa.
Para resultados de sobrevivência, devem utilizar-se métodos apropriados ao tempo de seguimento e à censura.

66. Actividade prática: objectivo

Análise crítica de uma revisão publicada

Avaliar a coerência entre a pergunta, os métodos, as medidas estatísticas, a avaliação do risco de viés e as conclusões de uma revisão sistemática.

Seleccionar uma revisão publicada que tenha como objecto:

- a acurácia de um teste diagnóstico; ou
- o desempenho de modelos prognósticos.

Registar a referência completa, o DOI, a pergunta da revisão e a área de aplicação.

67. Actividade: análise da pergunta

Para uma revisão diagnóstica, identificar:

- população;
- teste índice;
- padrão de referência;
- condição-alvo.

Para uma revisão prognóstica, identificar:

- população;
- modelos e preditores;
- resultados previstos;
- horizontes temporais.

68. Actividade: análise dos métodos

Verificar:

1. se os critérios de elegibilidade estão claros;
2. se a pesquisa bibliográfica é reproduzível;
3. se a selecção e a extracção foram documentadas;
4. se o instrumento de risco de viés é apropriado;
5. se as medidas respondem à pergunta;
6. se o modelo de síntese é justificado;
7. se a heterogeneidade foi examinada;
8. se as limitações são discutidas.

69. Actividade: interpretação dos resultados

Revisão diagnóstica:

- sensibilidade e especificidade;
- limiares de decisão;
- curvas ROC;
- regiões de confiança e de predição;
- heterogeneidade.

Revisão prognóstica:

- discriminação;
- calibração;
- horizonte temporal;
- validação;
- utilidade do modelo.

70. Actividade: plano metodológico

Preparar um plano de revisão que inclua:

- título provisório;
- justificação e pergunta;
- critérios de inclusão e exclusão;
- fontes de informação;
- estratégia de pesquisa preliminar;
- procedimento de selecção;
- dados a extrair;
- instrumento de avaliação crítica;
- plano de síntese;
- análises de sensibilidade;
- limitações previstas.

71. Modelo de plano metodológico

Componente	Descrição a preencher
Título provisório	Condição, teste ou modelo e finalidade da revisão.
Justificação	Problema, lacuna científica e relevância da síntese.
Pergunta	População, teste e padrão de referência; ou população, modelo, resultado e horizonte temporal.
Critérios de inclusão	Desenhos, participantes, testes ou modelos, resultados e contextos.
Critérios de exclusão	Exclusões justificadas e coerentes com a pergunta.
Bases de dados	Fontes bibliográficas e outras fontes pertinentes.
Estratégia	Conceitos, sinónimos, vocabulários controlados e operadores.
Selecção	Revisores, fases e resolução de discordâncias.
Extracção	Variáveis e procedimentos de verificação.

72. Modelo de plano: avaliação e síntese

Componente	Descrição a preencher
Avaliação crítica	QUADAS-2 para estudos de acurácia diagnóstica ou PROBAST para estudos de modelos de previsão, conforme aplicável.
Síntese estatística	Medidas, modelos, condições para meta-análise e tratamento da heterogeneidade.
Análises adicionais	Subgrupos e análises de sensibilidade fundamentados.
Apresentação	Tabelas, gráficos, fluxograma e síntese narrativa.
Limitações	Dados incompletos, heterogeneidade e limitações da evidência.
Transparência	Registo do protocolo, documentação de alterações e orientações de relato pertinentes.

73. Grelha de avaliação da actividade

Critério	Peso	Pontuação
Clareza e adequação da pergunta	10%	_____
Coerência dos critérios de elegibilidade	10%	_____
Adequação da pesquisa e selecção	10%	_____
Qualidade do plano de extracção	10%	_____
Adequação do instrumento de avaliação crítica	15%	_____
Justificação das medidas e modelos	20%	_____
Interpretação e limitações	10%	_____
Clareza e reprodutibilidade do plano	15%	_____
Total	**100%**	_____

74. Orientações e instrumentos

- **PRISMA 2020:** orientação geral para o relato de revisões sistemáticas.
- **PRISMA-DTA:** extensão para o relato de revisões sistemáticas de estudos de acurácia diagnóstica.
- **TRIPOD:** orientação para o relato de estudos de desenvolvimento e validação de modelos de previsão.
- **PROBAST:** instrumento de avaliação do risco de viés e aplicabilidade em estudos de modelos de previsão.
- **QUADAS-2:** instrumento de avaliação do risco de viés e aplicabilidade em estudos de acurácia diagnóstica.

75. Funções distintas das ferramentas

Estas ferramentas têm funções diferentes:

- uma orientação de relato não substitui um instrumento de risco de viés;
- um instrumento de risco de viés não substitui um protocolo;
- nenhum deles substitui a definição de métodos de síntese adequados à pergunta.

Boa prática

Consultar as versões actualizadas das orientações e dos instrumentos antes da sua aplicação num projecto real.

76. Conclusão 1 — Perguntas distintas

As revisões diagnósticas e prognósticas respondem a perguntas diferentes.
A escolha dos estudos, das medidas e dos modelos deve reflectir a finalidade da investigação.

77. Conclusão 2 — Acurácia diagnóstica

Sensibilidade, especificidade, valores preditivos, razões de verosimilhança e curvas ROC fornecem perspectivas complementares.
A interpretação exige atenção:

- aos limiares;
- à prevalência;
- à heterogeneidade entre estudos;
- às consequências dos erros de classificação.

78. Conclusão 3 — Modelos prognósticos

A discriminação não é suficiente para demonstrar a qualidade de um modelo prognóstico.
Devem ser examinados separadamente:

- calibração;
- validação;
- horizonte temporal;
- aplicabilidade;
- utilidade das previsões.

79. Conclusão 4 — Rigor metodológico

A avaliação do risco de viés, a escolha de modelos de síntese apropriados e a transparência das decisões são essenciais para produzir conclusões úteis e cientificamente defensáveis.

Produto final do módulo

Um plano metodológico para uma revisão especializada, com pergunta definida, critérios de elegibilidade, estratégia de pesquisa, plano de extracção, avaliação crítica e método de síntese justificado.

80. Referências bibliográficas I

Whiting, P. F., Rutjes, A. W. S., Westwood, M. E., Mallett, S., Deeks, J. J., Reitsma, J. B., et al. (2011). QUADAS-2: A revised tool for the quality assessment of diagnostic accuracy studies. *Annals of Internal Medicine, 155*(8), 529–536. https://doi.org/10.7326/0003-4819-155-8-201110180-00009

Macaskill, P., Gatsonis, C., Deeks, J. J., Harbord, R. M., & Takwoingi, Y. (2010). Chapter 10: Analysing and presenting results of diagnostic test accuracy reviews. In J. P. T. Higgins & S. Green (Eds.), *Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy, Version 1.0*. The Cochrane Collaboration.

Reitsma, J. B., Glas, A. S., Rutjes, A. W. S., Scholten, R. J. P. M., Bossuyt, P. M., & Zwinderman, A. H. (2005). Bivariate analysis of sensitivity and specificity produces informative summary measures in diagnostic reviews. *Journal of Clinical Epidemiology, 58*(10), 982–990. https://doi.org/10.1016/j.jclinepi.2005.02.022

Rutter, C. M., & Gatsonis, C. A. (2001). A hierarchical regression approach to meta-analysis of diagnostic test accuracy evaluations. *Statistics in Medicine, 20*(19), 2865–2884. https://doi.org/10.1002/sim.942

Bossuyt, P. M., Reitsma, J. B., Bruns, D. E., et al. (2015). STARD 2015: An updated list of essential items for reporting diagnostic accuracy studies. *BMJ, 351*, h5527. https://doi.org/10.1136/bmj.h5527

McInnes, M. D. F., Moher, D., Thombs, B. D., et al. (2018). PRISMA-DTA Statement. *JAMA, 319*(4), 388–396. https://doi.org/10.1001/jama.2017.19163

Moons, K. G. M., Wolff, R. F., Riley, R. D., et al. (2019). PROBAST: A tool to assess risk of bias and applicability of prediction model studies. *Annals of Internal Medicine, 170*(1), 51–58. https://doi.org/10.7326/M18-1376

80. Referências bibliográficas II

- Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. M. (2015). TRIPOD: The TRIPOD Statement. *Annals of Internal Medicine, 162*(1), 55–63. https://doi.org/10.7326/M14-0697
- Steyerberg, E. W. (2019). *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating* (2nd ed.). Springer. https://doi.org/10.1007/978-3-030-16399-0
- Debray, T. P. A., Damen, J. A. A. G., Snell, K. I. E., et al. (2017). A guide to systematic review and meta-analysis of prediction model performance. *BMJ, 356*, i6460. https://doi.org/10.1136/bmj.i6460
- Moons, K. G. M., de Groot, J. A. H., Bouwmeester, W., et al. (2014). CHARMS checklist. *PLoS Medicine, 11*(10), e1001744. https://doi.org/10.1371/journal.pmed.1001744
- R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. https://www.r-project.org/
- mada package. *Meta-Analysis of Diagnostic Accuracy*. Documentação do pacote R. https://cran.r-project.org/package=mada

UNIVERSIDADE EDUARDO MONDLANE

Centro de Desenvolvimento Académico

MÓDULO 18

Revisões de Estudos de Diagnóstico e Prognóstico

Rigor diagnóstico, previsão responsável e síntese de evidência cientificamente fundamentada.

Formador: Fernando Mucomole

Maputo, Moçambique — 2026