UNIVERSIDADE EDUARDO MONDLANE

Centro de Desenvolvimento Académico

FORMAÇÃO AVANÇADA

Revisão Sistemática e Meta-análises

MÓDULO 18

Revisões de Estudos de Diagnóstico e Prognóstico

Objectivo central

Desenvolver competências para formular perguntas, seleccionar estudos, avaliar o risco de viés e sintetizar evidência sobre a acurácia de testes diagnósticos e o desempenho de modelos prognósticos, utilizando métodos adequados a cada finalidade.

Formador: Fernando Mucomole

Maputo, Moçambique

2026

Índice

1 Enquadramento do módulo **3**

2 Objectivos de aprendizagem **3**

3 Diagnóstico e prognóstico: diferenças fundamentais **4**
3.1 Estudos de acurácia diagnóstica 4
3.2 Estudos de prognóstico 4

4 Formulação da pergunta de revisão **5**
4.1 Perguntas de diagnóstico 5
4.2 Perguntas de prognóstico 6
4.3 Definição prévia do protocolo 6

5 Medidas de acurácia diagnóstica **6**
5.1 Tabela de contingência 6
5.2 Sensibilidade 7
5.3 Especificidade 7
5.4 Valores preditivos 7
5.5 Razões de verosimilhança 8
5.6 Exemplo numérico completo 8

6 Curvas ROC e área sob a curva **10**
6.1 Curva ROC 10
6.2 Área sob a curva ROC 10
6.3 Escolha do limiar 10

7 Dependência entre sensibilidade e especificidade **11**
7.1 O efeito do limiar 11
7.2 Implicações para a meta-análise 11

8 Modelos estatísticos para síntese diagnóstica **12**
8.1 Por que utilizar modelos específicos? 12
8.2 Modelo bivariado de efeitos aleatórios 12
8.3 Modelo HSROC 12
8.4 Curva ROC sumária 13
8.5 Razão de possibilidades diagnóstica 13
8.6 Heterogeneidade em estudos diagnósticos 13

9 Validação e avaliação de modelos prognósticos **14**
9.1 Modelo prognóstico 14
9.2 Discriminação 14
9.3 Calibração 15
9.3.1 Calibração global 15
9.3.2 Intercepto e declive de calibração 15

9.4 Erro de previsão . . . 15
9.5 Validação interna e externa . . . 15
9.6 Desenvolvimento versus validação . . . 16
9.7 Risco de sobreajustamento . . . 16

10 Risco de viés e aplicabilidade 17
10.1 Estudos de acurácia diagnóstica: QUADAS-2 . . . 17
10.2 Exemplos de problemas de viés diagnóstico . . . 17
10.3 Modelos prognósticos: PROBAST . . . 18
10.4 Problemas de viés prognóstico . . . 18

11 Estratégia de pesquisa, selecção e extracção 19
11.1 Fontes de informação . . . 19
11.2 Selecção dos estudos . . . 19
11.3 Dados a extrair de estudos diagnósticos . . . 20
11.4 Dados a extrair de estudos prognósticos . . . 20
11.5 Dados incompletos e resultados não reportados . . . 21

12 Plano de síntese estatística 21
12.1 Síntese diagnóstica . . . 21
12.2 Síntese prognóstica . . . 22
12.3 Análises de subgrupos . . . 22

13 Implementação ilustrativa em R 23
13.1 Cálculo das medidas diagnósticas . . . 23
13.2 Modelo bivariado para estudos diagnósticos . . . 24
13.3 Exemplo de avaliação de previsões prognósticas . . . 25

14 Actividade prática 27

15 Modelo de plano metodológico 28

16 Grelha de avaliação da actividade 28

17 Orientações para redacção e relato 29

18 Conclusões do módulo 30

19 Referências bibliográficas 30

1. Enquadramento do módulo

As revisões sistemáticas de estudos de diagnóstico e prognóstico procuram sintetizar evidência sobre a capacidade de testes, instrumentos ou modelos para identificar condições de saúde ou estimar acontecimentos futuros.

Embora estejam relacionadas, estas áreas respondem a perguntas diferentes. A investigação diagnóstica avalia, por exemplo, se um teste identifica correctamente uma doença ou condição presente. A investigação prognóstica avalia se um modelo estima a probabilidade de um acontecimento futuro, como mortalidade, recorrência, complicação ou progressão de uma doença.

A diferença entre as duas áreas determina os critérios de inclusão, as medidas estatísticas, os modelos de síntese e os instrumentos de avaliação crítica.

Conceito central

Uma revisão de acurácia diagnóstica sintetiza o desempenho de testes para classificar uma condição relativamente a um padrão de referência. Uma revisão de prognóstico sintetiza evidência sobre a evolução futura de uma condição ou sobre o desempenho de modelos que estimam riscos individuais.

O rigor metodológico exige que se distinga entre:

- acurácia de um teste;
- associação entre um marcador e um resultado;
- capacidade de discriminação de um modelo prognóstico;
- calibração das probabilidades estimadas;
- utilidade clínica ou prática das previsões.

Estas propriedades não são equivalentes. Um teste pode discriminar bem duas classes sem fornecer probabilidades prognósticas bem calibradas. Do mesmo modo, um marcador associado a um resultado não constitui necessariamente um modelo prognóstico útil.

2. Objectivos de aprendizagem

No final do módulo, o participante deverá ser capaz de:

1. Distinguir perguntas de diagnóstico e de prognóstico.
2. Formular uma pergunta estruturada para cada tipo de revisão.
3. Interpretar sensibilidade, especificidade, valores preditivos e razões de verosimilhança.
4. Interpretar curvas ROC e área sob a curva.

5. Explicar a dependência entre sensibilidade e especificidade nos estudos de acurácia diagnóstica.
6. Reconhecer modelos estatísticos específicos para a síntese de estudos diagnósticos.
7. Distinguir discriminação, calibração e utilidade de modelos prognósticos.
8. Compreender validação interna e validação externa.
9. Seleccionar instrumentos adequados para avaliar o risco de viés e a aplicabilidade dos estudos.
10. Elaborar um plano metodológico para uma revisão especializada.

3. Diagnóstico e prognóstico: diferenças fundamentais

3.1. Estudos de acurácia diagnóstica

Um estudo de acurácia diagnóstica compara um teste índice com um padrão de referência considerado adequado para determinar a presença ou ausência da condição de interesse.

Exemplos de perguntas:

- Qual é a sensibilidade e a especificidade de um teste rápido?
- O desempenho de um teste varia entre diferentes contextos?
- Qual é o desempenho de um método de imagem comparado com um padrão de referência?
- Como varia a acurácia entre diferentes limiares de decisão?

3.2. Estudos de prognóstico

Os estudos prognósticos podem descrever a evolução de uma condição ao longo do tempo ou avaliar modelos que estimam a probabilidade de um acontecimento futuro.

Exemplos de perguntas:

- Qual é o risco de recorrência durante um determinado período?
- Que factores estão associados à progressão de uma doença?
- Qual é a capacidade de um modelo para estimar o risco individual de mortalidade?
- O modelo mantém a sua calibração em populações diferentes daquela em que foi desenvolvido?

Tabela 1: Diferenças entre revisões diagnósticas e prognósticas

Dimensão	**Diagnóstico**	**Prognóstico**
Pergunta	O teste identifica correctamente uma condição presente?	O modelo estima correctamente um resultado futuro?
Comparador	Padrão de referência	Resultado observado durante um horizonte temporal definido
Medidas frequentes	Sensibilidade, especificidade, LR e AUC	Discriminação, calibração, erro preditivo e utilidade
Estrutura dos dados	Resultados positivos e negativos do teste e do padrão de referência	Preditores, resultados e seguimento temporal
Risco de viés	Selecção de participantes, teste índice, padrão de referência e fluxo	Participantes, preditores, resultados e análise
Questão de aplicabilidade	População, contexto, teste e limiar de decisão	População, horizonte temporal, preditores e contexto de utilização

4. Formulação da pergunta de revisão

4.1. Perguntas de diagnóstico

Uma pergunta diagnóstica deve especificar, pelo menos:

- **População:** participantes nos quais o teste será utilizado;
- **Teste índice:** teste ou procedimento avaliado;
- **Padrão de referência:** método utilizado para determinar a condição-alvo;
- **Condição-alvo:** doença, estado ou característica que se pretende identificar;
- **Contexto:** local e circunstâncias da utilização;
- **Limiar:** ponto de corte utilizado, quando aplicável.

Exemplo de pergunta diagnóstica

Em adultos com suspeita da condição X, qual é a sensibilidade e a especificidade do teste índice Y, comparado com o padrão de referência Z, em contextos de cuidados primários?

4.2. Perguntas de prognóstico

Uma pergunta prognóstica deve identificar:

- população de interesse;
- resultado a prever;
- horizonte temporal;
- preditores ou modelo prognóstico;
- contexto de utilização;
- tipo de desempenho que se pretende sintetizar.

Exemplo de pergunta prognóstica

Em adultos diagnosticados com a condição X, qual é o desempenho discriminativo e a calibração dos modelos que estimam o risco de recorrência aos dois anos?

4.3. Definição prévia do protocolo

O protocolo deve especificar a pergunta, os critérios de elegibilidade, as fontes de informação, a estratégia de pesquisa, os processos de selecção, os dados a extrair, os instrumentos de avaliação crítica e os métodos de síntese.

Deve também indicar como serão tratados:

- diferentes limiares diagnósticos;
- diferentes padrões de referência;
- diferentes horizontes temporais;
- populações e contextos distintos;
- modelos desenvolvidos e modelos validados externamente;
- dados incompletos ou resultados não reportados.

5. Medidas de acurácia diagnóstica

5.1. Tabela de contingência

A avaliação convencional da acurácia diagnóstica utiliza uma tabela de contingência que compara o resultado do teste índice com o estado definido pelo padrão de referência.

	Padrão de referência		**Total**
Teste índice	Condição presente	Condição ausente	
Teste positivo	Verdadeiro positivo (VP)	Falso positivo (FP)	VP + FP
Teste negativo	Falso negativo (FN)	Verdadeiro negativo (VN)	FN + VN
Total	VP + FN	FP + VN	N

Em que:

$$N = VP + FP + FN + VN.$$

As fórmulas seguintes pressupõem uma classificação binária e um padrão de referência que permite definir a condição-alvo.

5.2. Sensibilidade

A sensibilidade é a proporção de indivíduos com a condição que obtêm um resultado positivo no teste.

$$\text{Sensibilidade} = \frac{VP}{VP + FN}.$$

Uma sensibilidade elevada significa que o teste identifica uma proporção elevada dos indivíduos que têm a condição. Um teste com sensibilidade baixa pode produzir muitos falsos negativos.

5.3. Especificidade

A especificidade é a proporção de indivíduos sem a condição que obtêm um resultado negativo.

$$\text{Especificidade} = \frac{VN}{VN + FP}.$$

Uma especificidade elevada significa que o teste classifica correctamente uma proporção elevada dos indivíduos sem a condição.

5.4. Valores preditivos

O valor preditivo positivo (VPP) é a proporção de resultados positivos que correspondem a indivíduos com a condição.

$$VPP = \frac{VP}{VP + FP}.$$

O valor preditivo negativo (VPN) é a proporção de resultados negativos que correspondem a indivíduos sem a condição.

$$VPN = \frac{VN}{VN + FN}.$$

Dependência da prevalência

Os valores preditivos dependem da prevalência da condição na população em que o teste é utilizado, além da sensibilidade e da especificidade. Por isso, os valores preditivos observados numa amostra não devem ser transferidos automaticamente para populações com prevalências diferentes.

5.5. Razões de verosimilhança

As razões de verosimilhança relacionam a probabilidade de um resultado do teste entre pessoas com e sem a condição.

A razão de verosimilhança positiva é:

$$LR^{+} = \frac{\text{Sensibilidade}}{1 - \text{Especificidade}}.$$

A razão de verosimilhança negativa é:

$$LR^{-} = \frac{1 - \text{Sensibilidade}}{\text{Especificidade}}.$$

Em geral, um LR^{+} maior aumenta a probabilidade da condição após um resultado positivo. Um LR^{-} mais próximo de zero reduz a probabilidade da condição após um resultado negativo.

A interpretação deve considerar os valores concretos, a incerteza estatística, a população e a finalidade clínica ou prática.

5.6. Exemplo numérico completo

Considere-se um teste fictício aplicado a 1 000 indivíduos. O padrão de referência identifica 200 indivíduos com a condição e 800 sem a condição.

O teste apresenta os seguintes resultados:

- VP = 160;
- FN = 40;
- FP = 120;
- VN = 680.

	Condição presente	**Condição ausente**	**Total**
Teste positivo	160	120	280
Teste negativo	40	680	720
Total	200	800	1 000

A sensibilidade é:

$$Se = \frac{160}{160 + 40} = 0.80 = 80\%.$$

A especificidade é:

$$Sp = \frac{680}{680 + 120} = 0.85 = 85\%.$$

O valor preditivo positivo é:

$$VPP = \frac{160}{160 + 120} = 0.5714 \approx 57.1\%.$$

O valor preditivo negativo é:

$$VPN = \frac{680}{680 + 40} = 0.9444 \approx 94.4\%.$$

As razões de verosimilhança são:

$$LR^{+} = \frac{0.80}{1 - 0.85} = \frac{0.80}{0.15} \approx 5.33,$$

$$LR^{-} = \frac{1 - 0.80}{0.85} = \frac{0.20}{0.85} \approx 0.235.$$

A acurácia global é:

$$A = \frac{VP + VN}{N} = \frac{160 + 680}{1000} = 84\%.$$

Interpretação Neste exemplo, o teste identifica 80% dos indivíduos com a condição e classifica correctamente 85% dos indivíduos sem a condição. Apesar da especificidade relativamente elevada, o VPP é aproximadamente 57.1%, devido, entre outros factores, à prevalência de 20% nesta população.

A acurácia global de 84% não substitui a análise da sensibilidade, especificidade, valores preditivos e consequências dos erros de classificação.

6. Curvas ROC e área sob a curva

6.1. Curva ROC

A curva ROC (*Receiver Operating Characteristic*) representa a sensibilidade em função da taxa de falsos positivos para diferentes limiares de decisão.

A taxa de falsos positivos é:

$$FPR = 1 - Sp.$$

Assim, cada limiar pode originar um ponto:

$$(1 - Sp(c), Se(c)),$$

em que c representa o limiar utilizado para classificar o resultado do teste.

Um teste com resultados contínuos pode produzir vários pares de sensibilidade e especificidade, consoante o limiar escolhido.

6.2. Área sob a curva ROC

A área sob a curva ROC (AUC) resume a capacidade discriminativa do teste ao longo dos limiares.

$$AUC = \int_0^1 ROC(x)\, dx.$$

Uma interpretação probabilística comum é que a AUC corresponde à probabilidade de um indivíduo escolhido aleatoriamente com a condição apresentar um resultado mais indicativo da condição do que um indivíduo escolhido aleatoriamente sem a condição, com os cuidados necessários relativamente a empates e à definição do resultado do teste.

- $AUC = 0.5$: discriminação equivalente à de uma classificação aleatória no sentido convencional da ROC.
- AUC mais elevada: melhor discriminação global.
- $AUC = 1$: discriminação perfeita nos dados considerados.

Uma AUC elevada não garante, por si só, utilidade clínica, calibração, desempenho consistente em novas populações ou um limiar adequado para a decisão.

6.3. Escolha do limiar

A selecção de um limiar depende das consequências de falsos positivos e falsos negativos, da prevalência, dos recursos disponíveis e do objectivo do teste.

Um limiar pode ser adequado para rastreio, mas inadequado para confirmar uma condição. A escolha não deve basear-se exclusivamente na maximização de uma estatística sem considerar o contexto.

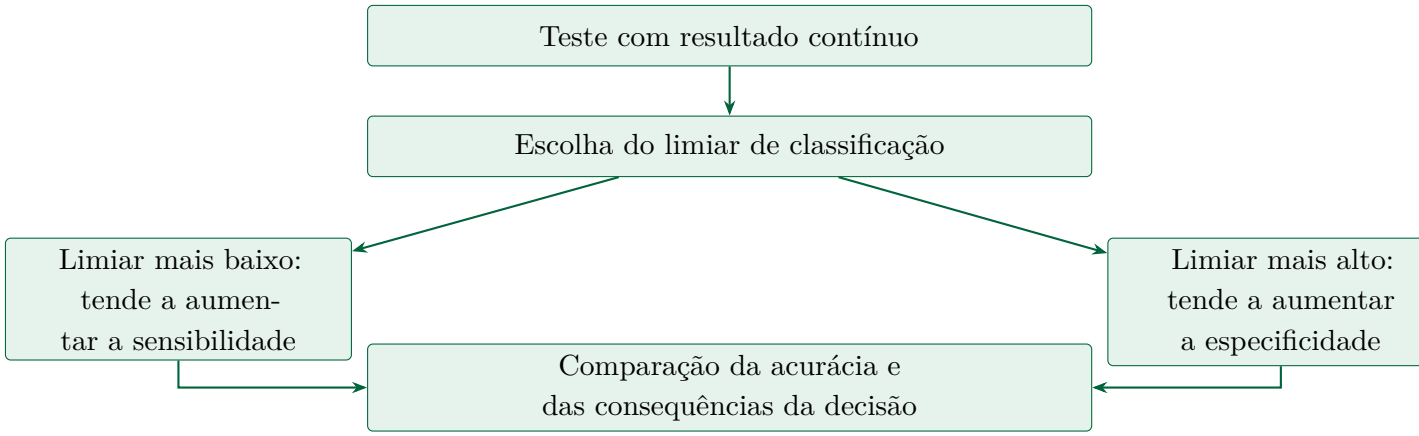
7. Dependência entre sensibilidade e especificidade

7.1. O efeito do limiar

Quando um teste contínuo utiliza um limiar mais baixo para classificar um resultado como positivo, tende a aumentar a sensibilidade e a diminuir a especificidade.

Quando o limiar aumenta, tende a diminuir a sensibilidade e a aumentar a especificidade.

Esta relação não significa que a sensibilidade e a especificidade sejam sempre complementares. A sua combinação depende da distribuição dos resultados do teste entre os indivíduos com e sem a condição.



7.2. Implicações para a meta-análise

Uma abordagem inadequada consiste em calcular uma média simples das sensibilidades e outra das especificidades, ignorando a relação entre elas e os limiares utilizados nos estudos.

A síntese deve considerar:

- se todos os estudos utilizam o mesmo limiar;
- se os testes são contínuos ou categóricos;
- se os limiares foram definidos previamente;
- se os participantes representam populações comparáveis;
- se os padrões de referência são semelhantes;
- se a variação observada resulta de diferenças clínicas, metodológicas ou de medição.

8. Modelos estatísticos para síntese diagnóstica

8.1. Por que utilizar modelos específicos?

Os estudos de acurácia diagnóstica apresentam frequentemente uma estrutura bivariada: cada estudo fornece informação sobre sensibilidade e especificidade, que podem estar estatisticamente relacionadas.

Além disso, as estimativas têm incerteza amostral e podem variar entre estudos devido a diferenças de população, limiares, execução do teste, critérios de interpretação e padrões de referência.

Os modelos devem considerar a estrutura dos dados e não apenas a disponibilidade de medidas agregadas.

8.2. Modelo bivariado de efeitos aleatórios

O modelo bivariado permite sintetizar conjuntamente a sensibilidade e a especificidade, frequentemente através de transformações logit.

Para o estudo i, podem representar-se os resultados por:

$$\begin{aligned} \text{logit}(Se_i) &= \mu_{Se} + u_{Se,i}, \\ \text{logit}(Sp_i) &= \mu_{Sp} + u_{Sp,i}. \end{aligned}$$

Os efeitos aleatórios podem seguir uma distribuição normal bivariada:

$$\begin{pmatrix} u_{Se,i} \\ u_{Sp,i} \end{pmatrix} \sim N\left[\begin{pmatrix} 0 \\ 0 \end{pmatrix}, \begin{pmatrix} \tau^2_{Se} & \rho\tau_{Se}\tau_{Sp} \\ \rho\tau_{Se}\tau_{Sp} & \tau^2_{Sp} \end{pmatrix} \right].$$

Em que:

- μ_{Se} e μ_{Sp} representam as médias na escala logit;
- τ^2_{Se} e τ^2_{Sp} representam a variabilidade entre estudos;
- ρ representa a correlação entre os efeitos aleatórios de sensibilidade e especificidade.

A formulação é esquemática. A estimação real inclui os modelos binomiais para os números de verdadeiros positivos, falsos negativos, verdadeiros negativos e falsos positivos, bem como as particularidades do método de estimação utilizado.

8.3. Modelo HSROC

O modelo HSROC (*Hierarchical Summary Receiver Operating Characteristic*) descreve a relação entre sensibilidade e especificidade através de uma estrutura hierárquica de acurácia e limiar.

Pode ser especialmente útil quando existem limiares diferentes entre estudos e se pretende caracterizar a relação ROC subjacente.

O modelo bivariado e o HSROC estão relacionados, mas não são idênticos em todas as parametrizações e condições. A escolha deve ser justificada pela estrutura dos dados, pela pergunta da revisão e pelos pressupostos do modelo.

8.4. Curva ROC sumária

Uma curva ROC sumária apresenta a relação estimada entre sensibilidade e especificidade. Pode ser acompanhada de uma região de confiança para o ponto sumário e, quando disponível e adequadamente estimada, de uma região de predição para a variabilidade esperada entre novos contextos.

A região de confiança representa a incerteza sobre os parâmetros sumários; a região de predição representa, sob os pressupostos do modelo, a variação esperada entre contextos ou estudos. Não devem ser interpretadas como equivalentes.

8.5. Razão de possibilidades diagnóstica

A razão de possibilidades diagnóstica (*Diagnostic Odds Ratio*, DOR) pode ser expressa como:

$$DOR = \frac{VP/FN}{FP/VN} = \frac{VP \times VN}{FP \times FN}.$$

Uma DOR mais elevada indica maior separação entre os resultados do teste nos indivíduos com e sem a condição, no sentido da classificação considerada.

Contudo, a DOR combina informação sobre falsos positivos e falsos negativos numa única medida. Não substitui a apresentação separada da sensibilidade e da especificidade, nem descreve directamente os valores preditivos numa população específica.

Quando existem células com zero observações, a DOR pode ser indefinida ou exigir métodos específicos de estimação. A aplicação automática de correcções numéricas deve ser justificada.

8.6. Heterogeneidade em estudos diagnósticos

A heterogeneidade pode resultar de:

- diferenças na gravidade da condição;
- variação da prevalência e do espectro clínico;
- diferenças nos limiares;
- utilização de padrões de referência distintos;
- diferenças na execução ou interpretação do teste;

- desenhos de estudo diferentes;
- selecção de participantes e contextos de utilização.

A heterogeneidade não deve ser avaliada apenas por um indicador genérico. É necessário examinar os mecanismos clínicos e metodológicos que podem produzir diferenças no desempenho.

Número reduzido de estudos

Os modelos hierárquicos podem ser instáveis quando existem poucos estudos, amostras pequenas ou tabelas de contingência esparsas. A complexidade do modelo deve ser proporcional à informação disponível, e as limitações da estimação devem ser relatadas.

9. Validação e avaliação de modelos prognósticos

9.1. Modelo prognóstico

Um modelo prognóstico utiliza uma ou mais características dos participantes para estimar a probabilidade de um resultado futuro, num horizonte temporal definido.

Um modelo pode ser representado de forma geral por:

$$\widehat{p}_i = f(X_{i1}, X_{i2}, \ldots, X_{ik}),$$

em que:

- $\widehat{p}_i$ é o risco estimado para o indivíduo i;
- X_{ij} são os preditores;
- f é a função estimada a partir dos dados.

Em modelos de sobrevivência, a previsão pode corresponder ao risco de um acontecimento até um determinado tempo t, tendo em conta o tratamento do tempo de seguimento e da censura.

9.2. Discriminação

A discriminação mede a capacidade do modelo para atribuir previsões diferentes a indivíduos que apresentam resultados distintos.

Para resultados binários, pode utilizar-se a AUC ou estatísticas relacionadas. Em modelos de sobrevivência, podem utilizar-se medidas de concordância adequadas ao tempo e à censura.

Uma discriminação elevada não garante que os riscos previstos sejam numericamente correctos.

9.3. Calibração

A calibração avalia a concordância entre os riscos previstos e os resultados observados.

Se um modelo prevê um risco de 20% para um grupo de indivíduos comparáveis, a calibração examina se a frequência observada do resultado se aproxima desse valor, considerando o horizonte temporal e o método de avaliação.

9.3.1. Calibração global

Para resultados binários, a calibração pode ser examinada comparando probabilidades previstas e frequências observadas, através de gráficos ou modelos de calibração.

9.3.2. Intercepto e declive de calibração

O intercepto de calibração examina, de forma simplificada, a tendência global de subestimação ou sobrestimação do risco. O declive de calibração avalia se as previsões são demasiado extremas ou demasiado concentradas.

Um declive inferior a 1 pode indicar previsões excessivamente extremas, situação frequentemente associada a sobreajustamento, embora a interpretação dependa do procedimento de avaliação.

Estes parâmetros devem ser estimados e interpretados segundo o modelo e o desenho de validação utilizados.

9.4. Erro de previsão

Para resultados binários, o escore de Brier pode ser escrito como:

$$BS = \frac{1}{N}\sum_{i=1}^{N}(\widehat{p}_i - y_i)^2,$$

em que $y_i \in \{0, 1\}$ representa o resultado observado.

Valores menores indicam menor erro quadrático médio das probabilidades previstas, mas a interpretação deve considerar a prevalência, o horizonte temporal e o contexto. Para resultados de sobrevivência, é necessário utilizar versões adequadas que considerem a censura e o tempo.

9.5. Validação interna e externa

Tabela 2: Tipos de validação de modelos prognósticos

Tipo	Procedimento	Finalidade e limitações
Validação interna	Reamostragem, por exemplo bootstrap, ou validação cruzada adequadamente implementada.	Estima a estabilidade e o optimismo do desempenho dentro do contexto de desenvolvimento. Não demonstra, por si só, a transportabilidade para outras populações.
Validação temporal	Avaliação em participantes recrutados num período posterior.	Examina a estabilidade do desempenho ao longo do tempo no contexto considerado.
Validação geográfica	Avaliação em instituições, regiões ou áreas geográficas diferentes.	Examina a transportabilidade para outros contextos geográficos.
Validação externa independente	Aplicação do modelo a dados independentes dos utilizados no desenvolvimento.	Avalia o desempenho numa população ou contexto distinto, desde que o procedimento de avaliação seja apropriado.

A divisão aleatória dos dados não garante uma validação independente se existir fuga de informação entre conjuntos ou se o modelo for repetidamente ajustado com base no conjunto de validação.

9.6. Desenvolvimento versus validação

É essencial distinguir estudos que desenvolvem um modelo dos estudos que avaliam um modelo já definido.

No desenvolvimento, são seleccionados preditores e estimados parâmetros. Na validação, avalia-se o desempenho do modelo num conjunto de dados adequado, sem ajustar novamente o modelo de forma a favorecer os resultados dessa validação.

Quando se efectua uma actualização ou recalibração do modelo, esse procedimento deve ser explicitado e distinguido da avaliação do modelo original.

9.7. Risco de sobreajustamento

O sobreajustamento ocorre quando o modelo capta características específicas dos dados de desenvolvimento que não se reproduzem em novos dados.

Pode resultar de:

- número insuficiente de participantes ou acontecimentos;
- selecção excessiva de preditores;

- utilização de procedimentos de selecção instáveis;
- ausência de validação interna adequada;
- fuga de informação entre os conjuntos de dados;
- optimização repetida de decisões com base nos mesmos dados.

A avaliação prognóstica deve examinar o desenho do estudo, o tamanho da amostra, o número de acontecimentos, a estratégia de modelação, o tratamento de dados em falta e os métodos de validação.

10. Risco de viés e aplicabilidade

10.1. Estudos de acurácia diagnóstica: QUADAS-2

O QUADAS-2 é um instrumento para avaliar o risco de viés e as preocupações relativas à aplicabilidade em estudos de acurácia diagnóstica.

Considera quatro domínios principais:

1. **Selecção de participantes:** forma como os participantes foram seleccionados e possíveis exclusões inadequadas.
2. **Teste índice:** execução e interpretação do teste, incluindo a utilização de limiares.
3. **Padrão de referência:** adequação do padrão e conhecimento dos resultados do teste índice, quando relevante.
4. **Fluxo e tempo:** sequência dos procedimentos, intervalo entre teste e padrão de referência, e tratamento dos participantes sem resultados completos.

Os primeiros três domínios são também utilizados na avaliação das preocupações com a aplicabilidade. O domínio de fluxo e tempo contribui para a avaliação do risco de viés.

10.2. Exemplos de problemas de viés diagnóstico

Tabela 3: Problemas metodológicos em estudos diagnósticos

Problema	Exemplo	Possível consequência
Viés de selecção	Inclusão apenas de casos graves e controlos saudáveis.	Pode produzir uma estimativa de acurácia que não representa a prática habitual.

Problema	Exemplo	Possível consequência
Viés de revisão	O avaliador conhece o resultado do teste índice ao interpretar o padrão de referência.	Pode influenciar a classificação final da condição.
Limiar escolhido após observar os dados	O melhor ponto de corte é seleccionado e avaliado na mesma amostra.	Pode sobrestimar o desempenho do teste.
Padrão de referência inadequado	A condição é definida por um método imperfeito ou inconsistente.	Pode introduzir erros na classificação dos participantes.
Verificação parcial	Nem todos os participantes recebem o padrão de referência.	Pode distorcer as estimativas de sensibilidade e especificidade.
Perdas ou exclusões após inclusão	Participantes sem resultados completos são excluídos sem análise.	Pode comprometer a comparabilidade e introduzir viés.

10.3. Modelos prognósticos: PROBAST

O PROBAST foi desenvolvido para avaliar o risco de viés e a aplicabilidade de estudos de modelos de previsão diagnóstica e prognóstica. Para uma revisão de modelos prognósticos, deve ser utilizada a estrutura apropriada à finalidade do estudo.

O instrumento organiza a avaliação em quatro domínios:

1. **Participantes:** selecção, elegibilidade e representatividade da população.
2. **Preditores:** definição, medição e disponibilidade dos preditores no momento em que o modelo seria utilizado.
3. **Resultados:** definição, determinação e momento de avaliação dos resultados.
4. **Análise:** tamanho da amostra, dados em falta, selecção de preditores, sobreajustamento e avaliação do desempenho.

10.4. Problemas de viés prognóstico

- exclusão de participantes sem justificação adequada;
- preditores medidos de forma inconsistente;
- definição ambígua do resultado;
- horizonte temporal incompatível com a pergunta;

- tratamento inadequado de dados em falta;
- selecção de preditores baseada nos mesmos dados sem controlo do sobreajustamento;
- avaliação do modelo nos mesmos dados em que foi desenvolvido;
- ausência de avaliação da calibração;
- apresentação selectiva de medidas de desempenho.

Risco de viés não é sinónimo de desempenho

Um modelo pode apresentar uma AUC elevada e, simultaneamente, ter elevado risco de viés ou calibração inadequada. A avaliação metodológica deve ser separada da apresentação dos resultados de desempenho.

11. Estratégia de pesquisa, selecção e extracção

11.1. Fontes de informação

A selecção das fontes deve depender da pergunta, da área temática e dos tipos de estudos esperados. Podem considerar-se bases de dados bibliográficas como MEDLINE/PubMed, Embase, Scopus e Web of Science, bem como fontes especializadas relevantes.

A estratégia deve ser adaptada a cada base de dados, utilizando vocabulários controlados quando disponíveis, termos livres, sinónimos e operadores booleanos.

Uma estratégia genérica para estudos diagnósticos pode combinar:

```
(diagnostic accuracy OR sensitivity OR specificity OR ROC)
AND
(index test OR diagnostic test)
AND
(target condition)
```

Uma estratégia genérica para modelos prognósticos pode combinar:

```
(prognostic model OR prediction model OR risk prediction)
AND
(validation OR discrimination OR calibration)
AND
(target outcome)
```

Estas expressões são exemplos conceptuais, não estratégias prontas para submissão. Devem ser adaptadas à base de dados, aos termos indexados e à pergunta concreta.

11.2. Selecção dos estudos

O processo de selecção deve ser documentado e incluir:

1. remoção de duplicados;
2. triagem de títulos e resumos;
3. avaliação do texto integral;
4. registo dos motivos de exclusão na fase de texto integral;
5. resolução de discordâncias segundo o protocolo;
6. apresentação do fluxo de selecção.

Sempre que possível, a elegibilidade deve ser avaliada por dois revisores de forma independente, com um procedimento predefinido para resolver discordâncias.

11.3. Dados a extrair de estudos diagnósticos

A extracção deve incluir, conforme aplicável:

- referência e características do estudo;
- desenho e contexto;
- critérios de inclusão e exclusão;
- características dos participantes;
- prevalência ou proporção com a condição;
- descrição do teste índice;
- limiar de decisão;
- descrição do padrão de referência;
- VP, FP, FN e VN;
- estimativas de sensibilidade e especificidade;
- informação sobre dados em falta;
- elementos necessários para avaliar o risco de viés.

11.4. Dados a extrair de estudos prognósticos

A extracção pode incluir:

- finalidade e tipo de modelo;
- população, contexto e período de recrutamento;

- resultado previsto e horizonte temporal;
- definição e medição dos preditores;
- número de participantes e acontecimentos;
- tratamento dos dados em falta;
- método de desenvolvimento do modelo;
- validação interna ou externa;
- discriminação, calibração e medidas de erro;
- informação sobre actualização ou recalibração;
- elementos necessários para avaliar o risco de viés.

11.5. Dados incompletos e resultados não reportados

A equipa deve documentar quais os dados que não foram reportados, quais foram obtidos por contacto com os autores e quais foram calculados a partir da informação disponível.

Não se devem reconstruir tabelas de contingência sem informação suficiente. Do mesmo modo, resultados de prognóstico não devem ser tratados como equivalentes quando utilizam horizontes temporais, definições de resultados ou métricas diferentes.

12. Plano de síntese estatística

12.1. Síntese diagnóstica

Um plano de síntese diagnóstica deve indicar:

1. a medida principal de acurácia;
2. o modelo estatístico escolhido;
3. o tratamento de estudos com dados esparsos;
4. a análise de diferentes limiares;
5. os factores de heterogeneidade a investigar;
6. as análises de sensibilidade previstas;
7. a forma de apresentação da incerteza.

Se os estudos apresentarem dados comparáveis, pode considerar-se um modelo bivariado ou HSROC. Se a heterogeneidade clínica ou metodológica impedir uma síntese estatística defensável, deve privilegiar-se uma síntese estruturada sem combinar resultados inadequadamente.

12.2. Síntese prognóstica

A síntese de estudos prognósticos exige atenção à comparabilidade entre modelos, resultados e horizontes temporais.

O protocolo deve especificar:

- se serão sintetizados modelos de desenvolvimento, validação ou ambos;
- quais as medidas de desempenho prioritárias;
- como serão tratados diferentes horizontes temporais;
- se os modelos utilizam os mesmos resultados e populações;
- como serão consideradas as diferenças de calibração;
- quais as condições para efectuar uma meta-análise;
- como serão descritos os modelos sem resultados comparáveis.

Uma média simples de AUC provenientes de populações, horizontes temporais e métodos de validação muito diferentes pode ser enganadora. A síntese deve considerar a estrutura dos dados, a dependência entre estimativas e as fontes de heterogeneidade.

12.3. Análises de subgrupos

Os subgrupos devem ser definidos previamente e fundamentados cientificamente.

Em estudos diagnósticos, podem considerar-se:

- tipo de teste;
- limiar de decisão;
- gravidade da condição;
- contexto de utilização;
- tipo de padrão de referência;
- desenho do estudo.

Em estudos prognósticos, podem considerar-se:

- população de desenvolvimento ou validação;
- horizonte temporal;

- contexto geográfico ou institucional;
- tipo de modelo;
- resultado previsto;
- disponibilidade e qualidade dos preditores.

As análises de subgrupos devem ser interpretadas com cautela quando existem poucos estudos ou quando as comparações não foram previstas no protocolo.

13. Implementação ilustrativa em R

13.1. Cálculo das medidas diagnósticas

O código seguinte calcula sensibilidade, especificidade, valores preditivos e razões de verosimilhança a partir de uma tabela de contingência fictícia.

```r
# Dados ficticios de um estudo diagnostico
VP <- 160
FN <- 40
FP <- 120
VN <- 680

sensibilidade <- VP / (VP + FN)
especificidade <- VN / (VN + FP)

VPP <- VP / (VP + FP)
VPN <- VN / (VN + FN)

LR_positivo <- sensibilidade / (1 - especificidade)
LR_negativo <- (1 - sensibilidade) / especificidade

acuracia <- (VP + VN) / (VP + FN + FP + VN)

resultados <- data.frame(
  Medida = c(
    "Sensibilidade",
    "Especificidade",
    "Valor preditivo positivo",
    "Valor preditivo negativo",
    "LR positivo",
    "LR negativo",
    "Acuracia global"
  ),
  Valor = c(
    sensibilidade,
    especificidade,
```

```
    VPP,
    VPN,
    LR_positivo,
    LR_negativo,
    acuracia
  )
)

print(resultados)
```

O código utiliza valores fictícios e não substitui a estimação de intervalos de confiança nem uma síntese de múltiplos estudos.

13.2. Modelo bivariado para estudos diagnósticos

O pacote `mada` do R disponibiliza ferramentas para análise de dados de acurácia diagnóstica, incluindo modelos bivariados e abordagens HSROC. A sintaxe exacta deve ser confirmada na documentação da versão instalada.

```
# Instalar uma vez, se necessario
install.packages("mada")

library(mada)

# Exemplo com dados ficticios de cinco estudos
dados <- data.frame(
  TP = c(45, 62, 38, 71, 54),
  FN = c(15, 18, 12, 19, 16),
  FP = c(12, 20, 10, 25, 14),
  TN = c(88, 100, 75, 110, 92)
)

# Converter para a estrutura de dados do mada
d <- mada::mada(
  data.frame(
    TP = dados$TP,
    FN = dados$FN,
    FP = dados$FP,
    TN = dados$TN
  )
)

# Ajustar o modelo bivariado
modelo <- mada::reitsma(d)

# Resumo do modelo
summary(modelo)
```

```r

# Representacao grafica
plot(modelo)
```

Verificação do software

O código é um exemplo de implementação e deve ser testado na versão do pacote instalada. Antes da análise definitiva, verifique a documentação, os argumentos aceites e os pressupostos do modelo. Confirme também se os dados foram correctamente mapeados para verdadeiros positivos, falsos negativos, falsos positivos e verdadeiros negativos.

13.3. Exemplo de avaliação de previsões prognósticas

Para um resultado binário, o código seguinte calcula o escore de Brier e a AUC a partir de probabilidades previstas e resultados observados. Trata-se de uma demonstração simplificada, não de uma validação completa de um modelo prognóstico.

```r
# Instalar uma vez, se necessario
install.packages("pROC")

library(pROC)

# Resultados ficticios
observado <- c(1, 0, 1, 0, 0, 1, 0, 1, 0, 1)
previsto <- c(0.80, 0.25, 0.65, 0.30, 0.40,
              0.75, 0.20, 0.70, 0.35, 0.60)

# Escore de Brier
brier <- mean((previsto - observado)^2)

# AUC
roc_obj <- roc(
  response = observado,
  predictor = previsto,
  quiet = TRUE
)

auc_valor <- as.numeric(auc(roc_obj))

cat("Brier score:", brier, "\n")
cat("AUC:", auc_valor, "\n")

plot(
  roc_obj,
  main = "Curva ROC - exemplo ilustrativo"
)
```

O exemplo não avalia a calibração, não considera censura e não demonstra validação externa. Para resultados de sobrevivência, devem utilizar-se métodos apropriados ao tempo de seguimento e à censura.

14. Actividade prática

Análise crítica de uma revisão de diagnóstico ou prognóstico

Objectivo: avaliar a coerência entre a pergunta, os métodos, as medidas estatísticas, a avaliação do risco de viés e as conclusões de uma revisão publicada.

Etapa 1 — Selecção da revisão

Seleccionar uma revisão sistemática publicada que tenha como objecto:

- a acurácia de um teste diagnóstico; ou
- o desempenho de modelos prognósticos.

Registar a referência completa, o DOI, a pergunta da revisão e a área de aplicação.

Etapa 2 — Análise da pergunta

Identificar a população, o teste índice, o padrão de referência e a condição-alvo, se for uma revisão diagnóstica.
Se for uma revisão prognóstica, identificar a população, os modelos, os preditores, os resultados previstos e os horizontes temporais.

Etapa 3 — Análise dos métodos

Verificar:

1. se os critérios de elegibilidade estão claros;
2. se a pesquisa bibliográfica é reproduzível;
3. se a selecção e a extracção foram documentadas;
4. se o instrumento de risco de viés é apropriado;
5. se as medidas estatísticas respondem à pergunta;
6. se o modelo de síntese é justificado;
7. se a heterogeneidade foi examinada adequadamente;
8. se as limitações são discutidas.

Etapa 4 — Interpretação dos resultados

Para uma revisão diagnóstica, examinar sensibilidade, especificidade, limiares, curvas ROC e regiões de incerteza.
Para uma revisão prognóstica, examinar discriminação, calibração, horizonte temporal, validação e utilidade do modelo.

Etapa 5 — Elaboração do plano metodológico

Preparar um plano de revisão que inclua:

- título provisório;
- justificação e pergunta;
- critérios de inclusão e exclusão;
- fontes de informação;

15. Modelo de plano metodológico

O seguinte modelo pode ser preenchido pelos participantes e adaptado ao tipo de revisão seleccionado.

Tabela 4: Plano metodológico para revisão especializada

Componente	**Descrição a preencher**
Título provisório	Indicar a condição, o teste ou o modelo e a finalidade da revisão.
Justificação	Descrever o problema, a lacuna científica e a relevância da síntese.
Pergunta de investigação	Definir população, teste e padrão de referência, ou população, modelo, resultado e horizonte temporal.
Critérios de inclusão	Especificar desenhos, participantes, testes ou modelos, resultados, contextos e período de publicação, quando aplicável.
Critérios de exclusão	Definir exclusões justificadas e coerentes com a pergunta.
Bases de dados	Identificar as fontes bibliográficas e outras fontes pertinentes.
Estratégia de pesquisa	Descrever conceitos, sinónimos, vocabulários controlados e operadores.
Selecção dos estudos	Definir revisores, fases de selecção e resolução de discordâncias.
Extracção dos dados	Enumerar as variáveis e os procedimentos de verificação.
Avaliação crítica	Especificar QUADAS-2 para estudos de acurácia diagnóstica ou PROBAST para estudos de modelos de previsão, conforme aplicável.
Síntese estatística	Indicar medidas, modelos, condições para meta-análise e tratamento da heterogeneidade.
Análises adicionais	Definir subgrupos e análises de sensibilidade fundamentados.
Apresentação	Prever tabelas, gráficos, fluxograma e síntese narrativa.
Limitações previstas	Antecipar dados incompletos, heterogeneidade e limitações da evidência disponível.
Transparência	Indicar registo do protocolo, documentação de alterações e orientações de relato pertinentes.

16. Grelha de avaliação da actividade

Tabela 5: Rubrica de avaliação

Critério	**Peso**	**Pontuação**
Clareza e adequação da pergunta de investigação	10%	_____
Coerência dos critérios de elegibilidade	10%	_____
Adequação da pesquisa e da selecção	10%	_____
Qualidade do plano de extracção dos dados	10%	_____
Adequação do instrumento de avaliação crítica	15%	_____
Justificação das medidas e dos modelos de síntese	20%	_____
Interpretação crítica dos resultados e limitações	10%	_____
Clareza, organização e reprodutibilidade do plano	15%	_____
Total	**100%**	_____

17. Orientações para redacção e relato

A apresentação final deve seguir orientações de relato adequadas ao tipo de estudo e de revisão.

- **PRISMA 2020:** orientação geral para o relato de revisões sistemáticas.
- **PRISMA-DTA:** extensão destinada ao relato de revisões sistemáticas de estudos de acurácia diagnóstica.
- **TRIPOD:** orientação para o relato de estudos de desenvolvimento e validação de modelos de previsão.
- **PROBAST:** instrumento de avaliação do risco de viés e da aplicabilidade em estudos de modelos de previsão.
- **QUADAS-2:** instrumento de avaliação do risco de viés e da aplicabilidade em estudos de acurácia diagnóstica.

Estas ferramentas têm funções diferentes. Uma orientação de relato não substitui um instrumento de risco de viés, e nenhum deles substitui a definição de um protocolo adequado.

As versões actualizadas das orientações e dos instrumentos devem ser consultadas antes da sua aplicação num projecto real.

18. Conclusões do módulo

Conclusão 1 — Perguntas distintas

As revisões diagnósticas e prognósticas respondem a perguntas diferentes. A escolha dos estudos, das medidas e dos modelos deve reflectir a finalidade da investigação.

Conclusão 2 — Acurácia diagnóstica

Sensibilidade, especificidade, valores preditivos, razões de verosimilhança e curvas ROC fornecem perspectivas complementares. A interpretação exige atenção aos limiares, à prevalência e à heterogeneidade entre estudos.

Conclusão 3 — Modelos prognósticos

A discriminação não é suficiente para demonstrar a qualidade de um modelo prognóstico. A calibração, a validação, o horizonte temporal e a aplicabilidade devem ser examinados separadamente.

Conclusão 4 — Rigor metodológico

A avaliação do risco de viés, a escolha de modelos de síntese apropriados e a transparência das decisões são essenciais para produzir conclusões úteis e cientificamente defensáveis.

O produto final do módulo é um plano metodológico para uma revisão especializada, com pergunta definida, critérios de elegibilidade, estratégia de pesquisa, plano de extracção, avaliação crítica e método de síntese justificado.

19. Referências bibliográficas

[1] Whiting, P. F., Rutjes, A. W. S., Westwood, M. E., Mallett, S., Deeks, J. J., Reitsma, J. B., et al. (2011). QUADAS-2: A revised tool for the quality assessment of diagnostic accuracy studies. *Annals of Internal Medicine, 155*(8), 529–536. https://doi.org/10.7326/0003-4819-155-8-201110180-00009

[2] Macaskill, P., Gatsonis, C., Deeks, J. J., Harbord, R. M., & Takwoingi, Y. (2010). *Chapter 10: Analysing and presenting results of diagnostic test accuracy reviews.* In J. P. T. Higgins & S. Green (Eds.), *Cochrane Handbook for Systematic Reviews of Diagnostic Test Accuracy, Version 1.0.* The Cochrane Collaboration.

[3] Reitsma, J. B., Glas, A. S., Rutjes, A. W. S., Scholten, R. J. P. M., Bossuyt, P. M., & Zwinderman, A. H. (2005). Bivariate analysis of sensitivity and specificity produces informative summary measures in diagnostic reviews. *Journal of Clinical Epidemiology, 58*(10), 982–990. https://doi.org/10.1016/j.jclinepi.2005.02.022

[4] Rutter, C. M., & Gatsonis, C. A. (2001). A hierarchical regression approach to meta-analysis of diagnostic test accuracy evaluations. *Statistics in Medicine, 20*(19), 2865–2884. https://doi.org/10.1002/sim.942

[5] Bossuyt, P. M., Reitsma, J. B., Bruns, D. E., et al. (2015). STARD 2015: An updated list of essential items for reporting diagnostic accuracy studies. *BMJ, 351*, h5527. https://doi.org/10.1136/bmj.h5527

[6] McInnes, M. D. F., Moher, D., Thombs, B. D., et al. (2018). Preferred Reporting Items for a Systematic Review and Meta-analysis of Diagnostic Test Accuracy Studies: The PRISMA-DTA Statement. *JAMA, 319*(4), 388–396. https://doi.org/10.1001/jama.2017.19163

[7] Moons, K. G. M., Wolff, R. F., Riley, R. D., et al. (2019). PROBAST: A tool to assess risk of bias and applicability of prediction model studies. *Annals of Internal Medicine, 170*(1), 51–58. https://doi.org/10.7326/M18-1376

[8] Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. M. (2015). Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis (TRIPOD): The TRIPOD Statement. *Annals of Internal Medicine, 162*(1), 55–63. https://doi.org/10.7326/M14-0697

[9] Steyerberg, E. W. (2019). *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating* (2nd ed.). Springer. https://doi.org/10.1007/978-3-030-16399-0

[10] Debray, T. P. A., Damen, J. A. A. G., Snell, K. I. E., et al. (2017). A guide to systematic review and meta-analysis of prediction model performance. *BMJ, 356*, i6460. https://doi.org/10.1136/bmj.i6460

[11] Moons, K. G. M., de Groot, J. A. H., Bouwmeester, W., et al. (2014). Critical appraisal and data extraction for systematic reviews of prediction modelling studies: The CHARMS checklist. *PLoS Medicine, 11*(10), e1001744. https://doi.org/10.1371/journal.pmed.1001744

[12] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. https://www.r-project.org/

[13] mada package. *Meta-Analysis of Diagnostic Accuracy*. Documentação do pacote R. https://cran.r-project.org/package=mada

Rigor diagnóstico, previsão responsável e síntese de evidência cientificamente fundamentada